Analítica Predictiva y Prescriptiva

Semana 4: Evaluación de modelos

Universidad Icesi · TIC-60286

Dónde vamos

- **La semana pasada:** el task 3 dejó tres hallazgos con cifra y la columna prohibida. Se discute hoy en el cierre, contra el sobre.
- **Una historia:** los jueces de Nueva York y un algoritmo que predice el riesgo de un acusado — una predicción evaluada en crímenes y presos, contra la regla vigente.
- **El caso:** dos consultoras le ofrecen a Meridiano sus modelos de cierre y de ventas. Del porcentaje de aciertos al beneficio neto en pesos, local por local.
- **El cierre:** la cacería del task 3, y el task 4: el ranking de modelos.

Antes de empezar

Parada activa: encuesta

Dos consultoras ofrecen un modelo que predice si el arrendatario de un local cerraría antes de tres años. En el lote de validación, A tiene **85.8 %** de exactitud y B **79.2 %**. ¿Cuál compras: A, B o ninguna?

Antes de empezar

Parada activa: encuesta

Dos consultoras ofrecen un modelo que predice si el arrendatario de un local cerraría antes de tres años. En el lote de validación, A tiene **85.8 %** de exactitud y B **79.2 %**. ¿Cuál compras: A, B o ninguna?

Un dato antes de votar de nuevo: en ese lote cerró uno de cada cinco arrendatarios. "Ningún arrendatario cierra" acierta el **80.0 %** sin mirar un solo dato.

1 La historia: los jueces de Nueva York

2 La aplicación: las consultoras A y B

3 El task y el cierre

¿Puede un algoritmo mejorar las decisiones de un juez?

Qué investigaron. Si un algoritmo que predice el riesgo de un acusado puede mejorar las decisiones de libertad provisional: a quién dejar en libertad mientras llega el juicio y a quién mantener preso.

Por qué es una predicción. La ley le pide al juez una sola cosa: estimar si el acusado se fugará o cometerá un delito si lo libera. Es una decisión con una predicción en el centro.

La trampa

Un juez que acierta "mucho" no es necesariamente un buen juez: la mayoría de los acusados no se fuga, así que liberar a todos ya acierta en la mayoría de los casos. Suena conocido.

Kleinberg, Lakkaraju, Leskovec, Ludwig y Mullainathan (2018), *Quarterly Journal of Economics* — https://doi.org/10.1093/qje/qjx032

Qué datos y cómo

- **Cientos de miles de audiencias** en la ciudad de Nueva York, 2008–2013, con lo que el juez ve en el momento: el cargo actual, los antecedentes, la edad.
- Un modelo de **árboles** (*gradient boosting*) que predice la fuga y la reincidencia, entrenado en una parte de los casos y evaluado en otra que el modelo no vio.
- **El problema:** solo se observa qué hicieron los liberados. De los que el juez dejó presos nunca se sabe si se habrían fugado.

Cómo lo resolvieron

Los casos se reparten entre jueces casi al azar, y unos jueces son más estrictos que otros. Comparando a los acusados que un juez laxo liberó con los parecidos que un juez estricto retuvo, se estima qué habrían hecho los presos.

Qué encontraron

Ordenando a los acusados por el riesgo predicho, la ciudad podía reducir el crimen cerca de un cuarto con el mismo número de presos,

o reducir los presos cerca de 40 % con el mismo crimen.

Los jueces liberaban a muchos acusados del tramo más riesgoso. La misma lista ordenada sirve para los dos objetivos, y cuál se elige no lo dice el modelo: lo dice quien decide, según cuánto vale evitar un delito y cuánto cuesta un preso.

Kleinberg et al. (2018), *Quarterly Journal of Economics* — https://doi.org/10.1093/qje/qjx032

Por qué importa para quien decide

Tres lecciones

1. **La moneda.** Una predicción vale lo que cambia en la decisión: delitos evitados y presos, no aciertos. Para Meridiano: incumplimientos evitados y evaluaciones pagadas.
2. **La regla vigente.** El modelo compite con los jueces, no con el azar. Para Meridiano: comprar sin filtro, o la cuenta de "8 $\times$ arriendo".
3. **Solo se observa lo que se decidió.** Los presos no tienen desenlace; los locales descartados tampoco. El lote de validación es lo más cercano a un experimento que Meridiano tiene.

La gerencia de inversión de Meridiano tiene dos listas de locales "riesgosos": una corta y una larga. La moneda para compararlas es la de su decisión: evaluaciones pagadas e incumplimientos evitados. Esa es la aplicación de hoy.

1 La historia: los jueces de Nueva York

2 La aplicación: las consultoras A y B

3 El task y el cierre

Las consultoras y el lote

- El estudio de locales: **480 locales** en seis ciudades, sin Barranquilla. La gerencia de inversión apartó **120 al azar** antes de entregarlo: el lote de validación. De esos 120, **24 arrendatarios cerraron**.
- Cada consultora (dos firmas de analítica, A y B) entrenó con los otros 360 y entregó, para los 120, una probabilidad de cierre, una etiqueta y una predicción de ventas.
- **A** marca cierre si la probabilidad supera 0.5: una lista corta. **B**, si supera 0.3: una lista larga.

La pregunta de hoy

¿Cuál de las dos, si alguna, le hace ganar dinero a Meridiano frente a decidir como hasta ahora?

Hoy no se entrena ningún modelo: se evalúan predicciones que ya existen.

Los primeros ocho locales, a mano

La probabilidad se vuelve etiqueta con el umbral de cada consultora, y cada etiqueta cae en una casilla. Los primeros ocho locales del lote; los ocho arrendatarios siguieron abiertos:

Local	A los 3 años	Prob. A	A dijo	Casilla A	Prob. B	B dijo	Casilla B
21	abierto	0.264	viable	TN	0.476	riesgoso	FP
22	abierto	0.000	viable	TN	0.028	viable	TN
26	abierto	0.117	viable	TN	0.062	viable	TN
35	abierto	0.332	viable	TN	0.310	riesgoso	FP
36	abierto	0.000	viable	TN	0.044	viable	TN
41	abierto	0.445	viable	TN	0.506	riesgoso	FP
43	abierto	0.213	viable	TN	0.096	viable	TN
45	abierto	0.476	viable	TN	0.424	riesgoso	FP

A no marcó ninguno: ocho viables confirmados, cero evaluaciones. B marcó cuatro: cuatro falsas alarmas, cuatro evaluaciones pagadas sobre locales que sí daban. Hasta aquí, la lista larga solo pierde. Faltan los locales que cerraron.

Los doce locales, completos

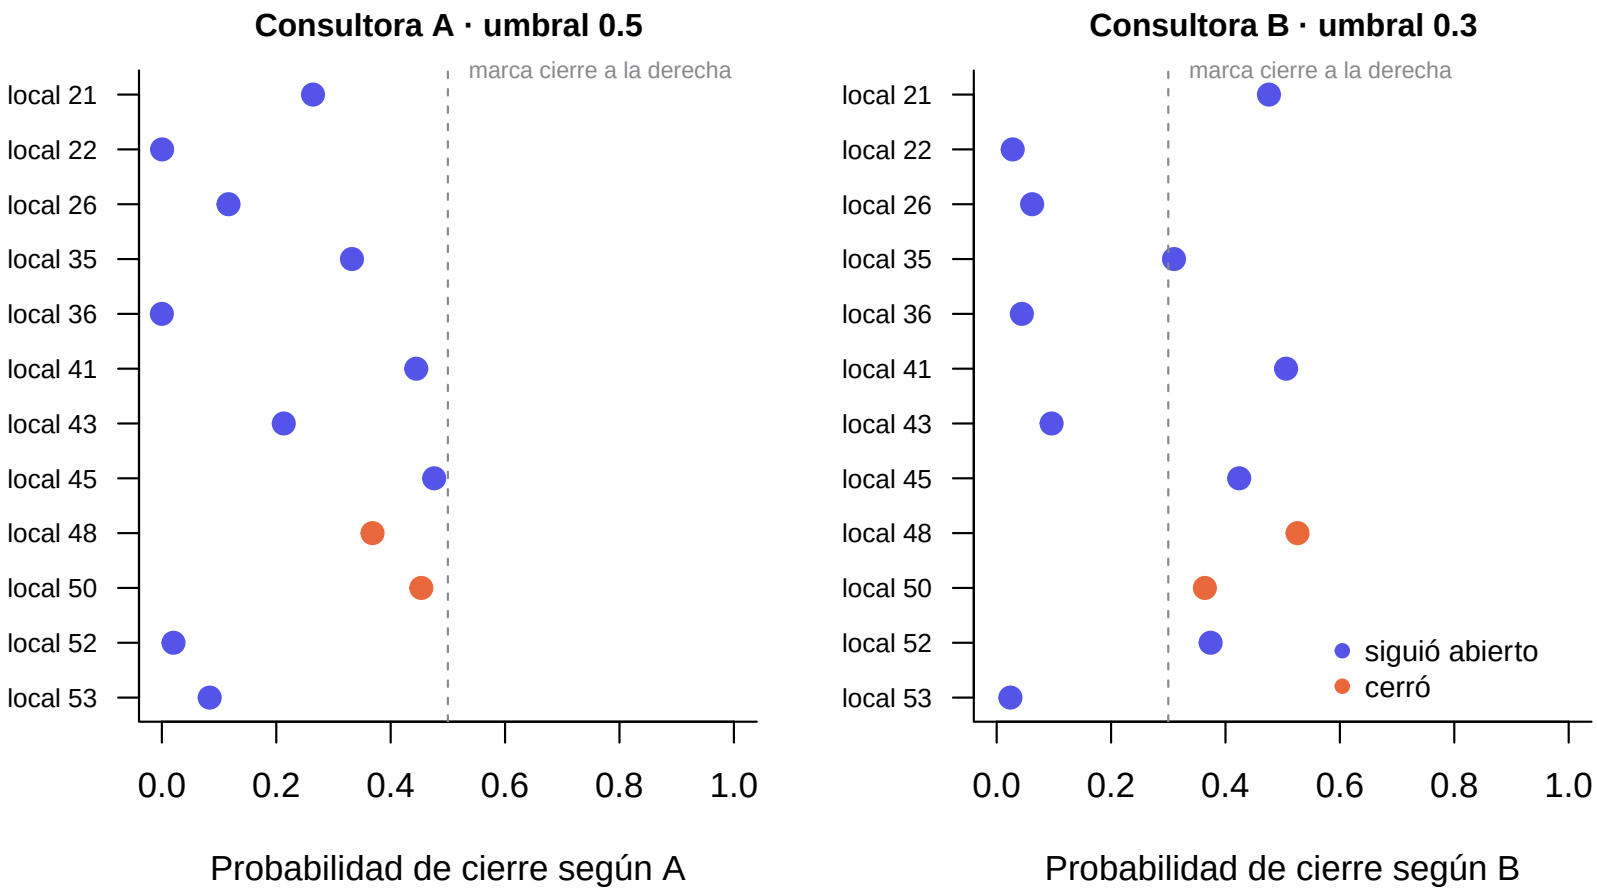
Local	A los 3 años	Prob. A	A dijo	Casilla A	Prob. B	B dijo	Casilla B
21	abierto	0.264	viable	TN	0.476	riesgoso	FP
22	abierto	0.000	viable	TN	0.028	viable	TN
26	abierto	0.117	viable	TN	0.062	viable	TN
35	abierto	0.332	viable	TN	0.310	riesgoso	FP
36	abierto	0.000	viable	TN	0.044	viable	TN
41	abierto	0.445	viable	TN	0.506	riesgoso	FP
43	abierto	0.213	viable	TN	0.096	viable	TN
45	abierto	0.476	viable	TN	0.424	riesgoso	FP
48	**cerró**	0.368	viable	**FN**	0.526	riesgoso	**TP**
50	**cerró**	0.454	viable	**FN**	0.364	riesgoso	**TP**
52	abierto	0.020	viable	TN	0.374	riesgoso	TN
53	abierto	0.084	viable	TN	0.024	viable	TN

Los cierres de 48 y 50 cambian el orden: A no los vio (FN); las alarmas de B los atraparon (TP).

Parada activa: a mano

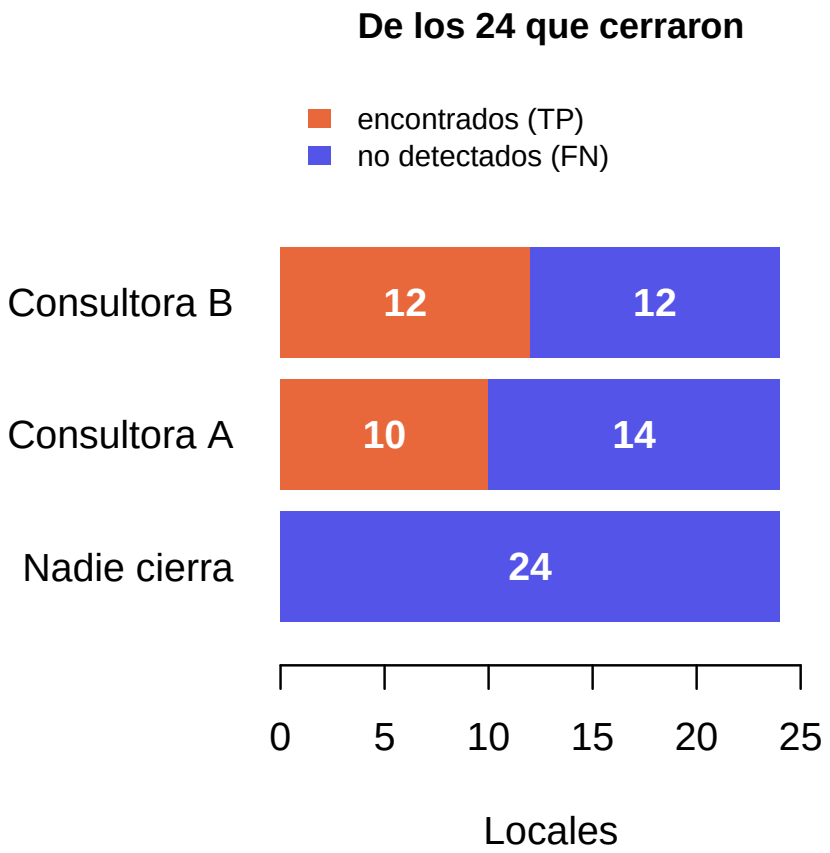
Una de las 24 casillas está mal marcada. ¿Cuál? Y en estos doce: ¿cuántos avisos dio cada consultora y cuántos cierres atrapó?

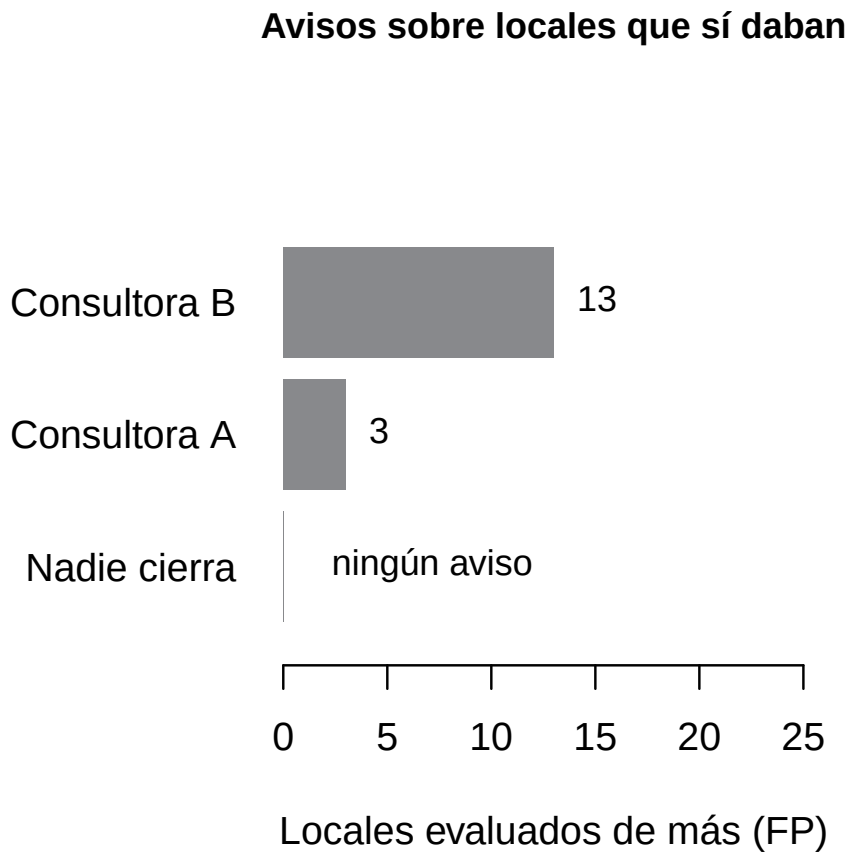
¿De dónde sale la etiqueta de cada local?



A no marcó ninguno de los doce y se le escaparon los dos que cerraron (48 y 50). B marcó siete: atrapó los dos cierres y dio cinco falsas alarmas. Los cortes de 0.5 y 0.3 los eligieron las consultoras, no Meridiano.

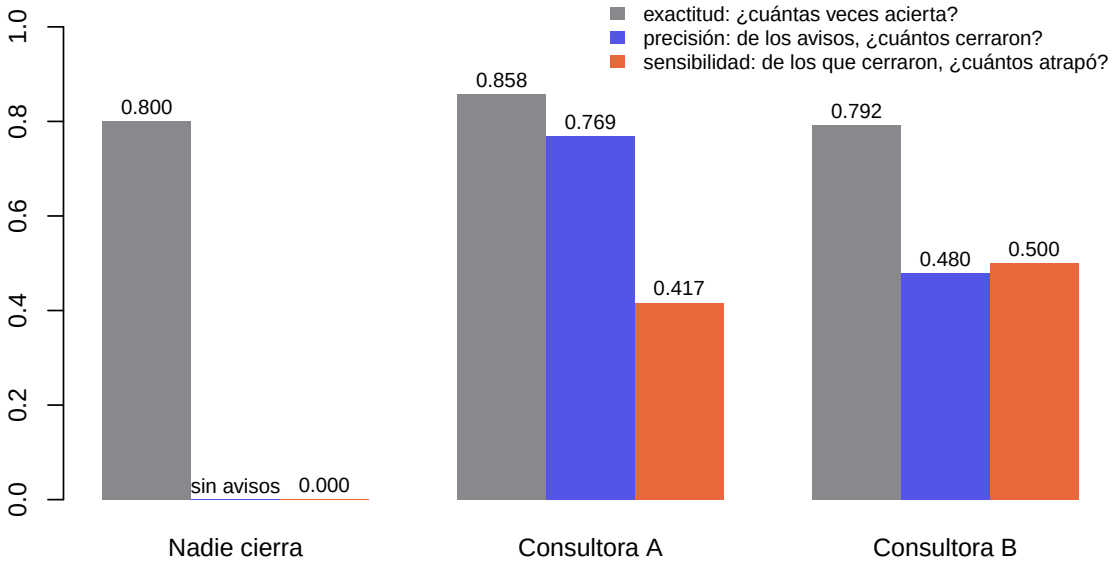
¿Qué errores comete cada una en los 120 del lote?





"Nadie cierra" no da avisos y se le escapan los 24. A da 13 avisos: 10 acertados, 3 falsas alarmas, 14 cierres no detectados. B da 25: 12 acertados, 13 falsas alarmas, 12 no detectados.

Tres métricas, tres preguntas



Lo que importa

Cada métrica premia a una consultora distinta: A gana en exactitud (0.858) y precisión (0.769); B, en sensibilidad (0.500 contra 0.417), con exactitud (0.792) por debajo del 0.800 de "nadie cierra". Qué pregunta importa lo deciden los costos de Meridiano.

La matriz leída en pesos

Parada activa: encuesta

¿Cuál error es más caro para Meridiano: una falsa alarma o un cierre no detectado?

	El modelo dijo "riesgoso"	**El modelo dijo "viable"**
El arrendatario cerró	**Aviso acertado (TP).** Se evalúa a fondo (12) y, con efectividad u, se evita un incumplimiento (250)	**Cierre no detectado (FN).** Se compra un local cuyo arrendatario cierra: 250 millones perdidos
Siguió abierto	**Falsa alarma (FP).** Se evalúa a fondo un local que sí daba: 12. Descartarlo a ciegas costaría 90 de utilidad	**Viable confirmado (TN).** Sin costo

Un cierre no detectado cuesta unas veinte veces lo que una falsa alarma. Por eso Meridiano evalúa en lugar de descartar: los 12 millones son el seguro contra los 90.

¿Cómo se calcula el costo de cada lista?

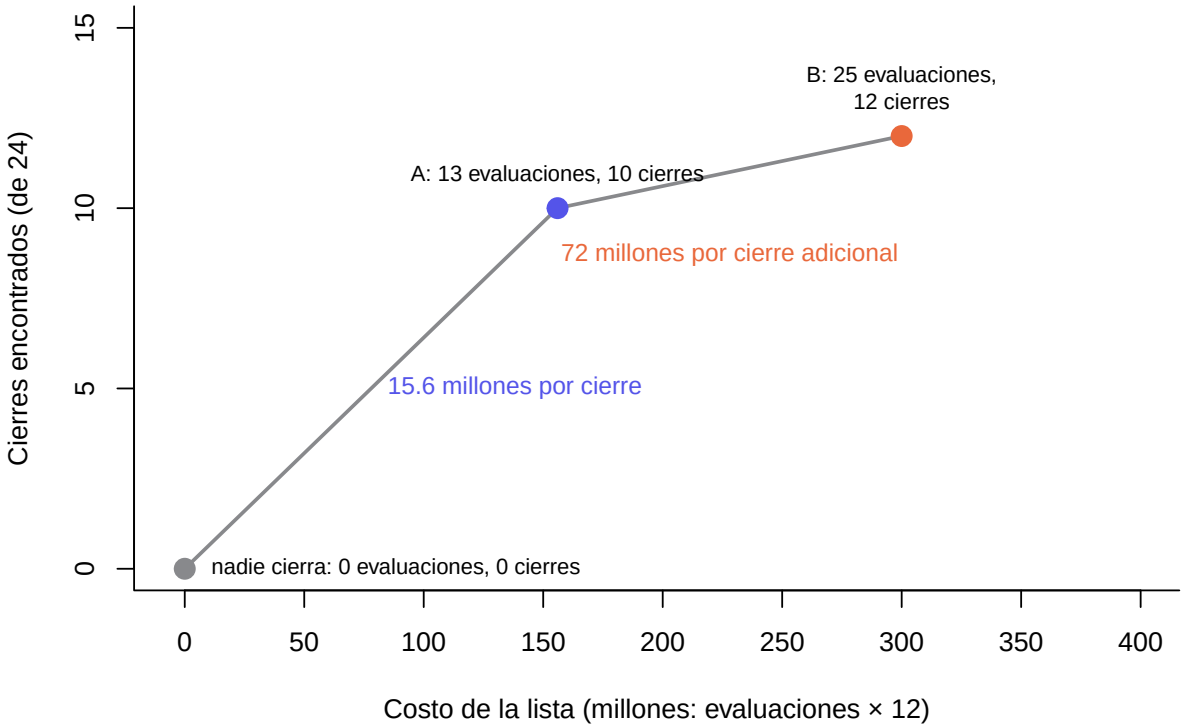
Con las casillas del lote y 12 millones por evaluación, en cuatro pasos:

Paso	**Nadie cierra**	**Consultora A**	**Consultora B**
1. Evaluaciones (TP + FP)	$0 + 0 = \mathbf{0}$	$10 + 3 = \mathbf{13}$	$12 + 13 = \mathbf{25}$
2. Costo de la lista (evaluaciones $\times$ 12)	**0**	$13 \times 12 = \mathbf{156}$	$25 \times 12 = \mathbf{300}$
3. Cierres encontrados (TP)	**0**	**10**	**12**
4. Por cierre encontrado (costo $\div$ encontrados)	no aplica	$156 \div 10 = \mathbf{15.6}$	$300 \div 12 = \mathbf{25.0}$

Lo que importa

Cada aviso cuesta lo mismo, acierte o no: cada cierre encontrado cuesta $12 \div$ precisión. A: $12 \div 0.769 = 15.6$; B: $12 \div 0.480 = 25.0$.

¿Cuánto cuesta encontrar un cierre más?



Lo que importa

De no hacer nada a A: 15.6 millones por cierre. De A a B: 144 millones por 2 cierres más: **72 por cierre adicional**. Ampliar la lista conviene mientras cada cierre adicional valga más de lo que cuesta encontrarlo.

El beneficio neto frente a no hacer nada

Encontrar un cierre no es evitarlo: el aviso dispara una evaluación, y la evaluación evita el incumplimiento solo una fracción u de las veces. Beneficio neto = cierres encontrados $\times\, u \times 250-$ evaluaciones $\times\, 12$; nadie $= 0$.

Efectividad del aviso	**Cada cierre vale**	**Consultora A**	**Consultora B**	**Gana**
$u = 0.5$: evita 1 de cada 2	125	$10 \times 125 - 156 =$ **1094**	$12 \times 125 - 300 =$ **1200**	B
$u = 0.25$: evita 1 de cada 4	62.5	$10 \times 62.5 - 156 =$ **469**	$12 \times 62.5 - 300 =$ **450**	A

El beneficio neto frente a no hacer nada

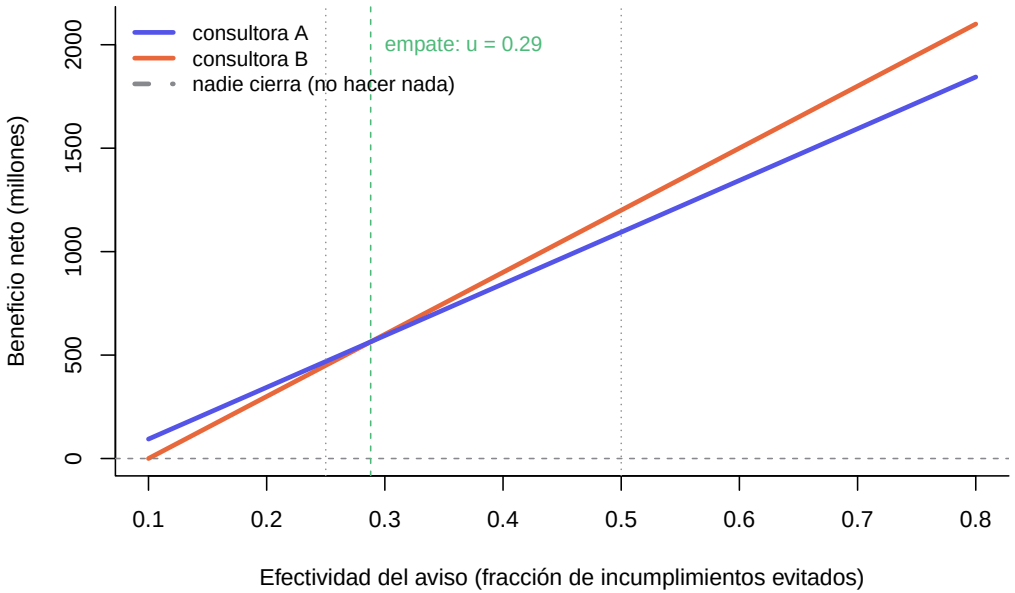
Encontrar un cierre no es evitarlo: el aviso dispara una evaluación, y la evaluación evita el incumplimiento solo una fracción u de las veces. Beneficio neto = cierres encontrados $\times\, u \times 250-$ evaluaciones $\times\, 12$; nadie $= 0$.

Efectividad del aviso	**Cada cierre vale**	**Consultora A**	**Consultora B**	**Gana**
$u = 0.5$: evita 1 de cada 2	125	$10 \times 125 - 156 =$ **1094**	$12 \times 125 - 300 =$ **1200**	B
$u = 0.25$: evita 1 de cada 4	62.5	$10 \times 62.5 - 156 =$ **469**	$12 \times 62.5 - 300 =$ **450**	A

Lo que importa

Los modelos no cambiaron; cambió cuánto vale cada acierto. Con el supuesto base pagan los dos tramos (hasta los 72 por cierre adicional); con el pesimista, solo el primero. Las dos le ganan a no hacer nada, con holgura.

¿Dónde se cruzan A y B?

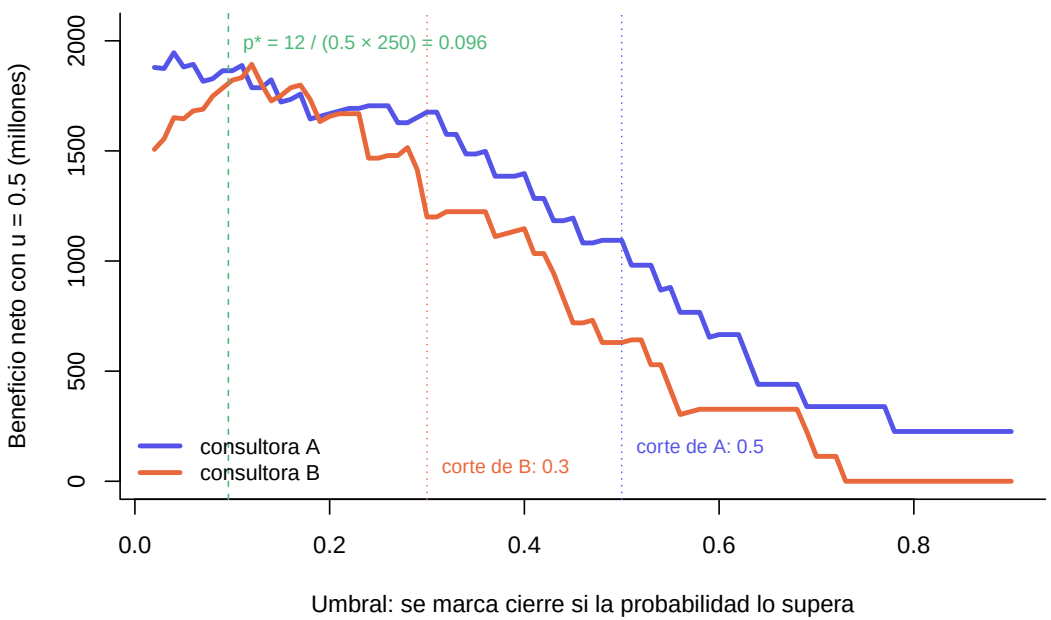


- A y B empatan en $u = 12 \times 12 \div (250 \times 2) =$ **0.288**. Por debajo gana A; por encima, B.
- En la otra moneda: con $u = 0.5$ empatan cuando la pérdida evitada vale **144**; con V por debajo gana A, por encima B.
- Para que valga la pena contratar: V por encima de 31.2 (A) o de 50.0 (B). Meridiano está lejos de ese piso.

Lo que importa

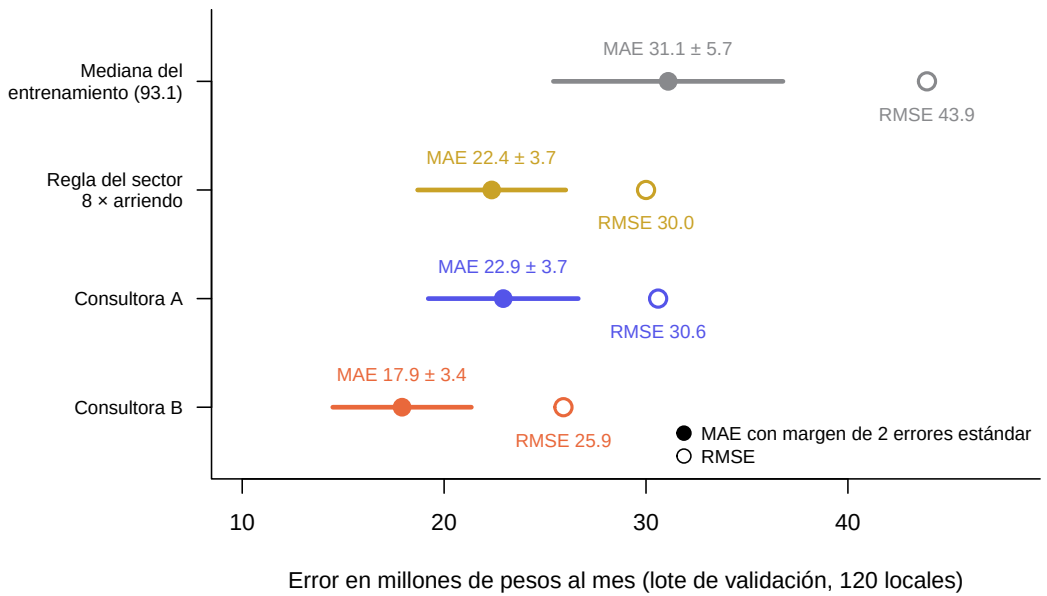
La elección entre A y B no la decide la exactitud: la decide un supuesto que nadie ha medido, cuántos incumplimientos evita de verdad una evaluación a fondo. Esa es la cifra que el task pide reportar.

El umbral también es una decisión



- Vale la pena evaluar cuando $p \times u \times V \geq c$:
  $p^* = c \div (u \times V) =$
  $12 \div (0.5 \times 250) =$ **0.096**; con $u = 0.25$, **0.192**.
- Los cortes de 0.5 y 0.3 los eligieron las consultoras. Con p^* las dos darían muchos más avisos y atraparían casi todos los cierres.
- **Con cupo**, el umbral no manda: si solo se pueden evaluar tres locales, se ordena por riesgo y se toman los tres primeros. Lo que importa es que el modelo ordene bien.

Las ventas: el error en pesos

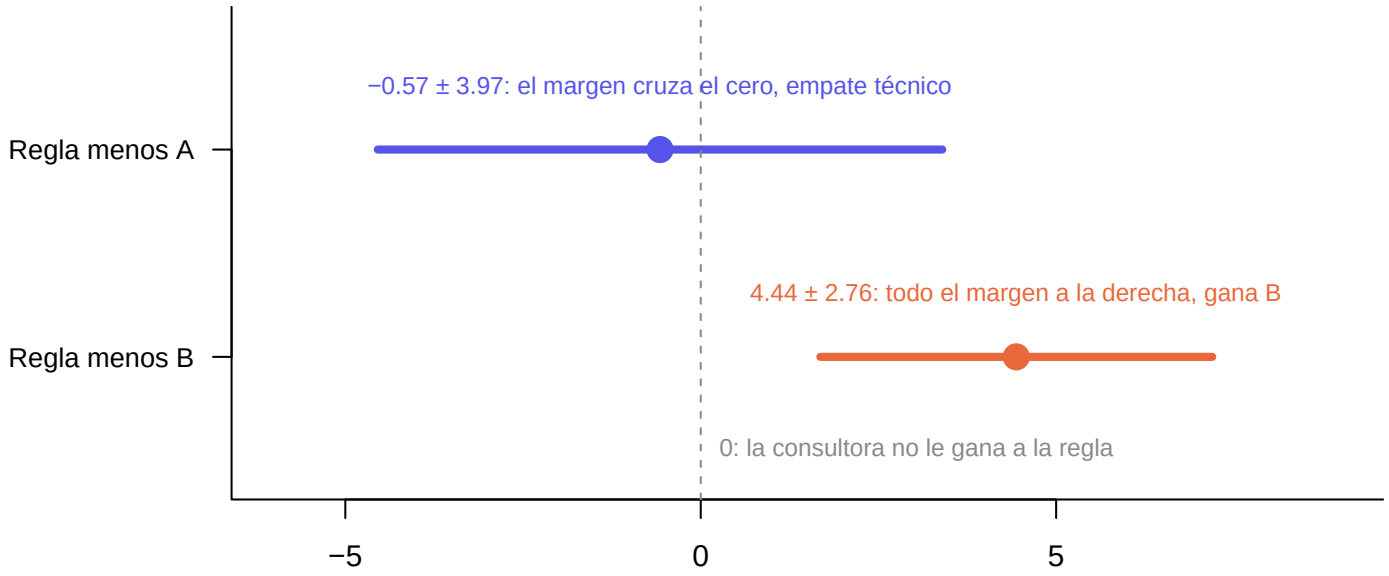


- **MAE:** el error promedio, en millones al mes. **RMSE:** castiga los errores grandes; la brecha delata fallas ocasionales.
- Regla 8 × arriendo: 22.4. A: 22.9. B: 17.9. Mediana (93.1): 31.1.
- Cada millón mensual de ventas mueve el VPN a cinco años en 3 millones (canon del 10 %): el MAE de B son **54 millones** de VPN por local.

Lo que importa

Con 120 locales, cada MAE trae un margen de dos errores estándar. Una diferencia menor que el margen no es una diferencia.

¿Le gana a la regla por más que el ruido?



Error de la regla menos error de la consultora, local por local (promedio y margen)

- **Pareada:** local por local, error de la regla menos error de la consultora; se promedia y se mira el margen. El ruido común se cancela.
- **Regla menos A:** -0.57 ± 3.97**.** El margen cruza el cero: **empate técnico**. Meridiano ya tenía esa información gratis.
- **Regla menos B:** 4.44 ± 2.76**.** Todo el margen a la derecha: B le gana a la regla por unos 4.4 millones al mes por local.

El giro: una nueva hoja de costos

Parada activa: el giro

Llega una cotización nueva: evaluar un local a fondo cuesta **el triple**, 36 millones en lugar de 12. La pérdida evitada sigue en 250. ¿Se sostiene la elección de B con $u = 0.5$? ¿Y la de A con $u = 0.25$? Dos minutos con la caja de costos o con las celdas de la práctica.

El giro: una nueva hoja de costos

Parada activa: el giro

Llega una cotización nueva: evaluar un local a fondo cuesta **el triple**, 36 millones en lugar de 12. La pérdida evitada sigue en 250. ¿Se sostiene la elección de B con $u = 0.5$? ¿Y la de A con $u = 0.25$? Dos minutos con la caja de costos o con las celdas de la práctica.

- Con $u = 0.5$: $\text{A} = 10 \times 125 - 13 \times 36 = 782$; $\text{B} = 12 \times 125 - 25 \times 36 = 600$. **Gana A:** el segundo tramo ya no paga.
- Con $u = 0.25$: $\text{A} = 157$; $\text{B} = -150$. **B pierde dinero frente a no hacer nada.**
- La efectividad de quiebre sube de 0.288 a **0.864**: B solo gana si la evaluación evita casi nueve de cada diez incumplimientos.

Lo que importa

Las predicciones no cambiaron. Cambió lo que cuesta actuar sobre ellas, y con eso cambió la consultora elegida: la evaluación depende de la hoja de costos tanto como del modelo.

Lo que importa

Lo que importa

1. **Solo cuenta lo que el modelo no vio, y contra un baseline.** El lote de validación y la regla vigente. "Nadie cierra" saca 80 % sin información; "8 $\times$ arriendo" empata con una consultora.
2. **La matriz se lee en pesos.** Una falsa alarma cuesta una evaluación; un cierre no detectado, un incumplimiento. Cada acierto vale lo que evita: encontrados $\times\, u \times V$, menos evaluaciones $\times\, c$.
3. **Una diferencia menor que el margen no es una diferencia,** y no adoptar ninguno es una respuesta: va con el costo o la efectividad que la voltearía.

1 La historia: los jueces de Nueva York

2 La aplicación: las consultoras A y B

3 El task y el cierre

Task 4: El ranking de modelos

Qué se entrega (una página, en equipo, antes de la sesión 5):

- el ranking de modelos, cierre y ventas, con el margen, el costo marginal de A a B y la efectividad de quiebre (2.0, contra el sobre);
- la recomendación por target: A, B o ninguna, justificada al elegir **y al descartar**, en las palabras del negocio (1.5);
- la sensibilidad: qué efectividad y qué pérdida evitada voltean la decisión, y de qué lado está el supuesto defendible (1.0);
- el acta y la declaración (0.5).

En el cierre de la sesión 5

Dos equipos al azar dicen a quién eligieron y por qué descartaron a las otras. El giro como pregunta: si evaluar costara el triple, ¿se sostiene? Y qué hace Meridiano con un empate técnico.

En el memo no hay TP ni FP: hay incumplimientos evitados y locales buenos descartados.

Cierre: la cacería del task 3

1. **Las cifras contra el sobre** (6 minutos). Dos equipos al azar, dos minutos cada uno, expositor al azar: un hallazgo con su cifra. Se abre el sobre de la semana 3 y se compara. Si no coincide, ¿de dónde venía la diferencia?
2. **¿Quién atrapó la fuga?** (6 minutos). La columna prohibida: cuántos equipos la excluyeron antes de modelar y con qué regla (el momento de la decisión). Qué habría pasado con un modelo que la usara.
3. **¿Qué hizo el agente de más?** (5 minutos). Un hallazgo que el agente propuso y el equipo descartó; una cifra que el agente dio y el equipo no pudo reproducir.
4. **Dudas** (3 minutos): el task 4, la caja de costos y las celdas del ranking de modelos.

Referencias

- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J. y Mullainathan, S. (2018). Human decisions and machine predictions. *Quarterly Journal of Economics*, 133(1), 237–293. https://doi.org/10.1093/qje/qjx032
- Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review: Papers & Proceedings*, 105(5), 491–495. https://doi.org/10.1257/aer.p20151023
- Sosa Escudero, W. (2019). *Big data*. Siglo XXI. El capítulo sobre los límites del análisis de datos.
- Meridiano S.A.S., gerencia de inversión (2026). *Estudio de locales: 480 locales comerciales arrendados a minoristas*. `predicciones_consultoras.csv`, `costos_decision.csv` y el sobre de la semana 4.