Analítica Predictiva y Prescriptiva

Semana 4: Evaluación de modelos

Eduard F. Martínez González, Ph.D.

Universidad Icesi · TIC-60286

13 de octubre de 2026

Dónde vamos

La semana pasada: el task 3, tres hallazgos con cifra sobre el estudio de locales, la columna prohibida y el acta del agente. Se discute hoy, en el cierre, contra el sobre.

Hoy, la pieza 4 del expediente: la evaluación de los modelos. Dos firmas de analítica, las consultoras A y B, ofrecen predicciones de cierre del arrendatario y de ventas. El ranking de modelos (cierre y ventas), una recomendación (A, B o ninguna) y el supuesto que la voltea.

La sesión

1. El paper: jueces, libertad provisional y una predicción medida en crímenes y presos.
2. Las consultoras A y B, local por local.
3. La evaluación en pesos: el costo de cada lista, el beneficio neto, la efectividad de quiebre.
4. Las ventas: MAE y RMSE contra la regla del sector.
5. El giro, y el task 4.
6. Cierre: la cacería del task 3.

Antes de empezar

Parada activa: encuesta

Dos consultoras ofrecen un modelo que predice si el arrendatario de un local cerraría antes de tres años. En el lote de validación, A tiene **85.8 %** de exactitud y B **79.2 %**. ¿Cuál compras: A, B o ninguna?

Antes de empezar

Parada activa: encuesta

Dos consultoras ofrecen un modelo que predice si el arrendatario de un local cerraría antes de tres años. En el lote de validación, A tiene **85.8 %** de exactitud y B **79.2 %**. ¿Cuál compras: A, B o ninguna?

Un dato antes de votar de nuevo: en ese lote cerró uno de cada cinco arrendatarios. "Ningún arrendatario cierra" acierta el **80.0 %** sin mirar un solo dato.

1. El paper: jueces, libertad provisional y una predicción
2. La aplicación: las consultoras A y B
3. El task y el cierre

¿Puede un algoritmo mejorar las decisiones de un juez?

Kleinberg, Lakkaraju, Leskovec, Ludwig y Mullainathan (2018), *Quarterly Journal of Economics*

Qué investigaron. Si un algoritmo que predice el riesgo de un acusado puede mejorar las decisiones de libertad provisional de los jueces: a quién dejar en libertad mientras llega el juicio y a quién mantener preso.

Por qué es una predicción. La ley le pide al juez una sola cosa: estimar si el acusado se fugará o cometerá un delito si lo libera. No hay que decidir qué es justo; hay que predecir bien. Es una decisión con una predicción en el centro.

La trampa

Un juez que acierta "mucho" no es necesariamente un buen juez: la mayoría de los acusados no se fuga, así que liberar a todos ya acierta en la mayoría de los casos. Suena conocido.

Qué datos y cómo

- **Cientos de miles de audiencias** en la ciudad de Nueva York, 2008–2013, con lo que el juez ve en el momento: el cargo actual, los antecedentes, la edad.
- Un modelo de **árboles** (*gradient boosting*) que predice la fuga y la reincidencia, entrenado en una parte de los casos y evaluado en otra que el modelo no vio.
- **El problema:** solo se observa qué hicieron los liberados. De los que el juez dejó presos nunca se sabe si se habrían fugado.

Cómo lo resolvieron

Los casos se reparten entre jueces casi al azar, y unos jueces son más estrictos que otros. Comparando a los acusados que un juez laxo liberó con los parecidos que un juez estricto retuvo, se estima qué habrían hecho los presos.

Qué encontraron

- Los jueces **liberan a muchos acusados de alto riesgo**: entre los que el modelo pone en el tramo más riesgoso, una parte grande sale en libertad, y muchos de ellos se fugan o reinciden.
- Si se ordenara a los acusados por el riesgo predicho y se usara esa lista, se podría **reducir el crimen cerca de un cuarto** manteniendo el mismo número de presos, o **reducir los presos cerca de 40 %** manteniendo el mismo crimen.
- La misma lista ordenada sirve para los dos objetivos. **Cuál se elige no lo dice el modelo:** lo dice quien decide, según cuánto vale evitar un delito y cuánto cuesta un preso.

Lo que importa

El modelo no se evaluó en "porcentaje de aciertos". Se evaluó en la moneda de la decisión, crímenes y presos, y contra la regla vigente: los jueces.

Por qué importa para quien decide

Tres lecciones

1. **La moneda.** Una predicción vale lo que cambia en la decisión: delitos evitados y presos, no aciertos. Para Meridiano: incumplimientos evitados y evaluaciones pagadas.
2. **La regla vigente.** El modelo compite con los jueces, no con el azar. Para Meridiano: comprar sin filtro, o la cuenta de "8 $\times$ arriendo".
3. **Solo se observa lo que se decidió.** Los presos no tienen desenlace; los locales descartados tampoco. El lote de validación es lo más cercano a un experimento que Meridiano tiene.

Parada activa: el puente

La gerencia de inversión de Meridiano tiene dos listas de locales "riesgosos": una corta (A) y una larga (B). ¿En qué moneda las compara?

1 El paper: jueces, libertad provisional y una predicción

2 La aplicación: las consultoras A y B

3 El task y el cierre

Las consultoras y el lote

- El estudio de locales: **480 locales** en seis ciudades, sin Barranquilla. La gerencia de inversión apartó **120 al azar** antes de entregarlo: el lote de validación. De esos 120, **24 arrendatarios cerraron**.
- Cada consultora (dos firmas de analítica, A y B) entrenó con los otros 360 y entregó, para los 120, una probabilidad de cierre, una etiqueta y una predicción de ventas.
- **A** marca cierre si la probabilidad supera 0.5: una lista corta. **B**, si supera 0.3: una lista larga.

La pregunta de hoy

¿Cuál de las dos, si alguna, le hace ganar dinero a Meridiano frente a decidir como hasta ahora?

Hoy no se entrena ningún modelo: se evalúan predicciones que ya existen.

Los doce primeros locales, uno por uno

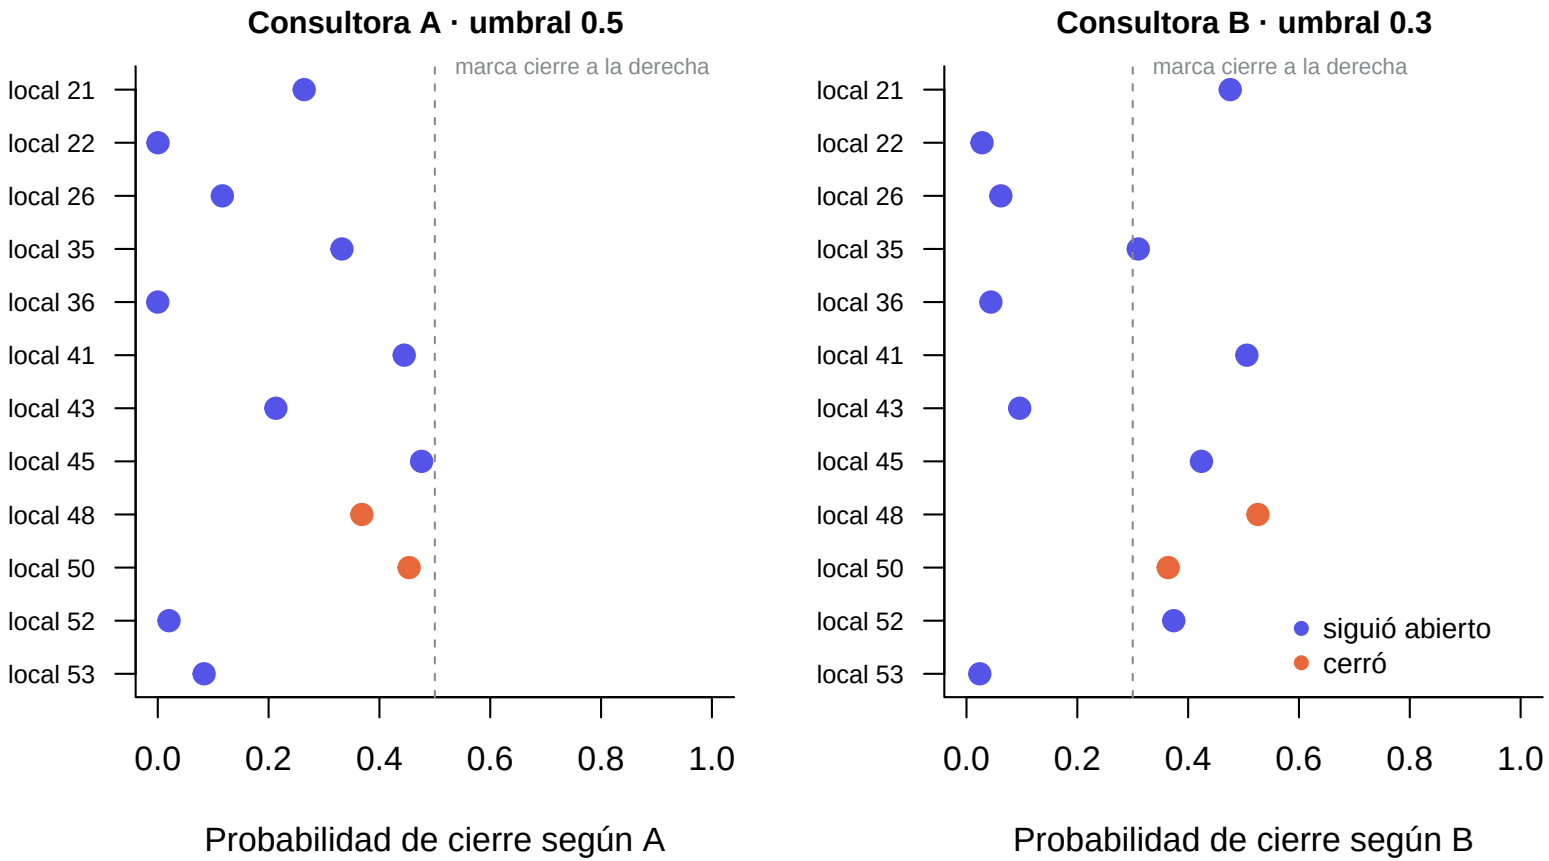
Local	A los 3 años	Prob. A	A dijo	Casilla A	Prob. B	B dijo	Casilla B
21	abierto	0.264	viable	TN	0.476	riesgoso	FP
22	abierto	0.000	viable	TN	0.028	viable	TN
26	abierto	0.117	viable	TN	0.062	viable	TN
35	abierto	0.332	viable	TN	0.310	riesgoso	FP
36	abierto	0.000	viable	TN	0.044	viable	TN
41	abierto	0.445	viable	TN	0.506	riesgoso	TN
43	abierto	0.213	viable	TN	0.096	viable	TN
45	abierto	0.476	viable	TN	0.424	riesgoso	FP
48	**cerró**	0.368	viable	**FN**	0.526	riesgoso	**TP**
50	**cerró**	0.454	viable	**FN**	0.364	riesgoso	**TP**
52	abierto	0.020	viable	TN	0.374	riesgoso	FP
53	abierto	0.084	viable	TN	0.024	viable	TN

Clase positiva: “riesgoso”. Primera letra: ¿acertó? Segunda: ¿qué predijo? TP: aviso acertado. FP: falsa alarma. FN: cierre no detectado. TN: viable confirmado.

Parada activa: a mano

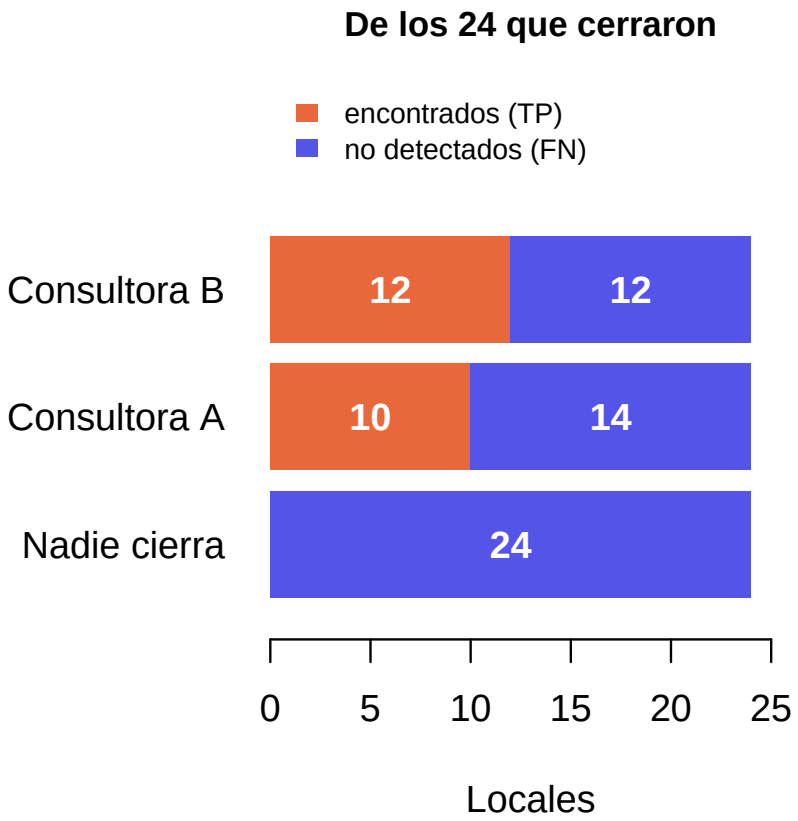
Una de las 24 casillas está mal marcada. ¿Cuál? Y en estos doce: ¿cuántos avisos dio cada consultora y cuántos cierres atrapó?

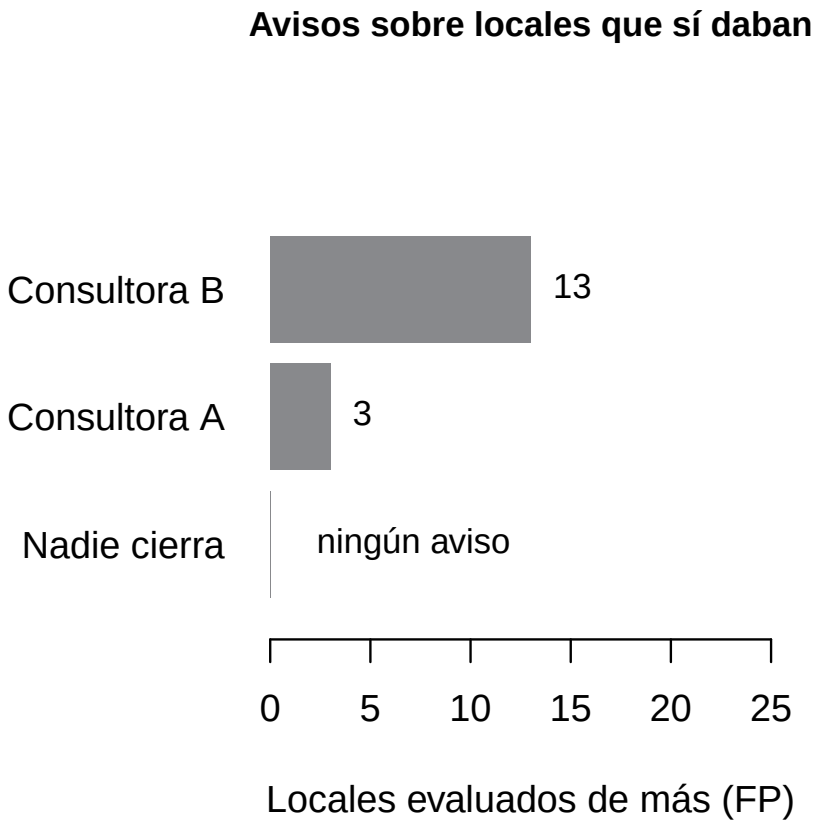
Los mismos doce locales, dos cortes



A no marcó ninguno de los doce y se le escaparon los dos que cerraron (48 y 50). B marcó siete: atrapó los dos cierres y dio cinco falsas alarmas. Los cortes de 0.5 y 0.3 los eligieron las consultoras, no Meridiano.

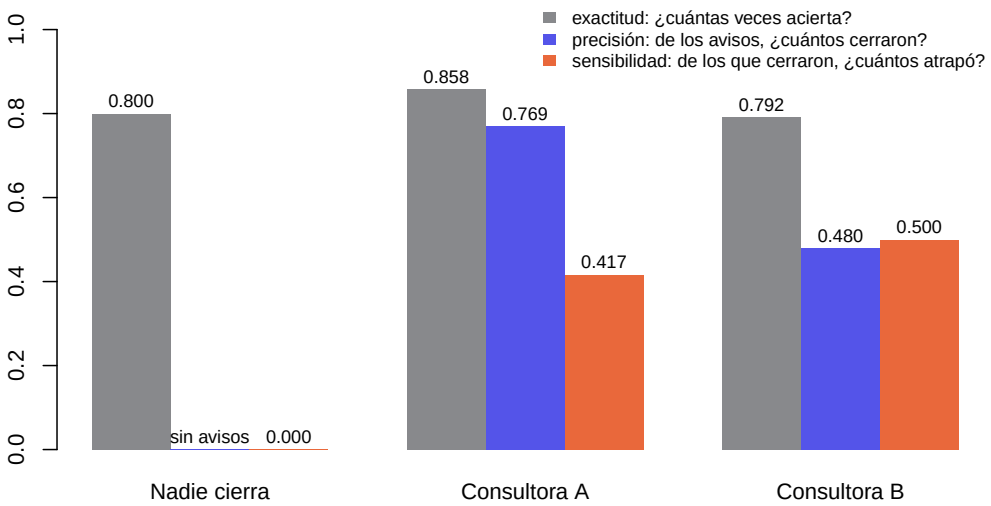
¿Qué errores comete cada una? Los 120 del lote





"Nadie cierra" no da avisos y se le escapan los 24. A da 13 avisos: 10 acertados, 3 falsas alarmas, 14 cierres no detectados. B da 25: 12 acertados, 13 falsas alarmas, 12 no detectados.

Tres métricas, tres preguntas



- **Exactitud:** ¿cuántas veces acierta? Gana A (0.858). "Nadie cierra" saca 0.800 sin encontrar nada; B (0.792) queda por debajo.
- **Precisión:** de los avisos, ¿cuántos cerraron? Gana A: 0.769. B: 0.480.
- **Sensibilidad:** de los 24 que cerraron, ¿cuántos atrapó? Gana B: 0.500. A: 0.417. Nadie: 0.

Lo que importa

Cada métrica premia a una consultora distinta. Antes de elegir hay que decidir qué pregunta le importa a Meridiano, y eso lo deciden los costos.

La matriz leída en pesos

Parada activa: encuesta

¿Cuál error es más caro para Meridiano: una falsa alarma o un cierre no detectado?

	El modelo dijo "riesgoso"	**El modelo dijo "viable"**
El arrendatario cerró	**Aviso acertado (TP).** Se evalúa a fondo (12) y, con efectividad u, se evita un incumplimiento (250)	**Cierre no detectado (FN).** Se compra un local cuyo arrendatario cierra: 250 millones perdidos
Siguió abierto	**Falsa alarma (FP).** Se evalúa a fondo un local que sí daba: 12. Descartarlo a ciegas costaría 90 de utilidad	**Viable confirmado (TN).** Sin costo

Un cierre no detectado cuesta unas veinte veces lo que una falsa alarma. Por eso Meridiano evalúa en lugar de descartar: los 12 millones son el seguro contra los 90.

¿Cómo se calcula el costo de cada lista?

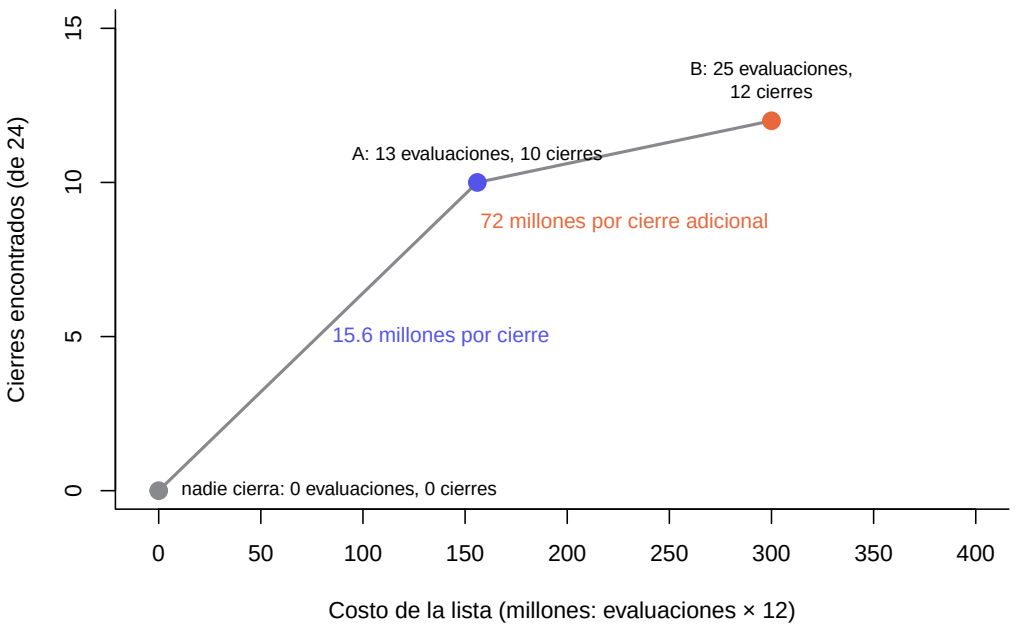
Con las casillas del lote y 12 millones por evaluación, en cuatro pasos:

Paso	**Nadie cierra**	**Consultora A**	**Consultora B**
1. Evaluaciones (TP + FP)	$0 + 0 = \mathbf{0}$	$10 + 3 = \mathbf{13}$	$12 + 13 = \mathbf{25}$
2. Costo de la lista (evaluaciones $\times$ 12)	**0**	$13 \times 12 = \mathbf{156}$	$25 \times 12 = \mathbf{300}$
3. Cierres encontrados (TP)	**0**	**10**	**12**
4. Por cierre encontrado (costo $\div$ encontrados)	no aplica	$156 \div 10 = \mathbf{15.6}$	$300 \div 12 = \mathbf{25.0}$

Lo que importa

Cada aviso cuesta lo mismo, acierte o no: cada cierre encontrado cuesta $12 \div$ precisión. A: $12 \div 0.769 = 15.6$; B: $12 \div 0.480 = 25.0$.

¿Cuánto cuesta encontrar un cierre más?



- De no hacer nada a la lista de A: **15.6 millones** por cierre encontrado (10 cierres por 156).
- De A a B: 12 evaluaciones más (144 millones) por 2 cierres más: **72 millones por cierre adicional**.

Lo que importa

Ampliar la lista conviene mientras cada cierre adicional valga más de lo que cuesta encontrarlo. ¿Y cuánto vale un cierre encontrado? Depende de cuántos incumplimientos evita de verdad.

El beneficio neto frente a no hacer nada

Encontrar un cierre no es evitarlo: el aviso dispara una evaluación, y la evaluación evita el incumplimiento solo una fracción u de las veces. Beneficio neto $=$ cierres encontrados $\times\, u \times 250-$ evaluaciones $\times 12$; nadie $= 0$.

Efectividad del aviso	**Cada cierre vale**	**Consultora A**	**Consultora B**	**Gana**
$u = 0.5$: evita 1 de cada 2	125	$10 \times 125 - 156 =$ **1094**	$12 \times 125 - 300 =$ **1200**	B
$u = 0.25$: evita 1 de cada 4	62.5	$10 \times 62.5 - 156 =$ **469**	$12 \times 62.5 - 300 =$ **450**	A

El beneficio neto frente a no hacer nada

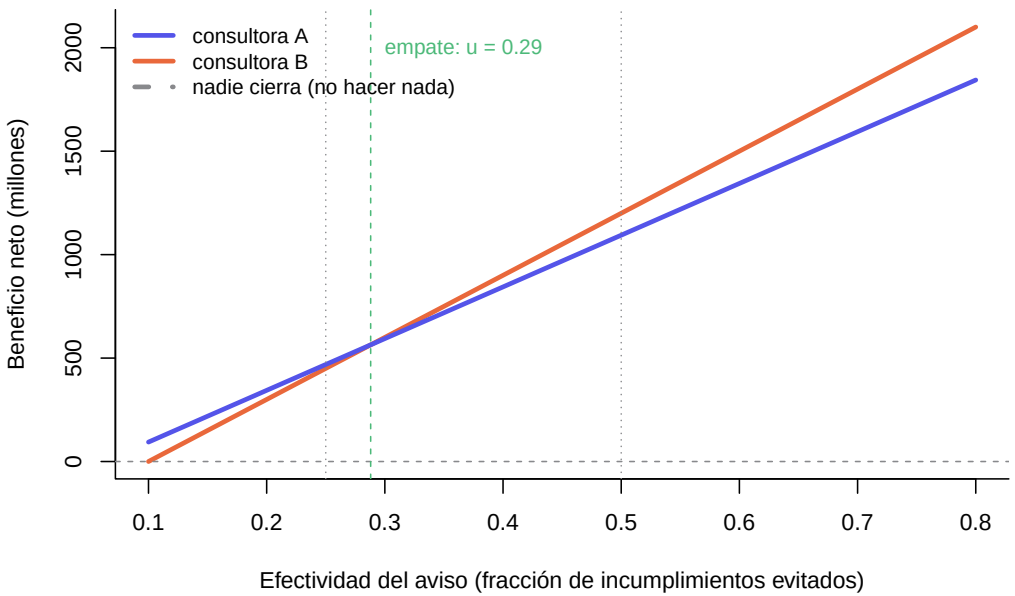
Encontrar un cierre no es evitarlo: el aviso dispara una evaluación, y la evaluación evita el incumplimiento solo una fracción u de las veces. Beneficio neto = cierres encontrados $\times\, u \times 250-$ evaluaciones $\times\, 12$; nadie $= 0$.

Efectividad del aviso	**Cada cierre vale**	**Consultora A**	**Consultora B**	**Gana**
$u = 0.5$: evita 1 de cada 2	125	$10 \times 125 - 156 =$ **1094**	$12 \times 125 - 300 =$ **1200**	B
$u = 0.25$: evita 1 de cada 4	62.5	$10 \times 62.5 - 156 =$ **469**	$12 \times 62.5 - 300 =$ **450**	A

Lo que importa

Los modelos no cambiaron; cambió cuánto vale cada acierto. Con el supuesto base pagan los dos tramos (hasta los 72 por cierre adicional); con el pesimista, solo el primero. Las dos le ganan a no hacer nada, con holgura.

La efectividad de quiebre

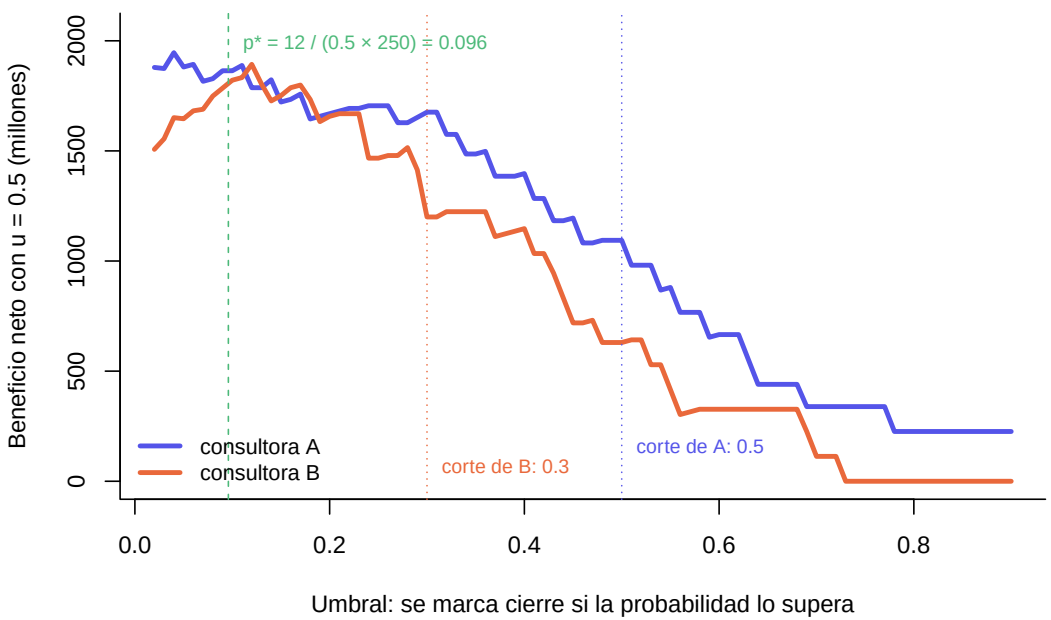


- A y B empatan en $u = 12 \times 12 \div (250 \times 2) =$ **0.288**. Por debajo gana A; por encima, B.
- En la otra moneda: con $u = 0.5$ empatan cuando la pérdida evitada vale **144**; con V por debajo gana A, por encima B.
- Para que valga la pena contratar: V por encima de 31.2 (A) o de 50.0 (B). Meridiano está lejos de ese piso.

Lo que importa

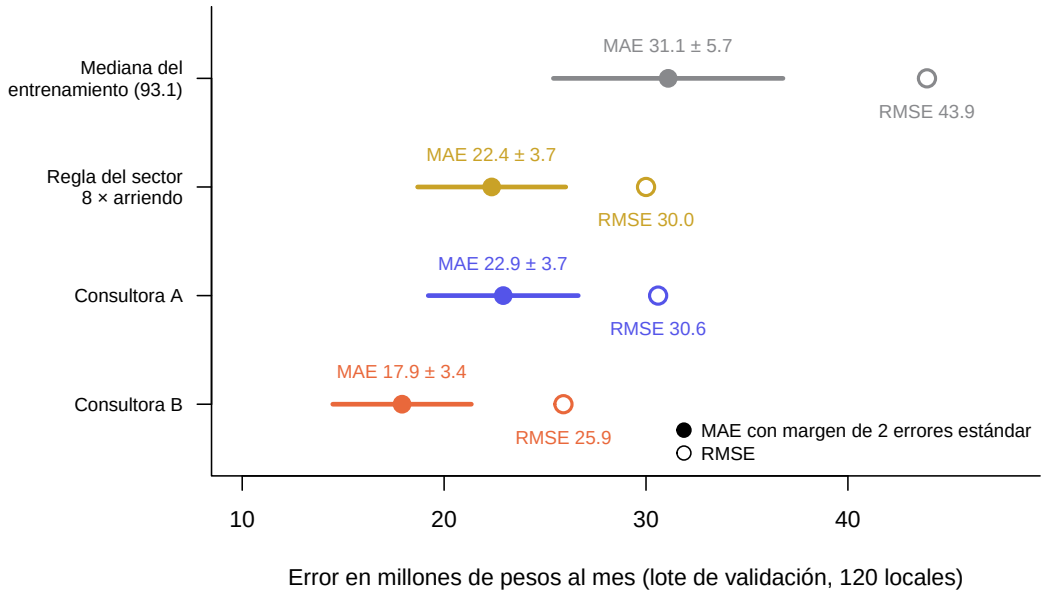
La elección entre A y B no la decide la exactitud: la decide un supuesto que nadie ha medido, cuántos incumplimientos evita de verdad una evaluación a fondo. Esa es la cifra que el task pide reportar.

El umbral también es una decisión



- Vale la pena evaluar cuando $p \times u \times V \geq c$:
  $p^* = c \div (u \times V) =$
  $12 \div (0.5 \times 250) =$ **0.096**; con $u = 0.25$, **0.192**.
- Los cortes de 0.5 y 0.3 los eligieron las consultoras. Con p^* las dos darían muchos más avisos y atraparían casi todos los cierres.
- **Con cupo**, el umbral no manda: si solo se pueden evaluar tres locales, se ordena por riesgo y se toman los tres primeros. Lo que importa es que el modelo ordene bien.

Las ventas: el error en pesos

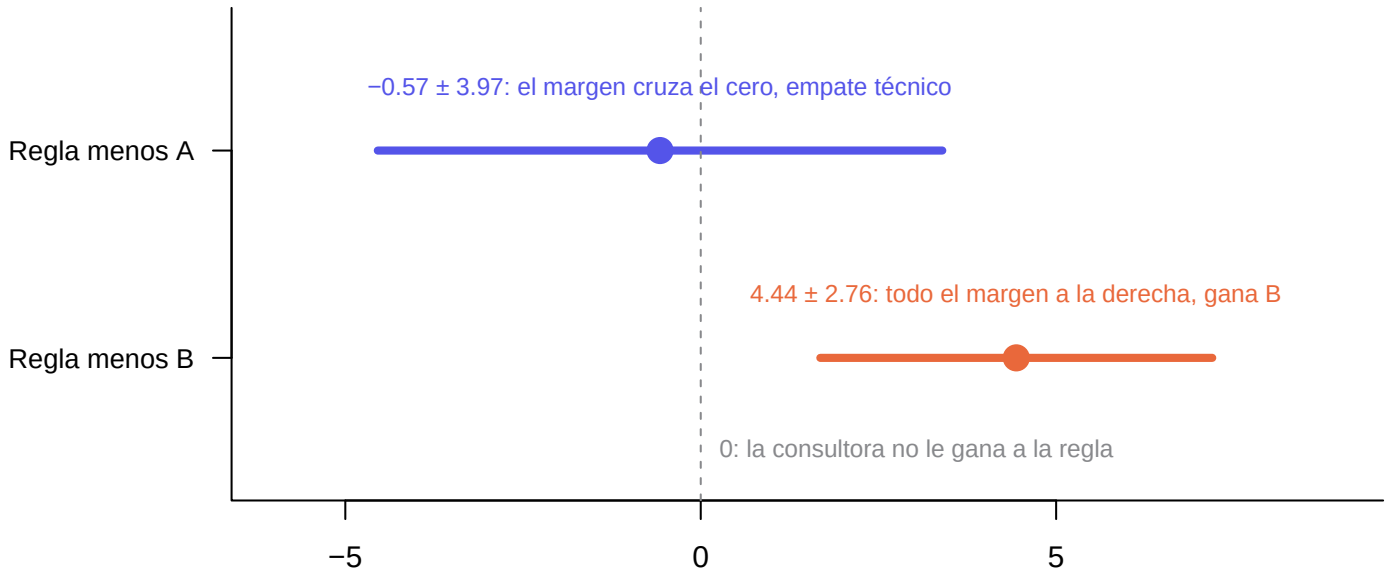


- **MAE:** el error promedio, en millones al mes. **RMSE:** castiga los errores grandes; la brecha delata fallas ocasionales.
- Regla 8 × arriendo: 22.4. A: 22.9. B: 17.9. Mediana (93.1): 31.1.
- Cada millón mensual de ventas mueve el VPN a cinco años en 3 millones (canon del 10 %): el MAE de B son **54 millones** de VPN por local.

Lo que importa

Con 120 locales, cada MAE trae un margen de dos errores estándar. Una diferencia menor que el margen no es una diferencia.

¿Le gana a la regla por más que el ruido?



Error de la regla menos error de la consultora, local por local (promedio y margen)

- **Pareada:** local por local, error de la regla menos error de la consultora; se promedia y se mira el margen. El ruido común se cancela.
- **Regla menos A:** -0.57 ± 3.97**.** El margen cruza el cero: **empate técnico**. Meridiano ya tenía esa información gratis.
- **Regla menos B:** 4.44 ± 2.76**.** Todo el margen a la derecha: B le gana a la regla por unos 4.4 millones al mes por local.

El giro: una nueva hoja de costos

Parada activa: el giro

Llega una cotización nueva: evaluar un local a fondo cuesta **el triple**, 36 millones en lugar de 12. La pérdida evitada sigue en 250. ¿Se sostiene la elección de B con $u = 0.5$? ¿Y la de A con $u = 0.25$? Dos minutos con la caja de costos o con el código de la semana.

El giro: una nueva hoja de costos

Parada activa: el giro

Llega una cotización nueva: evaluar un local a fondo cuesta **el triple**, 36 millones en lugar de 12. La pérdida evitada sigue en 250. ¿Se sostiene la elección de B con $u = 0.5$? ¿Y la de A con $u = 0.25$? Dos minutos con la caja de costos o con el código de la semana.

- Con $u = 0.5$: $\text{A} = 10 \times 125 - 13 \times 36 = 782$; $\text{B} = 12 \times 125 - 25 \times 36 = 600$. **Gana A:** el segundo tramo ya no paga.
- Con $u = 0.25$: $\text{A} = 157$; $\text{B} = -150$. **B pierde dinero frente a no hacer nada.**
- La efectividad de quiebre sube de 0.288 a **0.864**: B solo gana si la evaluación evita casi nueve de cada diez incumplimientos.

Lo que importa

Las predicciones no cambiaron. Cambió lo que cuesta actuar sobre ellas, y con eso cambió la consultora elegida: la evaluación depende de la hoja de costos tanto como del modelo.

Lo que importa

Lo que importa

1. **Solo cuenta lo que el modelo no vio, y contra un baseline.** El lote de validación y la regla vigente. "Nadie cierra" saca 80 % sin información; "8 $\times$ arriendo" empata con una consultora.
2. **La matriz se lee en pesos.** Una falsa alarma cuesta una evaluación; un cierre no detectado, un incumplimiento. Cada acierto vale lo que evita: encontrados $\times\, u \times V$, menos evaluaciones $\times\, c$.
3. **Una diferencia menor que el margen no es una diferencia,** y no adoptar ninguno es una respuesta: va con el costo o la efectividad que la voltearía.

1 El paper: jueces, libertad provisional y una predicción

2 La aplicación: las consultoras A y B

3 El task y el cierre

Task 4: El ranking de modelos

Qué se entrega (una página, en equipo, antes de la sesión 5):

- el ranking de modelos, cierre y ventas, con el margen, el costo marginal de A a B y la efectividad de quiebre (2.0, contra el sobre);
- la recomendación por target: A, B o ninguna, justificada al elegir **y al descartar**, en las palabras del negocio (1.5);
- la sensibilidad: qué efectividad y qué pérdida evitada voltean la decisión, y de qué lado está el supuesto defendible (1.0);
- el acta y la declaración (0.5).

En el cierre de la sesión 5

Dos equipos al azar dicen a quién eligieron y por qué descartaron a las otras. El giro como pregunta: si evaluar costara el triple, ¿se sostiene? Y qué hace Meridiano con un empate técnico.

En el memo no hay TP ni FP: hay incumplimientos evitados y locales buenos descartados.

Cierre: la cacería del task 3

1. **Las cifras contra el sobre** (6 minutos). Dos equipos al azar, dos minutos cada uno, expositor al azar: un hallazgo con su cifra. Se abre el sobre de la semana 3 y se compara. Si no coincide, ¿de dónde venía la diferencia?
2. **¿Quién atrapó la fuga?** (6 minutos). La columna prohibida: cuántos equipos la excluyeron antes de modelar y con qué regla (el momento de la decisión). Qué habría pasado con un modelo que la usara.
3. **¿Qué hizo el agente de más?** (5 minutos). Un hallazgo que el agente propuso y el equipo descartó; una cifra que el agente dio y el equipo no pudo reproducir.
4. **Dudas** (3 minutos): el task 4, la caja de costos y las celdas del ranking de modelos.

Referencias

- Kleinberg, J., Lakkaraju, H., Leskovec, J., Ludwig, J. y Mullainathan, S. (2018). Human decisions and machine predictions. *Quarterly Journal of Economics*, 133(1), 237–293.
- Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review: Papers & Proceedings*, 105(5), 491–495.
- Sosa Escudero, W. (2019). *Big data*. Siglo XXI. El capítulo sobre los límites del análisis de datos.
- Meridiano S.A.S., gerencia de inversión (2026). *Estudio de locales: 480 locales comerciales arrendados a minoristas*. `predicciones_consultoras.csv`, `costos_decision.csv` y el sobre de la semana 4.