Analítica Predictiva y Prescriptiva

Semana 5: Árboles de clasificación

Universidad Icesi · TIC-60286

Dónde vamos

- **La semana pasada:** evaluaron modelos ajenos — dos consultoras, una matriz, una hoja de costos y un ranking de modelos. Su veredicto (el task 4) se discute hoy, en el cierre.
- **Una historia:** en 1985, el primer árbol de clasificación compitió contra el método estándar para predecir la quiebra de empresas; cuarenta años después la lección sigue vigente: para decidir, una regla que se deje leer.
- **La aplicación:** el árbol del estudio de locales, construido en vivo — la primera pregunta, el árbol completo y su examen, el memorizador y la poda, un error sembrado, el umbral con los costos y los tres candidatos de Barranquilla.
- **El cierre:** el task 5 (el árbol del equipo) y la discusión del task 4.

1. La historia: el primer árbol que predijo quiebras
2. La aplicación: el árbol del estudio de locales
3. El task y el cierre

Predecir la quiebra de una empresa

Qué investigaron. Si un árbol de clasificación (*recursive partitioning*) predice la quiebra de empresas mejor que el método estándar de la época: el análisis discriminante del Z-score de Altman.

El contexto. Un banco, un proveedor o un auditor necesitan saber qué empresas van a entrar en dificultades. La herramienta estándar era una combinación lineal de razones financieras con un punto de corte: funcionaba, pero no se leía como una regla.

Qué datos y cómo.

- Doscientas empresas, **58 quebradas**.
- **Veinte razones financieras** conocidas antes de la quiebra.
- Árboles que ensayan todos los cortes, con **costos de error asimétricos**: equivocarse con una empresa que quiebra cuesta más que con una sana.
- Comparados con el análisis discriminante en los mismos datos y en muestras reservadas.

Frydman, Altman y Kao (1985), *The Journal of Finance* — https://doi.org/10.1111/j.1540-6261.1985.tb04949.x

Qué encontraron

- El árbol **compite o gana** frente al análisis discriminante, dentro y fuera de la muestra con la que se construyó.
- Usa **pocas razones**: unas cuantas preguntas en secuencia (flujo de caja frente a deuda, utilidades retenidas frente a activos) bastan.
- Produce **reglas que un analista lee**: "si esta razón está por debajo de tal valor y aquella por debajo de tal otro, la empresa va a quiebra".
- Los **costos de cada error entran en la regla**: cambiar el costo relativo de los dos errores cambia los cortes y las hojas, no solo el punto de corte final.

Lo que importa

Leer el modelo completo no fue el precio de predecir peor. Y la economía de los errores no se agrega al final: está dentro del árbol.

Frydman, Altman y Kao (1985), *The Journal of Finance* — https://doi.org/10.1111/j.1540-6261.1985.tb04949.x

Por qué importa para quien decide

Tres lecciones

1. Un banco necesita **una regla legible**: el comité de crédito, el regulador y el cliente rechazado tienen derecho a saber por qué.
2. Necesita **un umbral que respete el costo** de prestarle a quien quiebra, que no es el mismo que el de negarle crédito a quien iba a pagar.
3. Lo que importa es el desempeño **fuera de la muestra** con la que se construyó la regla; dentro de ella, cualquier árbol acierta.

Parada activa: el puente

Meridiano tiene un estudio de 480 locales con su desenlace a tres años, doce variables de antes de comprar y tres candidatos en Barranquilla. Le pasa lo que a los bancos con las empresas: necesita una regla legible, un umbral con sus costos, y saber qué pasa fuera de la muestra.

Modelos interpretables para decisiones de alto riesgo

- Para decisiones de alto riesgo (crédito, justicia, salud), un modelo **interpretable** y no una caja negra explicada después.
- Una "explicación" de una caja negra es otro modelo que la imita; cuando no coincide con ella, nadie sabe cuál de los dos falló.
- El intercambio "más exactitud a cambio de menos legibilidad" es menos frecuente de lo que se cree: con datos estructurados, un modelo interpretable bien construido suele empatar.

Lo que importa

Cuando la junta pregunte "¿por qué este local y no aquel?", la respuesta tiene que caber en una lámina. El árbol cabe. Un bosque de quinientos árboles, no; cuando se usa un bosque, un árbol sencillo lo resume para quien decide.

Rudin (2019), *Nature Machine Intelligence* — https://doi.org/10.1038/s42256-019-0048-x

1 La historia: el primer árbol que predijo quiebras

2 La aplicación: el árbol del estudio de locales

3 El task y el cierre

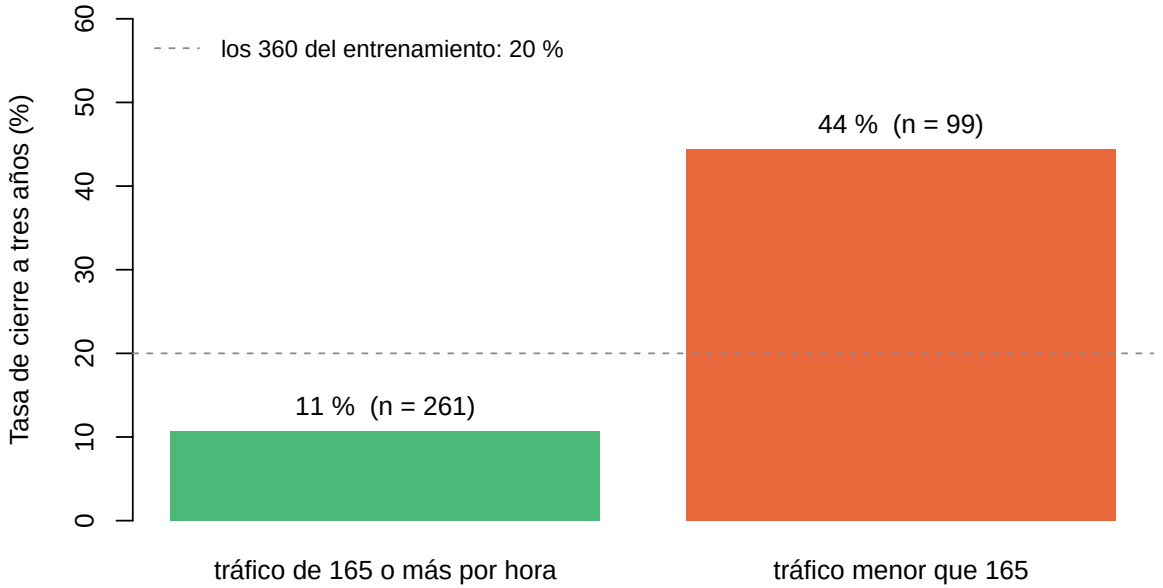
Antes de empezar

Parada activa: chat

Si tuvieran que hacer **una sola pregunta** sobre un local y su arrendatario para saber si el contrato sigue vigente a los tres años, ¿cuál sería? Una línea. Leemos cinco y luego las comparamos con la pregunta que hace el árbol.

Lo que cada uno escribió es su raíz. El árbol elige la suya midiendo qué corte separa mejor a los arrendatarios que cerraron de los que siguen abiertos, entre los 360 locales de entrenamiento.

¿Qué pregunta separa mejor a los que cerraron?

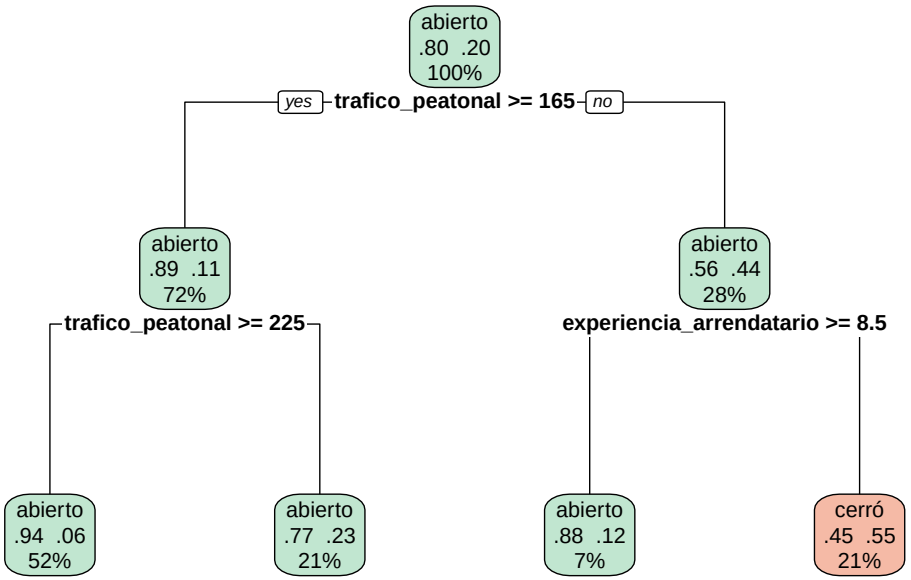


De todos los cortes posibles en las doce columnas de antes de comprar, el árbol se queda con **el tráfico peatonal en 164.5**: debajo cierra el 44 % (n = 99); encima, el 11 % (n = 261). Rehecho a mano desde el CSV, con los 360 de entrenamiento (`entr`):

```
tapply(entr$estado_3a == "cerró", entr$trafico_peatonal < 164.5, mean)
```

Un corte del árbol es una tabla cruzada. Si no se puede rehacer, no se puede defender.

El árbol completo: dos preguntas, cuatro hojas



Profundidad 2, mínimo 15 por hoja, 360 locales, doce columnas de antes de comprar.

Tráfico de 225 o más: cierra 1 de cada 10 (p = 0.06, n = 187).
Tráfico entre 165 y 224: 2 de cada 10 (0.23, n = 74).
Tráfico bajo, arrendatario con 9 años o más: 1 de cada 10 (0.12, n = 24).
Tráfico bajo, menos de 9 años: 5 de cada 10 (0.55, n = 75). La única hoja que predice "cierra".

¿Coincide la raíz con la pregunta que escribieron al empezar?

El examen: los 120 locales de validación

El árbol se examina donde no estudió, con el umbral de 0.5:

TP	FP	FN	TN	Exactitud	Margen	Sensibilidad
15	11	9	85	0.833	$\pm$ 0.068	0.625

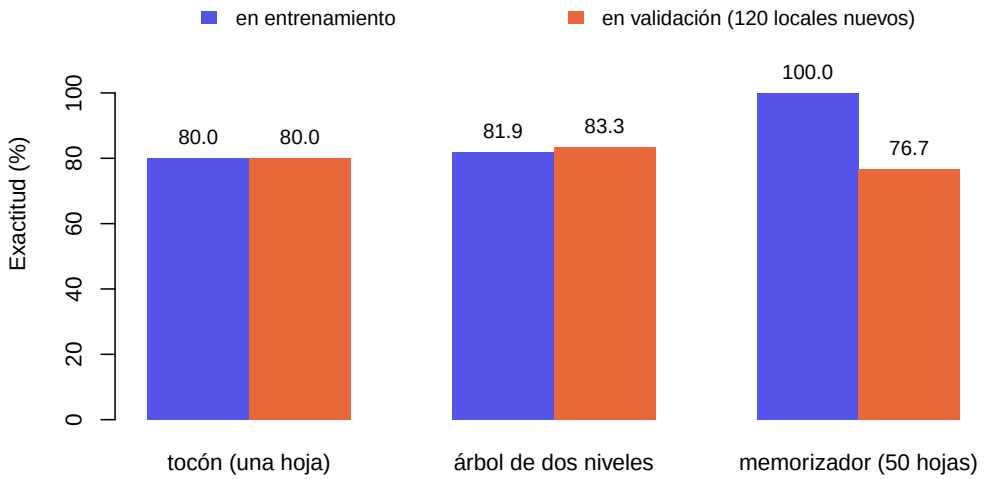
Y entra al ranking de modelos de la semana 4:

Regla o modelo	Exactitud	Sensibilidad
Nadie cierra	0.800	0.000
Consultora A	0.858	0.417
Consultora B	0.792	0.500
Árbol de dos niveles	**0.833**	**0.625**

Lo que importa

En exactitud, empate técnico con "nadie cierra" (0.833 contra 0.800, margen $\pm$ 0.068). En cierres encontrados, 15 de 24: más que cualquier consultora. Se reportan las dos cifras juntas.

El memorizador, en vivo



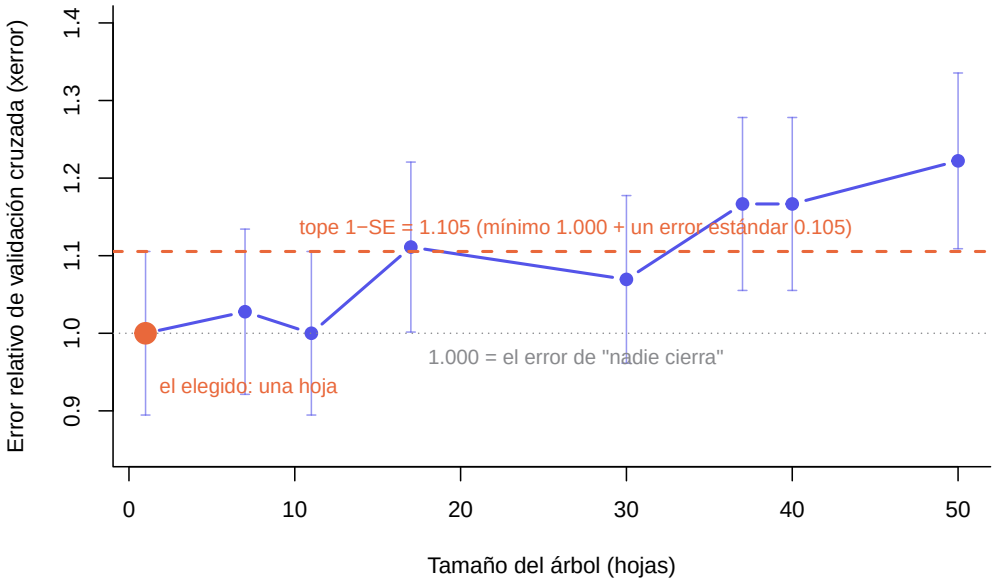
- **50 hojas.** Exactitud **1.000** en entrenamiento.
- En validación, **0.767**: peor que no hacer nada (0.800).
- El árbol de dos niveles: 0.819 y 0.833. Lo que aprendió, lo repite.

Sin frenos: `cp = 0.0001`, `minsplit = 2`, `minbucket = 1`. En el laboratorio de la semana 5, profundidad 6 y mínimo 5 muestran lo mismo.

Lo que importa

El estudiante que se sabía el parcial de memoria. La cifra de entrenamiento no se reporta como desempeño.

La poda honesta: la tabla cp y la regla 1-SE



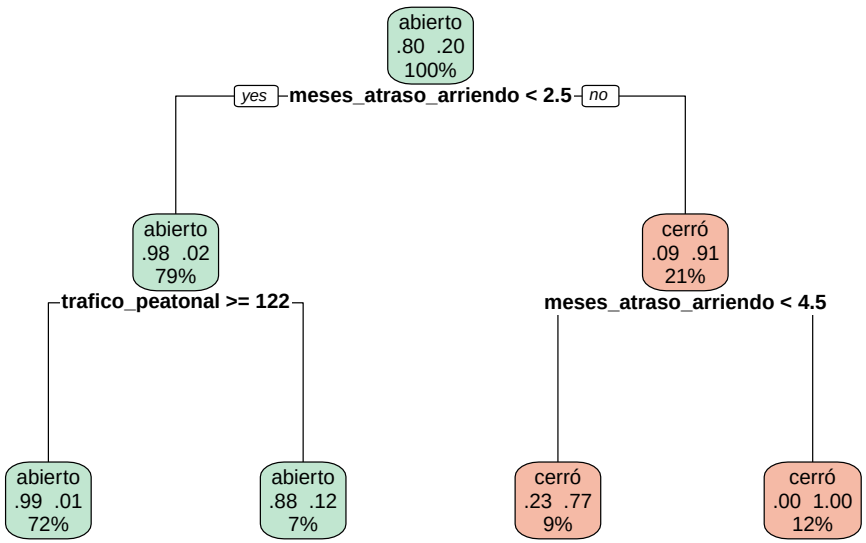
`rpart` corre validación cruzada mientras entrena: para cada tamaño, el error relativo a "nadie cierra" (1.000).

Regla 1-SE: mínimo (1.000) más un error estándar (0.105) = tope **1.105**. El árbol más simple bajo el tope tiene **una hoja**: el tocón.

¿Falló algo? No. Con dos de cada diez cerrados, ningún corte le gana a "nadie cierra" en exactitud por más de un error estándar.

¿Inútil? En exactitud, 0.833 contra 0.800 es empate técnico ($\pm$ 0.068). En cierres encontrados, **15 de 24** contra **0**. Eso es lo que importa.

Un segundo árbol, con más exactitud



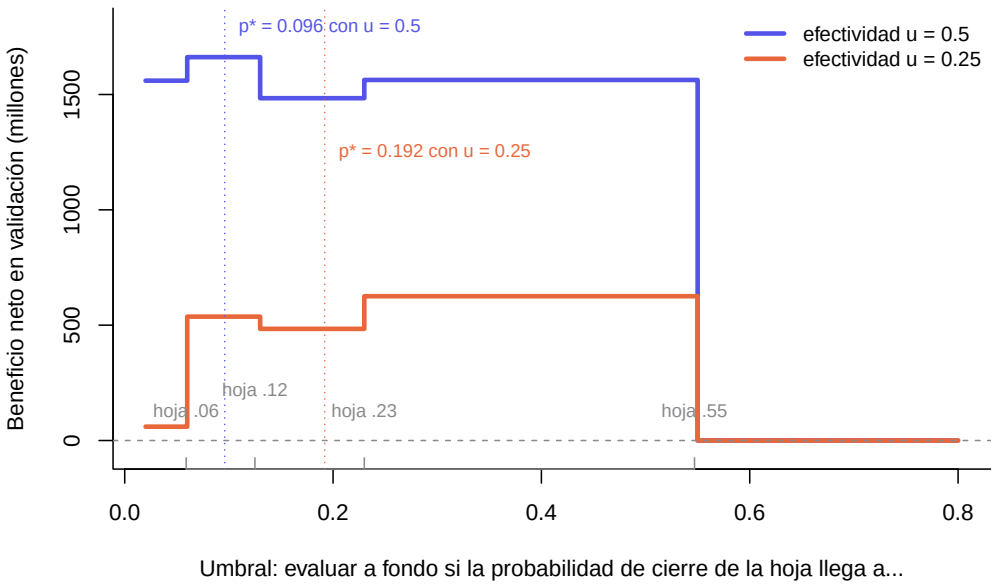
Un equipo entrena otro árbol con las mismas 360 filas: raíz en `meses_atraso_arriendo < 2.5` y **94.2 %** de exactitud en validación, frente a 83.3 %.

Parada activa: error sembrado

¿Qué está mal? Dos minutos en parejas. Pista: ¿cuánta mora en el canon tiene un local que todavía no se arrienda?

La mora se acumula *mientras* el arrendatario cierra: predice el pasado. Para un local candidato vale cero por definición. El salto a 0.942 es la alarma de la semana 3.

El umbral con los costos de la semana 4



La hoja no dice "cierra": dice 6, 12, 23 o 55 de cada 100. El 0.5 que trae el programa no es de Meridiano.

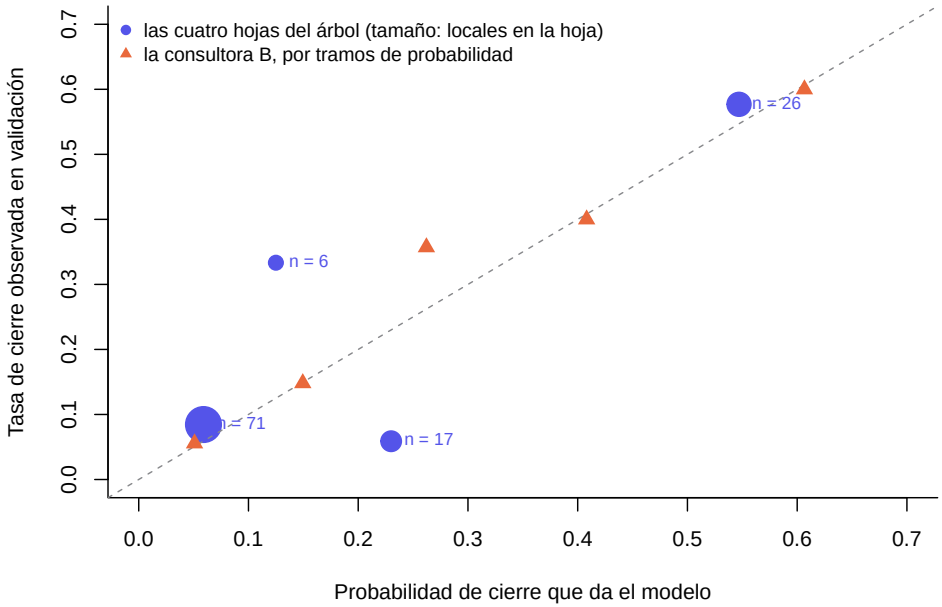
En palabras: evaluar a fondo cuando $p \times u \times V > c$; el umbral es $p^* = c/(u \times V)$.

$u = 0.5$: $p^* = 12/125 = \mathbf{0.096}$.
Se evalúan tres de las cuatro hojas.

$u = 0.25$: $p^* = 12/62.5 = \mathbf{0.192}$.
Solo las hojas de 0.23 y 0.55.

Con cupo (presupuesto para evaluar uno o dos de los tres locales), el umbral deja de importar: se ordena por riesgo.

¿Las probabilidades son creíbles?

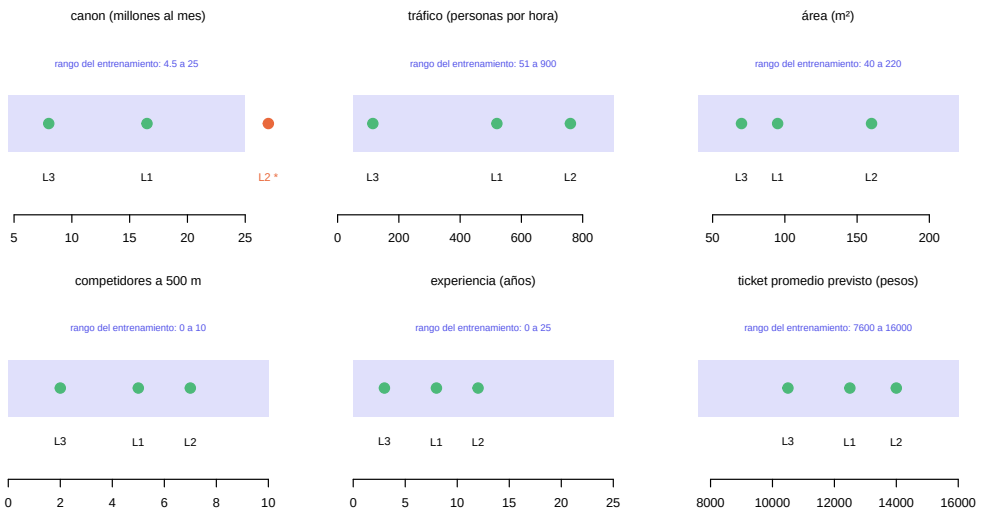


Entre los locales a los que el árbol les da 55 %, ¿cierra cerca del 55 %? La promesa del modelo se compara, por tramos, con lo observado en validación.

Hoja del árbol	Observada	n
p = 0.06	0.085	71
p = 0.12	0.333	6
p = 0.23	0.059	17
p = 0.55	0.577	26
B, tramo 0 a 0.1	0.056	54
B, 0.1 a 0.2	0.148	27
B, 0.2 a 0.3	0.357	14
B, 0.3 a 0.5	0.400	15
B, 0.5 a 1	0.600	10

Las hojas grandes son creíbles; las pequeñas oscilan con uno o dos cierres. Por eso el umbral no rinde lo que p^* promete: la hoja de 0.23 decepcionó.

Los tres locales de Barranquilla, con asteriscos



Local	p	Nota
1	0.059	* ciudad
2	0.059	* ciudad, canon 27
3	0.547	* ciudad

Orden por riesgo: 3, luego 1 y 2 empatados. **Con** $p^* = 0.096$**:** se evalúa a fondo el 3; 1 y 2 pasan.

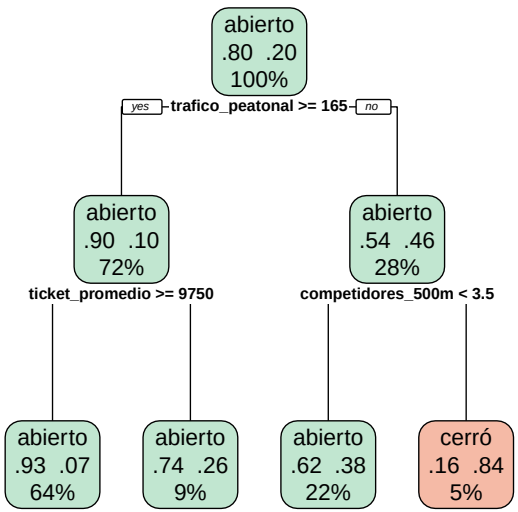
*** Fuera del soporte.** Ningún local del estudio está en Barranquilla; el canon de mercado del local 2 es 27 millones y el máximo del entrenamiento es 25. El árbol responde igual: que responda no significa que sepa.

Lo que importa

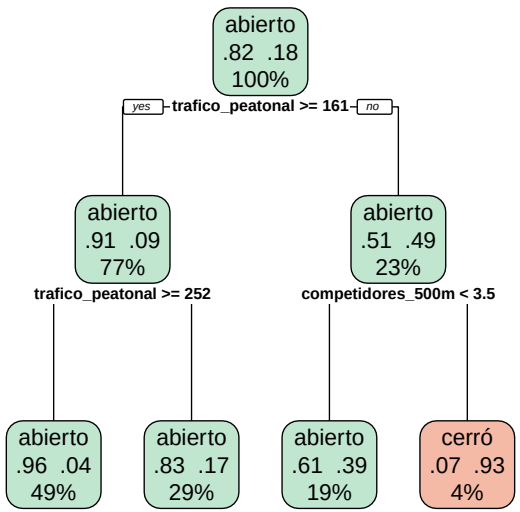
La nota de extrapolación va pegada a la cifra. Sin nota, no cuenta.

El giro: otra semilla, otro segundo nivel

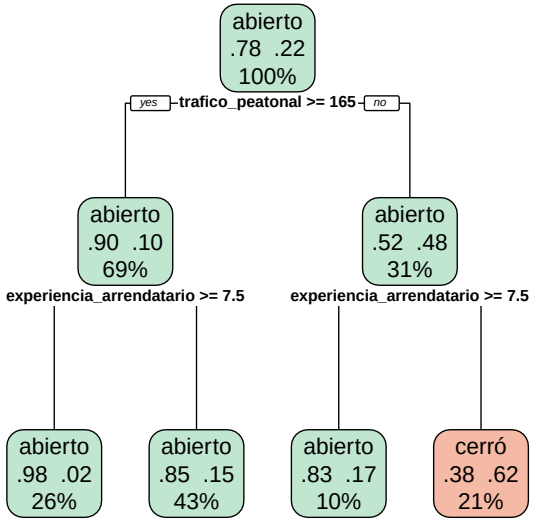
semilla de partición 101



semilla de partición 202



semilla de partición 303



Tres particiones distintas del mismo estudio. La raíz es siempre el tráfico (164.5, 160.5 y 164.5). El segundo nivel cambia: ticket promedio y competidores; tráfico y competidores; experiencia.

Parada activa: el giro

¿Qué sí le decimos a la junta y qué nos guardamos? Una línea por equipo.

Lo que importa

Lo que importa

1. **El árbol es una política que se lee.** Cuatro reglas, cada una con cuántos de cada diez y con cuántos locales la respaldan. Se traduce sin decir nodo ni corte, y sin decir causa.
2. **La cifra que vale es la de validación.** El memorizador saca 1.000 en entrenamiento y 0.767 en validación; la poda honesta deja el tocón porque la exactitud engaña con clases raras. Se reportan exactitud *y* sensibilidad.
3. **La hoja es una probabilidad y el umbral es del negocio.** $p^* = c/(u \times V)$: 0.096 o 0.192 según la efectividad. Con cupo, se ordena por riesgo.
4. **Lo que aguanta cuando cambia la muestra es lo que se cuenta.** La raíz sí; el segundo nivel, no. Y fuera del soporte, asterisco.

1. La historia: el primer árbol que predijo quiebras
2. La aplicación: el árbol del estudio de locales
3. El task y el cierre

Task 5: el árbol del equipo

Qué se entrega (una página, en equipo, antes de la sesión 6; se hace con el laboratorio de la semana 5, sin código):

- tres reglas del árbol traducidas para la junta, con p y n (1.5);
- el ranking de modelos con la fila del árbol del equipo, contra el sobre y con margen (1.5);
- el umbral elegido con los costos y qué locales pasan (1.0);
- los tres locales con su riesgo y su nota de extrapolación (0.5);
- el acta y la declaración (0.5).

En el cierre de la sesión 6

Cada equipo traduce una rama en voz alta. Dos preguntas: ¿el árbol cambió con otra semilla y qué aguantó? ¿Qué sí se le dice a la junta?

Lo que no cuenta

La exactitud de entrenamiento. Un árbol con `meses_atraso_arriendo`. Una hoja de menos de diez locales. Barranquilla sin asterisco.

Cierre: evaluación de modelos (task 4)

1. **Encuesta** (2 minutos): ¿quién eligió A, quién B, quién ninguna? Se cuenta a mano alzada.
2. **Dos equipos al azar, dos minutos cada uno** (6 minutos): su ranking de modelos y su recomendación. A encuentra 10 de 24 cierres con 13 evaluaciones; B, 12 con 25.
3. **El giro de costos** (8 minutos): con efectividad 0.5 gana B (1.200 frente a 1.094 millones); con 0.25 gana A (469 frente a 450). ¿Qué costo volteó su elección? La efectividad de quiebre es 0.288; la pérdida evitada de quiebre, 144 millones.
4. **La pregunta de hoy** (2 minutos): el árbol encuentra 15 de 24 con 26 evaluaciones. ¿Queda por encima de las consultoras, empata o queda por debajo? ¿Con qué cifra lo defienden?
5. **Dudas** (2 minutos): el laboratorio, la práctica opcional y la entrega del task 5.

Referencias

- Frydman, H., Altman, E. I. y Kao, D.-L. (1985). Introducing recursive partitioning for financial classification: the case of financial distress. *The Journal of Finance*, 40(1), 269–291. https://doi.org/10.1111/j.1540-6261.1985.tb04949.x
- Rudin, C. (2019). Stop explaining black box machine learning models for high stakes decisions and use interpretable models instead. *Nature Machine Intelligence*, 1(5), 206–215. https://doi.org/10.1038/s42256-019-0048-x
- Altman, E. I. (1968). Financial ratios, discriminant analysis and the prediction of corporate bankruptcy. *The Journal of Finance*, 23(4), 589–609. https://doi.org/10.1111/j.1540-6261.1968.tb00843.x
- Breiman, L., Friedman, J., Olshen, R. y Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Sosa Escudero, W. (2019). *Big data*. Siglo XXI. El capítulo sobre aprendizaje automático.