Analítica Predictiva y Prescriptiva

Semana 6: Árboles de regresión

Universidad Icesi · TIC-60286

Dónde vamos

La semana pasada: un árbol que responde sí o no. Lo leyeron como política, lo examinaron en validación y lo aplicaron a los tres locales candidatos con asterisco. Su task 5 se discute hoy, en el cierre.

Hoy, la pieza 6 del expediente: el mismo árbol, preguntando un número. Cuánto vende el arrendatario de un local, con qué error en pesos, si le gana a la regla del sector, dónde falla, y las ventas base con banda que entran al VPN de la semana 7.

La sesión

1. El paper: árboles, bosques y regresión prediciendo el valor de viviendas (2017).
2. El árbol de ventas, leído en voz alta y rehecho a mano.
3. El ranking de modelos en pesos, con un error sembrado.
4. Los diez peores, las bandas y un giro.
5. Cierre: el task 5.

Antes de empezar

Parada activa: encuesta por rangos

¿Cuánto vende al mes el arrendatario minorista de un local de **80 m^2 en zona de oficinas en Barranquilla**? Marquen un rango: menos de 80 / de 80 a 120 / de 120 a 160 / de 160 a 200 / más de 200 millones.

Guarden su rango. Al final de la aplicación lo comparamos con lo que dice el árbol para un local parecido (el local 1, de 95 m^2) y con lo que dice la regla del sector. La cifra que cada uno marcó es su ancla: vamos a ver cuánto pesa.

1. El paper: predecir el valor de una vivienda
2. La aplicación: el árbol de ventas de Meridiano
3. El task y el cierre

Qué aporta el aprendizaje automático a la economía aplicada

Qué investigaron. Qué puede hacer el aprendizaje automático por la economía aplicada. Su respuesta: predecir. La econometría clásica estima parámetros ($\hat{\beta}$: cuánto cambia y cuando cambia x); el aprendizaje automático produce $\hat{y}$ (qué valor toma y en una unidad nueva) sin prometer nada sobre los parámetros.

El ejemplo. Predecir el valor de una vivienda a partir de sus características: el problema del avaluador instantáneo, y el nuestro a otra escala.

La distinción que organiza el estudio

- **Predicción ($\hat{y}$):** se juzga por el error en datos nuevos; vale cualquier método que acierte.
- **Estimación ($\hat{\beta}$):** se juzga por si el coeficiente es el efecto; exige supuestos.
- Un buen $\hat{y}$ no da un buen $\hat{\beta}$: las variables que elige el algoritmo no son "las causas".

Mullainathan y Spiess (2017), *Journal of Economic Perspectives* — https://doi.org/10.1257/jep.31.2.87

Qué datos y cómo

- **American Housing Survey 2011**, muestra metropolitana: viviendas ocupadas por su propietario y el valor que el propietario declara (en logaritmo).
- **150 características** de la vivienda y su entorno (habitaciones, área, antigüedad, región, ciudad o suburbio), más doce indicadores de datos faltantes.
- **10.000 unidades de entrenamiento** y **41.808 de prueba**, separadas antes de ajustar nada.
- Cinco métodos: **regresión lineal** con las 150 variables, **árbol de regresión** ajustado por profundidad, **LASSO**, **bosque aleatorio** y un **ensamble** de los anteriores.
- Los frenos (la profundidad del árbol, la penalización del LASSO) se eligen por validación cruzada de ocho pliegues *dentro* del entrenamiento.
- Todos se juzgan por el R^2 en las 41.808 unidades de prueba, que ningún método vio.

Lo que importa

La arquitectura del curso: un lote para construir, otro para examinar, y los frenos elegidos sin mirar el examen.

¿Quién predice mejor fuera de muestra?

	R^2 del valor de la vivienda	
Método	Entrenamiento	Prueba
Regresión lineal	47.3 %	41.7 %
Árbol de regresión	39.6 %	34.5 %
LASSO	46.0 %	43.3 %
Bosque aleatorio	**85.1 %**	45.5 %
Ensamble	80.4 %	**45.9 %**

10.000 viviendas para entrenar; 41.808 de prueba, que ningún método vio. El árbol, con la profundidad elegida por validación cruzada. Margen de dos errores estándar en prueba: cerca de $\pm$ 2 puntos en todas las filas.

Tabla 1 de Mullainathan y Spiess (2017), *Journal of Economic Perspectives* — https://doi.org/10.1257/jep.31.2.87

La lectura de la tabla

- **El árbol solo pierde** con la regresión fuera de muestra: 34.5 contra 41.7. Es tosco: una escalera de promedios.
- **El bosque "memoriza" y aun así gana:** 85.1 en entrenamiento, 45.5 en prueba. La columna de entrenamiento no dice nada; la de prueba, todo.
- **El ensamble gana por poco** (45.9): ningún método domina en todos los tramos de valor.
- **Las variables que elige LASSO cambian** de una submuestra a otra **sin que cambie la calidad de la predicción**: lo estable es el pronóstico, no la lista de variables.

Mullainathan y Spiess (2017), *Journal of Economic Perspectives* — https://doi.org/10.1257/jep.31.2.87

Por qué importa para quien decide

Tres lecciones

1. **Un pronóstico se juzga por su error fuera de muestra**, en la unidad de la decisión. El ajuste en entrenamiento es un espejismo: el bosque sacó 85 y valía 45.
2. **El árbol solo es tosco; el bosque promedia y gana.** Por eso la consultora B es un bosque y el árbol es su vocero: el bosque decide, el árbol explica.
3. **Las variables del árbol no son las causas.** Otra muestra, otras variables, la misma calidad. A la junta se le cuenta lo que aguanta, no la lista.

Parada activa: el puente

Meridiano tiene el estudio de locales (480 locales con las ventas de sus arrendatarios y doce variables de antes de comprar) y tres locales candidatos en Barranquilla. Necesita lo mismo que el avaluador: un pronóstico con su error en pesos, medido en locales que el método no vio, y un baseline que vencer.

1. El paper: predecir el valor de una vivienda

2. La aplicación: el árbol de ventas de Meridiano

3. El task y el cierre

Los baselines: la mediana y la regla del sector

El baseline ingenuo: la mediana del entrenamiento, 93.1 millones para todos. MAE 31.1 en validación.

El baseline exigente: la regla del sector, ventas $\approx 8 \times$ canon de mercado. La cuenta que la gerencia de inversión hace de memoria. MAE **22.4** ($\pm$ 3.7), RMSE 30.0.

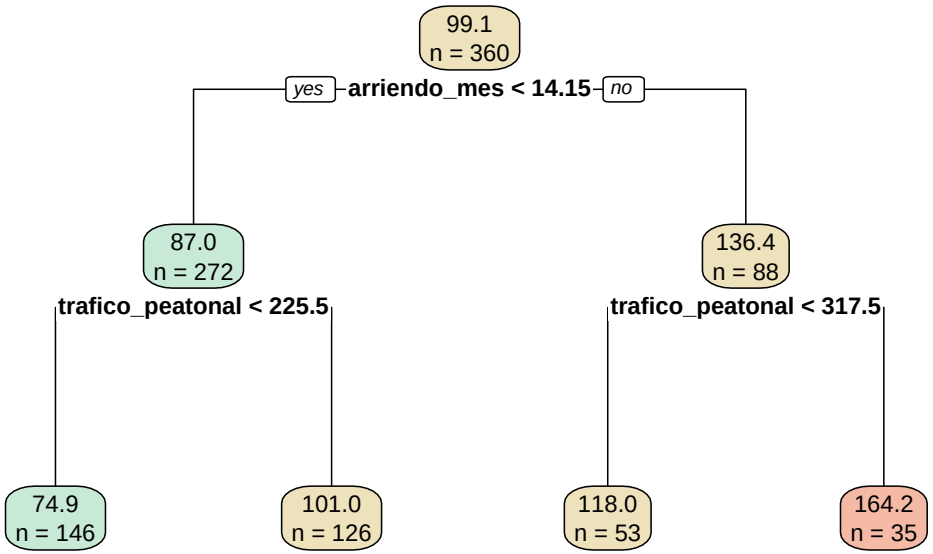
Para Barranquilla: local 1, $8 \times 16.5 = 132$; local 2, $8 \times 27 = 216$; local 3, $8 \times 8 = 64$.

Lo que importa

Un modelo aporta solo lo que le gana al baseline. La semana 4 lo dejó claro con las consultoras: A empató con la regla y B le ganó por 4.4 millones al mes por local. Hoy el árbol entra a la misma tabla.

La regla no es arbitraria: en estos datos el canon ya resume la ciudad, la zona, el área y el tráfico. Por eso la primera pregunta del árbol va a ser el canon (`arriendo_mes`).

El árbol de ventas, leído en voz alta



Profundidad 2, mínimo 10 por hoja, 360 locales, doce columnas de antes de comprar, método `anova`: cada hoja predice un promedio.

Canon bajo (menos de 14.15) y tráfico bajo: 74.9 millones (n = 146).
Canon bajo y tráfico de 226 o más: 101.0 (n = 126).
Canon alto y tráfico medio: 118.0 (n = 53).
Canon alto y tráfico de 318 o más: 164.2 (n = 35).

La raíz ya no es el tráfico: es el canon de mercado, que lo resume todo. ¿Coincide con su rango de la encuesta?

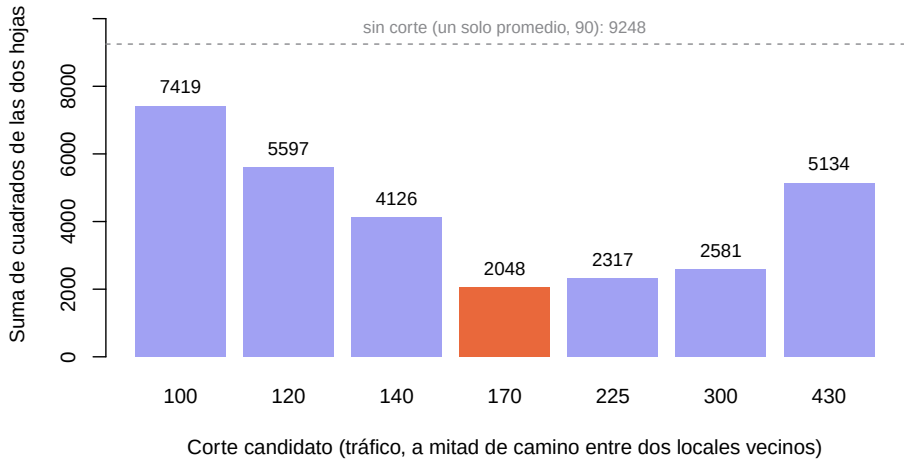
El promedio de una hoja a mano (I): elegir el corte

Local	A	B	C	D	E	F	G	H
Tráfico (personas por hora)	90	110	130	150	190	260	340	520
Ventas (millones al mes)	50	56	66	68	96	104	130	150

Corte en 170 (entre D y E): izquierda, promedio 60 y suma de cuadrados 216; derecha, promedio 120 y 1.832. Total **2.048**.

Corte en 300 (entre F y G): izquierda 73.3 y 2.381; derecha 140 y 200. Total 2.581.

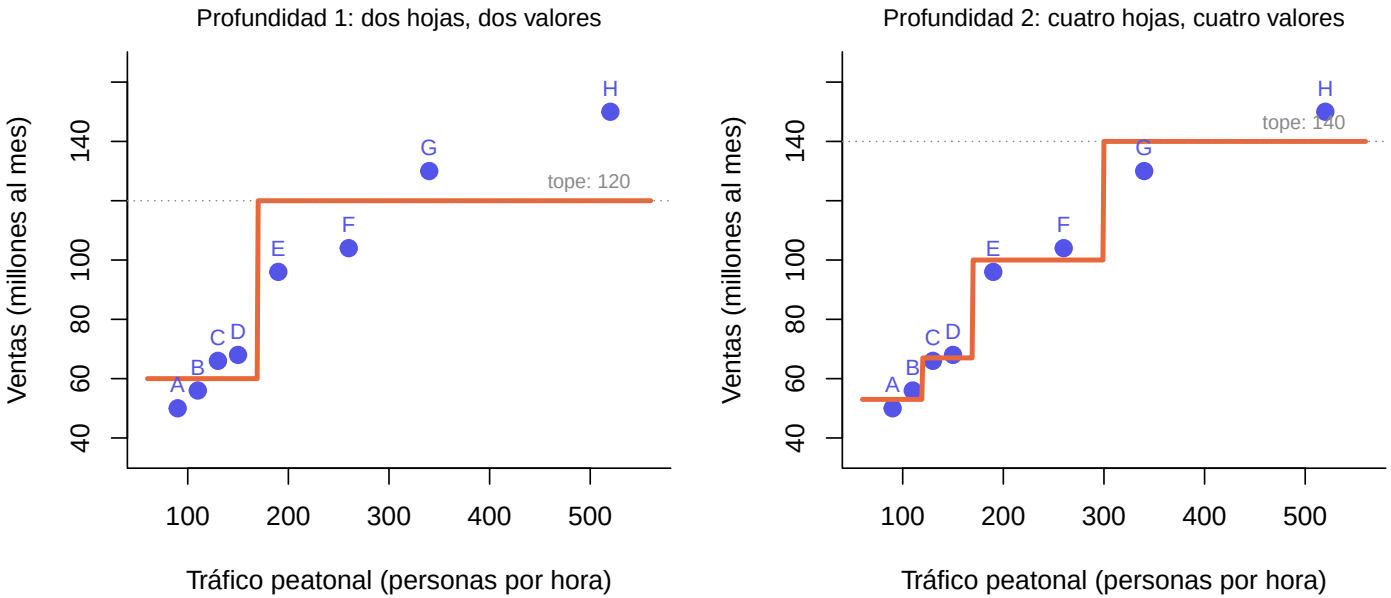
Sin corte: un solo promedio (90), 9.248.



Lo que importa

El árbol ensaya los siete cortes y se queda con el que deja las hojas más apretadas. Una hoja es un promedio; un corte es una tabla de dos promedios.

El promedio de una hoja a mano (II): una escalera, no una rampa



- **k hojas, k valores.** Con un corte el árbol solo dice 60 o 120; con tres, 53, 67, 100 o 140. No hay rampa entre peldaños.
- **El tope.** H vende 150 y recibe 140. Un local con 900 personas por hora también recibiría 140: el árbol no extrapola.
- **El error de construcción siempre baja:** MAE 30 (la mediana), 13.5 (un corte), 4.5 (tres cortes). Hasta cero si cada local queda solo en su hoja: el memorizador.

El promedio de una hoja a mano (III): la hoja real, n = 10



Ventas de los diez locales de entrenamiento que caen en la hoja (millones al mes)

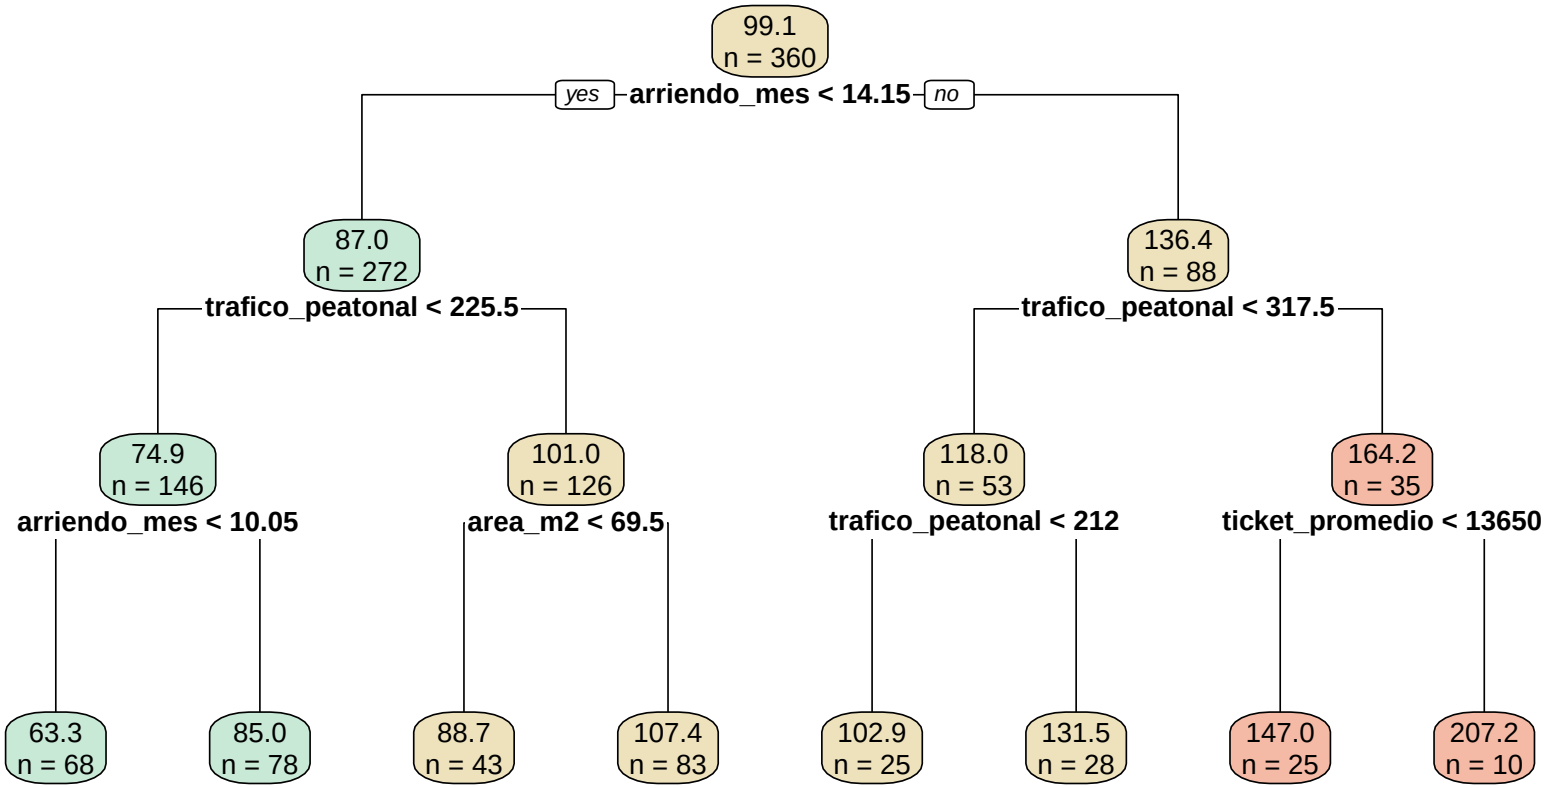
La hoja más alta del árbol de profundidad 3: canon de 14.15 o más, tráfico de 318 o más y ticket previsto de 13.650 pesos o más. Diez locales de entrenamiento:

215: 159.7; 151: 163.3; 44: 192.6; 270: 193.6; 111: 201.2; 280: 209.3; 5: 220.6; 147: 225.2; 90: 247.3; 452: 259.0.

Suma: 2.071.8. Promedio: $2071.8/10 = \mathbf{207.18}$.

Es la predicción del local 2 (canon 27, tráfico 760, ticket previsto 14.000): no puede ser otra, y no puede ser mayor. Es el tope del árbol.

Profundidad 3: ocho hojas, de 63.3 a 207.2



Es el árbol de referencia de las bandas. Añade el canon en 10.05, el área en 69.5, el tráfico en 212 y el ticket previsto en 13.650 pesos. Ocho valores posibles; el más alto, 207.2, con diez locales; el más bajo, 63.3, con 68. En validación: MAE **22.6** ($\pm$ 4.2), RMSE **32.2**.

El ranking de modelos en pesos (la versión de un equipo)

Predicción de ventas	MAE	RMSE
Mediana del entrenamiento	31.1	43.9
Regla del sector: 8 × canon	22.4	30.0
Consultora A	22.9	30.6
Consultora B	17.9	25.9
Árbol de profundidad 3	**17.8**	**23.4**

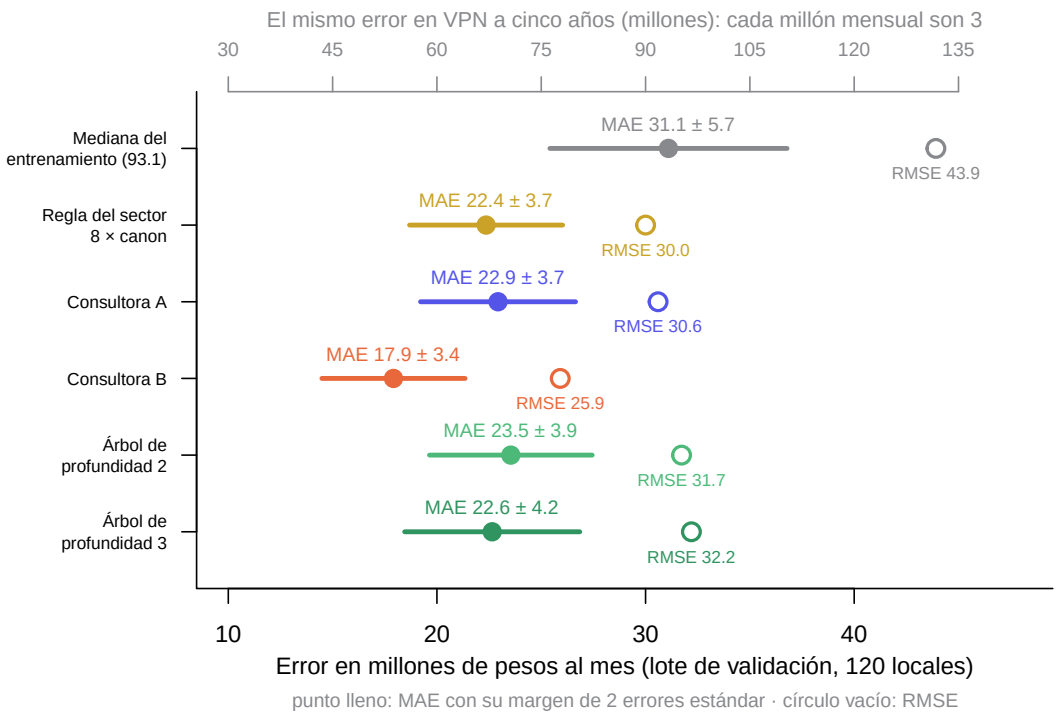
"El árbol del equipo le gana a la consultora B (17.8 contra 17.9) y a la regla del sector por más de cuatro millones al mes. Recomendamos adoptarlo."

Parada activa: error sembrado

¿Qué está mal en esta tabla? Dos minutos en parejas. Pista: ¿en qué locales se midió cada fila?

La fila del árbol es su MAE en los 360 locales con los que se construyó. Las otras cuatro, en los 120 de validación. En validación el árbol da **22.6**: empate con la regla. Es el bosque de Mullainathan y Spiess: 85 en entrenamiento, 45 en prueba.

El ranking de modelos en pesos, en validación



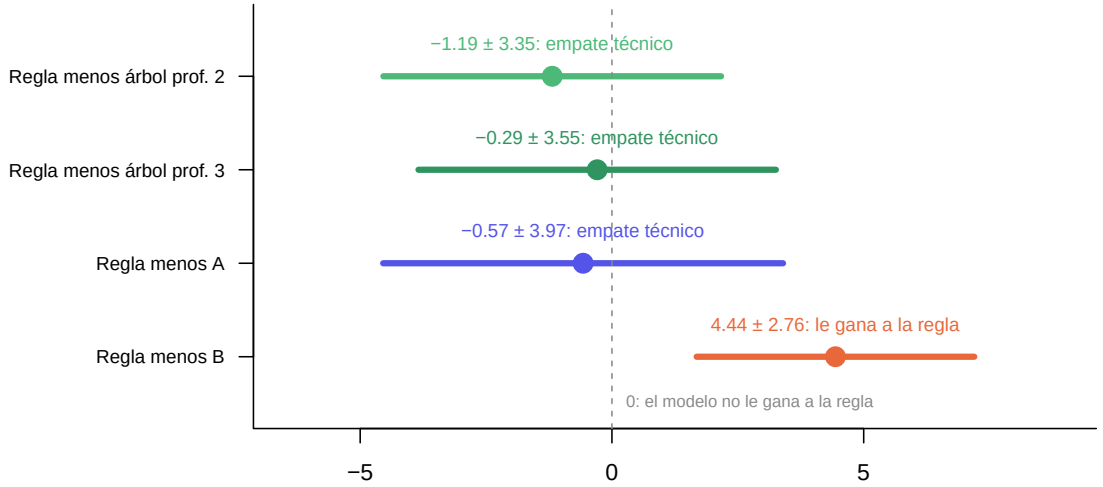
Los 120 locales que ningún método vio. MAE con margen de dos errores estándar; RMSE al lado.

El árbol: 22.6 $\pm$ 4.2 (prof. 3), 23.5 $\pm$ 3.9 (prof. 2). **La regla:** 22.4 $\pm$ 3.7. **B:** 17.9 $\pm$ 3.4.

En VPN a cinco años (3 por millón mensual, canon del 10 %): el error típico del árbol son **68 millones**; el de B, 54.

La brecha MAE–RMSE (22.6 contra 32.2) anuncia errores grandes ocasionales: los vemos en dos láminas.

¿Le gana a la regla del sector? La comparación pareada



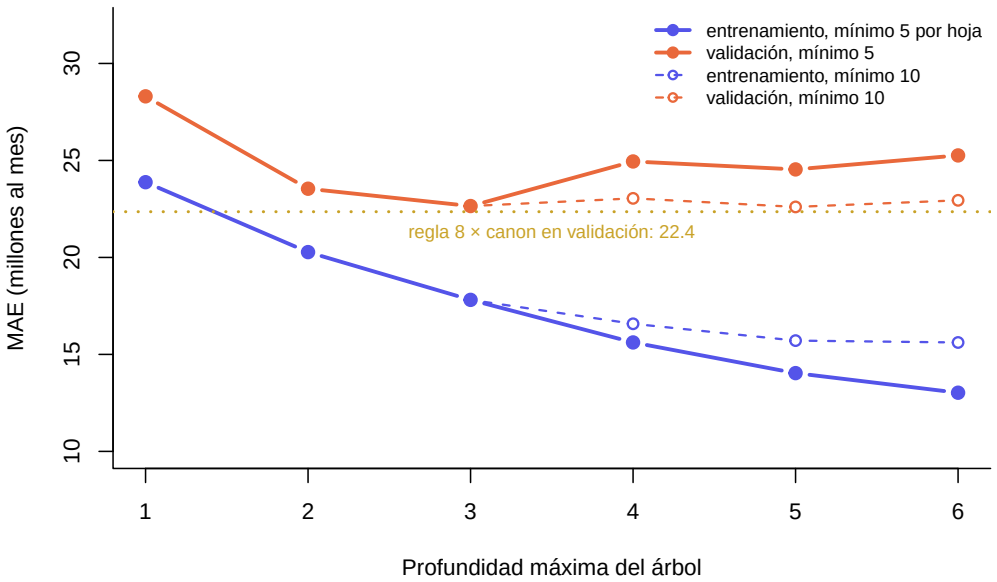
Error de la regla menos error del modelo, punto por punto (promedio y margen de 2 EE)

Punto por punto: error de la regla menos error del modelo. Regla menos árbol de profundidad 3: -0.29 ± 3.55; profundidad 2: -1.19 ± 3.35. El margen cruza el cero: **empate técnico**, igual que A. Solo B le gana (4.44 ± 2.76).

Lo que importa

Un árbol que empata con "8 × canon" no es inútil: dice lo que la gerencia de inversión ya sabe, con una banda medida. Pero no justifica una factura.

El memorizador, en pesos

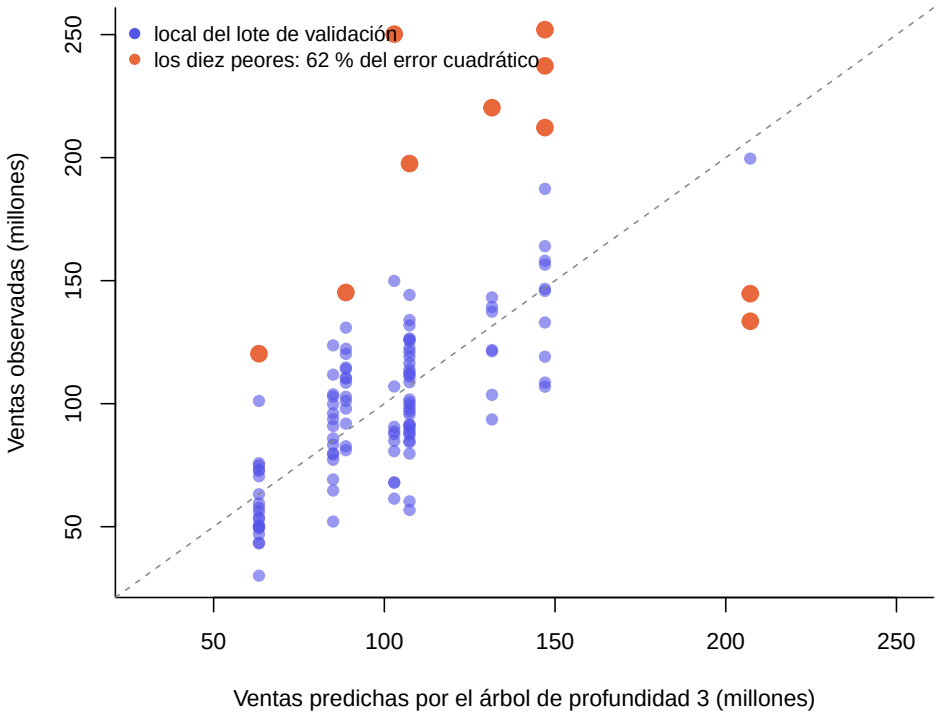


- Con mínimo 5 y profundidad 6, **33 hojas**: MAE 13.0 en entrenamiento y 25.3 en validación.
- La profundidad 3 (22.6) ya está en el fondo de la curva de validación; de ahí en adelante solo mejora la de entrenamiento.
- Ningún árbol le gana a la regla (22.4) por más que el ruido.

Parada activa: chat

Un equipo reporta MAE 14 y RMSE 31. ¿Qué está pasando? Una línea.

Dónde falla: los diez peores



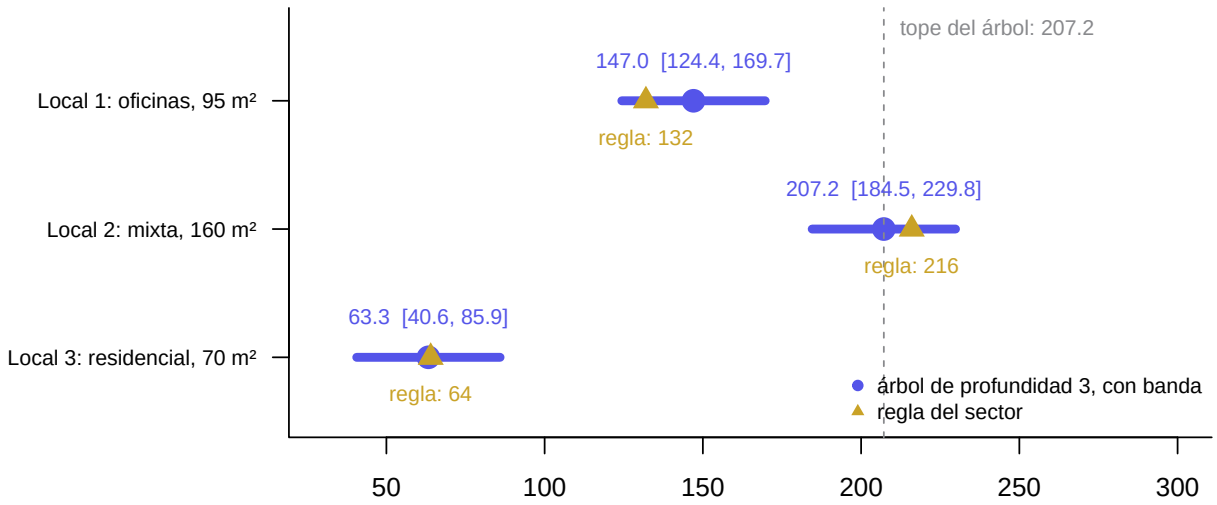
Diez locales de 120 concentran el **61.8 %** del error cuadrático. En ocho el arrendatario vende más de lo que el árbol dice; **seis pasan de 150 millones**; siete están en zona de oficinas. Los dos que el árbol sobreestima (366 y 36) caen en la hoja de 207.2.

El arrendatario del local 52 vende 250.2 y el árbol dice 102.9: ventas altas en una hoja típica. Ninguna hoja pasa de 207.2.

Lo que importa

Tratamiento aparte: el modelo para la mayoría, una persona para los grandes. Sin los diez, el MAE baja a 17.1; esa cifra es un diagnóstico, no un desempeño. No se arregla con más profundidad.

Las ventas base de los tres locales, con banda

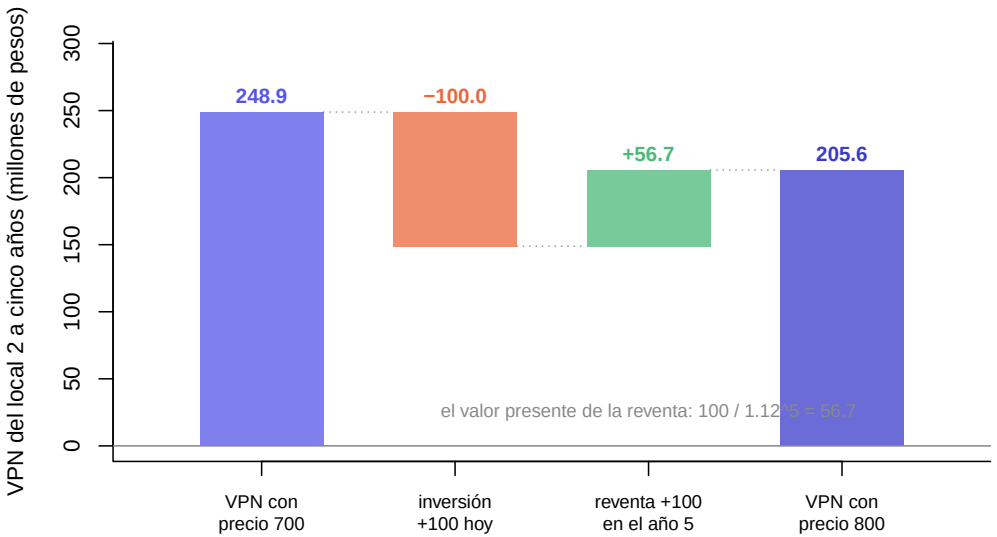


Ventas mensuales (millones): ventas base del árbol ± MAE 22.6, y la regla 8 × canon

Local	Base	Banda ($\pm$ 22.6)	Regla 8 $\times$	Nota de extrapolación
Local 1 (oficinas)	147.0	[124.4, 169.7]	132	* ciudad
Local 2 (mixta)	207.2	[184.5, 229.8]	216	* ciudad; canon 27 $>$ 25; el tope
Local 3 (residencial)	63.3	[40.6, 85.9]	64	* ciudad

En VPN a cinco años ($\times$ 3): local 1, de 373 a 509; local 2, de 554 a 689; local 3, de 122 a 258. Son las **ventas base** de la semana 7, con la nota pegada. La regla cae dentro de la banda en los tres. Su rango de la encuesta: ¿cayó dentro de la banda del local 1?

El giro: el vendedor del local 2 sube el precio



La cascada: pagar 100 más hoy devuelve 100 en el año 5 (la reventa de la plantilla de la semana 7 es al precio de compra), y esos 100 valen $100/1.12^5 = 56.7$ hoy.

El vendedor pide **800** millones en lugar de 700.

Las ventas base no cambian: el precio de compra no es una variable del árbol (207.2, misma hoja) ni de la regla.

El VPN sí: $\Delta\text{VPN} = -100 + 56.7 = -43.3$; el base del local 2 pasa de 248.9 a **205.6**, sigue positivo.

Parada activa: el giro

¿Cambia la recomendación sobre el local 2? Una línea por equipo.

Lo que importa

Lo que importa

1. **La hoja es un promedio y el árbol es una escalera.** k hojas, k valores; el más alto es el tope. No extrapola: fuera del rango, asterisco.
2. **El error se reporta en pesos y fuera de muestra.** MAE 22.6 en validación (el 17.8 de entrenamiento no cuenta); en VPN, 68 millones. La brecha con el RMSE manda a mirar los diez peores.
3. **Contra el baseline, pareado.** El árbol empata con 8 $\times$ canon; solo el bosque le gana. Un empate con la regla no justifica una factura.
4. **Lo que se entrega es una banda.** Ventas base $\pm$ error típico, con la nota de extrapolación pegada, en millones al mes y en VPN. Sin banda no es pronóstico; sin nota no cuenta.

1. El paper: predecir el valor de una vivienda
2. La aplicación: el árbol de ventas de Meridiano
3. El task y el cierre

Task 6: el ranking en pesos y las ventas base

Qué se entrega (una página, en equipo, antes de la sesión 7; se hace con el laboratorio de la semana 6, sin código):

- el ranking de modelos en pesos, contra el sobre (1.5);
- dónde falla el modelo y qué se haría ahí: los diez peores y el tratamiento aparte (1.0);
- las ventas base de los tres locales con su banda y su nota de extrapolación, con la regla 8 $\times$ al lado (1.5);
- la posición actualizada: registro de posición, toma 2, cinco líneas (0.5);
- el acta y la declaración (0.5).

En el cierre de la sesión 7

Traen las bandas de los tres locales candidatos y su posición. Se discute "¿le ganamos a la regla?" y se comparan las bandas entre equipos.

Lo que no cuenta

Un MAE de entrenamiento. Una banda sin nota de extrapolación. Una predicción por encima de la hoja más alta. Una fila que no coincida con el sobre sin explicar la diferencia.

Cierre: el árbol del equipo (task 5)

1. **Una rama en voz alta** (8 minutos): cada equipo, al azar, traduce una rama de su árbol como se la diría a la junta, en un minuto. Sin "nodo", sin "corte", sin "causa", con p y n.
2. **¿Aguantó la raíz?** (5 minutos): a mano alzada, ¿a quién le cambió la raíz al cambiar la semilla? Con la partición del curso es el tráfico en 164.5; con las semillas 101 y 202, 164.5 y 160.5. ¿Y el segundo nivel?
3. **¿Qué sí se le dice a la junta?** (5 minutos): la primera pregunta y las hojas grandes; no el segundo nivel ni la hoja de 24 locales. Los locales candidatos de Barranquilla, siempre con asterisco.
4. **Dudas** (2 minutos): el laboratorio, la práctica opcional y la entrega del task 6.

Referencias

- Mullainathan, S. y Spiess, J. (2017). Machine learning: an applied econometric approach. *Journal of Economic Perspectives*, 31(2), 87–106. Tabla 1 y apéndice en línea (tabla B.1). https://doi.org/10.1257/jep.31.2.87
- Breiman, L., Friedman, J., Olshen, R. y Stone, C. (1984). *Classification and Regression Trees*. Wadsworth.
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. https://doi.org/10.1023/A:1010933404324
- Kleinberg, J., Ludwig, J., Mullainathan, S. y Obermeyer, Z. (2015). Prediction policy problems. *American Economic Review*, 105(5), 491–495. https://doi.org/10.1257/aer.p20151023
- Sosa Escudero, W. (2019). *Big data*. Siglo XXI. El capítulo sobre árboles y predicción.