

Caso Cóndor

Contexto del Proyecto Final — Introducción al Business Analytics (06278-ECO)

Universidad Icesi | Periodo 2026-01 | Fecha de corte de los datos: 31 de marzo de 2026

1. La empresa y el encargo

Cóndor es una *fintech* (empresa ficticia) con sede en Colombia y operación incipiente en Perú y Ecuador. Opera una plataforma de **pagos y crédito**: una billetera (*wallet*) para que las personas paguen con QR y tarjeta, transfieran, recarguen y pidan microcréditos, y un lado de comercios que aceptan esos pagos.

Cinco años de crecimiento acelerado dejaron a Cóndor con **datos abundantes pero desarticulados**. La Gerencia sospecha que la empresa crece en usuarios pero pierde dinero por los flancos —fraude, mora de crédito, clientes que se vuelven inactivos, campañas poco efectivas— y no logra cuantificar dónde ni por qué. **Ustedes son el equipo de analistas contratado** para elegir uno de esos frentes, formular una pregunta de negocio y responderla con las herramientas del curso.

Idea clave

El proyecto **no** evalúa código perfecto. Evalúa que planteen una buena pregunta, elijan la tarea analítica adecuada (clasificación, regresión o segmentación), la ejecuten con orden e **interpreten** los resultados para que alguien sin conocimientos técnicos pueda decidir y actuar.


2. Los frentes de trabajo y sus rutas

Cada grupo elige **un** frente. La tabla muestra la pregunta típica de cada área y la ruta analítica natural; varias preguntas admiten más de un enfoque.

Frente (área)	Pregunta típica	Ruta natural
Retención (Growth)	¿Qué clientes se van a volver inactivos?	Clasificación
Finanzas / Planeación	¿Cuánto va a gastar un cliente el próximo trimestre?	Regresión
Segmentación (Marketing)	¿Qué grupos de clientes existen y cómo se comportan?	Segmentación
Fraude y Seguridad	¿Qué transacciones son fraudulentas?	Clasificación
Riesgo de Crédito	¿Qué solicitudes de crédito caerán en mora?	Clasificación / Regresión
Marketing (campañas)	¿Quién va a responder a una campaña?	Clasificación

3. La estructura de los datos

Cóndor les entrega **una base principal** con lo esencial y **tres anexos** con detalle opcional. Todas las tablas se conectan por `cliente_id`.



- **Ruta fácil.** Trabajen **solo** con la base principal (**base_clientes**). Ya trae todo calculado a nivel cliente y alcanza para las tres rutas.
- **Ruta avanzada.** Sumen uno o más anexos para hacer su propio *feature engineering* o abordar preguntas de fraude, crédito o campañas. Es más exigente y se reconoce en la rúbrica.

4. Base principal: base_clientes

Una fila por cliente. Reúne demografía, comportamiento (RFM), uso de la app, soporte y crédito, más **dos variables objetivo** ya listas. Con esta sola tabla se pueden hacer las tres rutas. A continuación se explica cada variable.

Variable	Tipo	Descripción
Identificación y demografía		
cliente_id	id	Identificador único del cliente. Es la llave para unir la base con los anexos.
edad	entero	Edad del cliente, en años.
genero	categorica	Género del cliente: F, M u Otro.
ciudad	categorica	Ciudad de residencia declarada.
departamento	categorica	Departamento o región de residencia.
ocupacion	categorica	Ocupación del cliente: empleado, independiente, estudiante o pensionado.
ingreso_declarado	continua	Ingreso mensual que el cliente declaró al registrarse, en pesos colombianos (COP).
kyc_nivel	ordinal	Nivel de verificación de identidad (nivel_1, nivel_2 o nivel_3): a mayor nivel, más datos del cliente fueron validados.
canal_adquisicion	categorica	Cómo llegó el cliente a Cóndor: orgánico, ads_meta, ads_google, referido o influencer.
antiguedad_meses	entero	Meses transcurridos desde que el cliente se registró hasta la fecha de corte.
Comportamiento transaccional (RFM)		
recencia_dias	entero	Días desde la última transacción del cliente hasta el corte. Es la R de RFM: menos días significa un cliente más reciente.
frecuencia_tx	entero	Número total de transacciones que hizo el cliente. Es la F de RFM.
monto_total	continua	Suma de todos los montos que transó el cliente, en COP. Es la M de RFM.
monto_promedio	continua	Monto promedio por transacción, en COP.
ticket_mediano	continua	Mediana del monto de sus transacciones, en COP. A diferencia del promedio, no se distorsiona con transacciones muy grandes.
pct_tx_internacional	continua	Proporción de sus transacciones que fueron internacionales, entre 0 y 1.

continúa en la página siguiente...

(continúa de la página anterior)

Variable	Tipo	Descripción
num_categorias_mcc	entero	Cantidad de rubros distintos en los que ha comprado (variedad de consumo).
canal_preferido	categorica	Canal que el cliente usa con más frecuencia: app_qr, tarjeta, pse o link.
Uso de la app, soporte y saldo		
num_sesiones_ult30d	entero	Número de sesiones que el cliente abrió en la app en los últimos 30 días antes del corte.
duracion_sesion_promedio	continua	Duración promedio de una sesión, en segundos. Queda vacía si el cliente no tuvo sesiones recientes.
os_principal	categorica	Sistema operativo principal del cliente: Android o iOS.
num_tickets	entero	Número de tickets de soporte que ha abierto el cliente.
csat_promedio	continua	Satisfacción promedio con el soporte, en escala de 1 a 5. Queda vacía si el cliente nunca abrió un ticket.
gasto_promedio_mensual	continua	Gasto mensual histórico promedio del cliente, en COP.
saldo_promedio_ult3m	continua	Saldo promedio en la cuenta durante los últimos 3 meses, en COP.
Crédito		
tiene_credito	binaria	1 si el cliente ha solicitado al menos un crédito; 0 si nunca lo ha hecho.
score_buro	continua	Puntaje de buró de crédito (de 300 a 850) de su última solicitud. Queda vacía si el cliente nunca pidió crédito.
Variables objetivo (lo que un modelo intenta predecir)		
★ abandono	binaria	Ruta de clasificación. Vale 1 si el cliente se vuelve inactivo (deja de usar Cóndor) y 0 si sigue activo. Está definida para todos los clientes.
★ gasto_proximo_trim	continua	Ruta de regresión. Gasto total del cliente, en COP, durante el trimestre siguiente a la fecha de corte.

Idea clave

Algunas columnas tienen faltantes **con sentido**: **score_buro** está vacía para quien nunca pidió crédito, **csat_promedio** para quien no abrió tickets y **duracion_sesion_promedio** para quien no tuvo sesiones recientes. Diagnosticar y decidir qué hacer con esos faltantes es parte de la Entrega 2.

5. Anexos (detalle opcional)

Cada anexo se une a la base por **cliente_id** y habilita preguntas más específicas. Su variable objetivo está marcada con ★.

anexo_transacciones — una fila por transacción. Permite detección de fraude, construir RFM propio o segmentar con más detalle.

Columnas: **transaccion_id**, **cliente_id**, **comercio_id**, **timestamp**, **monto**, **tipo** (compra, transferencia, retiro, recarga, pago_servicio), **canal**, **rubro**, **es_internacional**, **estado** (aprobada/rechazada), ★ **etiqueta_fraude**.

anexo_creditos — una fila por solicitud de crédito. Permite predecir la mora o el monto recuperado de la cartera.

Columnas: **credito_id**, **cliente_id**, **fecha_solicitud**, **monto_aprobado**, **plazo_meses**, **tasa**, **score_buro**, **destino**, ★ **default_90d** (cayó en mora de 90+ días), **dias_mora**, ★ **monto_recuperado**.

anexo_campanas — una fila por envío de campaña a un cliente. Permite predecir la respuesta a campañas de marketing.

Columnas: **campana_id**, **cliente_id**, **fecha_envio**, **canal** (push/email/sms), **tipo_oferta** (cashback, descuento, upgrade_credito, genérico), **costo**, ★ **convertido**.

Regla de oro: no usar información del futuro

No usen como predictor ninguna variable que solo se conoce **después** del evento que quieren predecir. Por ejemplo, `dias_mora` y `monto_recuperado` **no** sirven para predecir `default_90d`: al momento de aprobar el crédito todavía no existen. Cuando una variable “predice demasiado bien”, sospechen de esta fuga de información.

6. Cómo elegir la ruta y reglas de los datos

Primero la pregunta, luego la técnica. Decidan qué quieren responder y de ahí se desprende la ruta:

- **Clasificación** (predecir una categoría): `abandono` en la base, o `etiqueta_fraude`, `default_90d`, convertido en los anexos.
- **Regresión** (predecir un número): `gasto_proximo_trim` en la base, o `monto_recuperado` en el anexo de créditos.
- **Segmentación** (agrupar sin objetivo): usen el bloque RFM de la base. Un segmento solo sirve si se puede **describir** y **accionar** (“clientes jóvenes de alto gasto y baja antigüedad”, no “grupo 3”).

Dos reglas. (1) *Fecha de corte*: los predictores se miden hasta el 31 de marzo de 2026; los objetivos se refieren a lo que ocurre en o después de esa fecha. (2) *Entrenamiento y prueba*: separen los datos, entrenen solo con la parte de entrenamiento y midan el desempeño en la de prueba, comparándolo siempre contra un **baseline** (la clase mayoritaria en clasificación; la media o mediana en regresión).

Cuidado con el grano al unir tablas. La base tiene una fila por cliente, pero `anexo_transacciones` tiene muchas por cliente. Para llevar transacciones al nivel de cliente hay que **agregar primero** (contar, sumar, promediar) y luego unir; unir sin agregar duplica filas.

7. Cargar los datos en R

Las cuatro tablas están publicadas como `.csv` y se cargan con `read.csv()` apuntando a su URL:

```
url_base <- "https://eduard-martinez.github.io/databases/ba/condor/"
clientes <- read.csv(paste0(url_base, "base_clientes.csv"))
# anexos (opcionales, para la ruta avanzada):
transacciones <- read.csv(paste0(url_base, ".anexo_transacciones.csv"))
```

Para la ruta fácil basta con `base_clientes` (es liviana). El `anexo_transacciones` es el más grande; si solo necesitan una parte, filtrenlo apenas lo carguen.

Cóndor es una empresa ficticia creada con fines pedagógicos. Cualquier parecido con una empresa real es coincidencia.