

Analítica para los negocios

06327-ECO

Semana 06: Entender los datos antes de modelar — el EDA del caso
Cóndor

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

8 de septiembre de 2026

Objetivo de la sesión

Hoy volvemos al caso Cóndor con **una pregunta de negocio concreta** y hacemos, in vivo, el primer análisis exploratorio que esa pregunta necesita.

- Van a ver el **razonamiento**, no un catálogo de gráficos: qué se pregunta el analista en cada paso, qué mira y qué decide con lo que ve.
- Los datos de Cóndor están **limpios**. No vamos a “arreglar” nada: vamos a **entenderlos** — el grano, los faltantes, las distribuciones, las comparaciones, las relaciones y lo raro.
- Cada paso se conecta con el podcast: las cuatro dimensiones, el “¿por qué falta?”, el atípico que no es error, la EDA que produce hipótesis.
- Terminamos donde termina un EDA: con lo que **sale** de él — hallazgos, hipótesis, decisiones y una base lista para modelar.

La idea que gobierna la sesión

El EDA **no responde** la pregunta de negocio: **la prepara**. Se sale de él con hallazgos, hipótesis y decisiones documentadas — y con la certeza de que los datos aguantan lo que viene.

¿Dónde estamos en el curso?

- **Semanas 1–4:** las herramientas. R, dplyr, ggplot2.
- **Semana 5:** el mapa. Las siete etapas del proceso analítico y, en clase, dos casos reales: de la necesidad vaga a la pregunta. Ustedes formularon la de su grupo sobre Cóndor.
- **Semana 6 (hoy):** las etapas 3 y 4 — conocer los datos antes de modelar. El podcast dio el *criterio*: fuentes, cuatro dimensiones de calidad, faltantes, atípicos, qué es la EDA. Hoy ese criterio se *ejecuta* sobre Cóndor.

Lo que cambia hoy

En la semana 5 el mapa se recorrió con casos ajenos. Hoy se recorre **con los datos de Cóndor**: la pregunta es del caso, los números son reales y cada paso deja una decisión.

Roadmap

- 1 La pregunta que manda
- 2 El EDA de Cóndor, paso a paso
- 3 Lo que sale del EDA

Roadmap

1 La pregunta que manda

2 El EDA de Cóndor, paso a paso

3 Lo que sale del EDA

La pregunta de negocio de hoy

Frente de retención (Growth)

*“¿Qué clientes de Cóndor que hoy están activos tienen alta probabilidad de **volverse inactivos** el próximo trimestre, para que Growth concentre en ellos la **campana de reactivación** en vez de enviársela a los 8.000?”*

La pregunta de negocio de hoy

Frente de retención (Growth)

*“¿Qué clientes de Cóndor que hoy están activos tienen alta probabilidad de **volverse inactivos** el próximo trimestre, para que Growth concentre en ellos la **campana de reactivación** en vez de enviársela a los 8.000?”*

- **Específica** — qué: volverse inactivo (abandono); quién: los 8.000 clientes de la base al corte del 31-mar-2026; cuándo: el trimestre siguiente.
- **Accionable** — la decisión es *a quién enviar* la campaña. Hoy va a ciegas: 13.467 envíos (ene-2025 a mar-2026), 10 % de conversión, unos \$2.250 por envío.
- **Medible** — abandono existe para los 8.000; 1 de cada 5 se va.

La pregunta de negocio de hoy

Frente de retención (Growth)

*“¿Qué clientes de Cónдор que hoy están activos tienen alta probabilidad de **volverse inactivos** el próximo trimestre, para que Growth concentre en ellos la **campaña de reactivación** en vez de enviársela a los 8.000?”*

- **Específica** — qué: volverse inactivo (abandono); quién: los 8.000 clientes de la base al corte del 31-mar-2026; cuándo: el trimestre siguiente.
- **Accionable** — la decisión es *a quién enviar* la campaña. Hoy va a ciegas: 13.467 envíos (ene-2025 a mar-2026), 10 % de conversión, unos \$2.250 por envío.
- **Medible** — abandono existe para los 8.000; 1 de cada 5 se va.

¿Qué tarea analítica es? ¿Cuál es la vara?

Output = categoría + target histórico $\Rightarrow$ **clasificación supervisada**. **Baseline**: “todos se quedan” acierta el 77,85 %; cualquier modelo debe ganarle.

Qué le pide esta pregunta al EDA

La pregunta convierte 29 columnas en **nueve preguntas de analista**. Ese es el mapa de la sesión:

Paso	Lo que se pregunta el analista	Lo que mira
1	¿Qué es una fila y cuántas hay?	tamaño, llaves, duplicados, las 4 tablas
2	¿Qué falta y <i>por qué</i> falta?	faltantes por columna y a quién le faltan
3	¿Cómo se ve el target?	la tasa base y la definición de “activo”
4	¿Cómo se distribuyen las candidatas?	histogramas: colas, media vs. mediana
5	¿Quiénes abandonan más?	tasa de abandono por tramos de comportamiento
6	¿Y lo que “debería” importar?	tasa por canal, ciudad, edad, género
7	¿Las señales miden lo mismo?	el cruce de dos variables
8	¿Qué aporta un anexo?	agregar por cliente y luego unir
9	¿Qué raro quedó — y qué <i>no</i> puedo usar?	colas, atípicos, fugas de información

Sin la pregunta, cada paso admite decenas de gráficos. **Con la pregunta, uno o dos.**

Roadmap

- 1 La pregunta que manda
- 2 El EDA de Cóndor, paso a paso
- 3 Lo que sale del EDA

Paso 1 · ¿Qué es una fila y cuántas hay?

Antes de cualquier cálculo, la regla cero del podcast — para las cuatro tablas del caso:

Tabla	Una fila es...	Filas	Trae
base_clientes	un cliente	8.000	demografía, RFM, app, crédito
anexo_transacciones	una transacción	185.582	monto, tipo, canal, fraude
anexo_creditos	una solicitud	4.071	score, plazo, mora
anexo_campanas	un envío	13.467	oferta, costo, conversión

- base_clientes: 8.000 filas, **8.000** cliente_id **distintos**, **0** duplicadas (unicidad: aprobada). 29 columnas. Corte: 31-mar-2026.
- **No creer: verificar.** El RFM de la base debería salir del anexo de transacciones. Se recalcula: frecuencia_tx y monto_total coinciden con el anexo en el **100 %** de los clientes. Consistencia: aprobada.

Paso 1 · ¿Qué es una fila y cuántas hay?

Antes de cualquier cálculo, la regla cero del podcast — para las cuatro tablas del caso:

Tabla	Una fila es...	Filas	Trae
base_clientes	un cliente	8.000	demografía, RFM, app, crédito
anexo_transacciones	una transacción	185.582	monto, tipo, canal, fraude
anexo_creditos	una solicitud	4.071	score, plazo, mora
anexo_campanas	un envío	13.467	oferta, costo, conversión

- base_clientes: 8.000 filas, **8.000** cliente_id **distintos**, **0 duplicadas** (unicidad: aprobada). 29 columnas. Corte: 31-mar-2026.
- **No creer: verificar.** El RFM de la base debería salir del anexo de transacciones. Se recalcula: frecuencia_tx y monto_total coinciden con el anexo en el **100 %** de los clientes. Consistencia: aprobada.

La decisión del paso

La unidad de la pregunta es **el cliente** $\Rightarrow$ la base analítica tendrá 8.000 filas. Lo que venga de un anexo se **agrega** al nivel de cliente *antes* de unirlo.

Paso 2 · ¿Qué falta y por qué falta?

Tres columnas traen vacíos — y las tres tienen explicación exacta:

Columna	Faltantes	¿A quién le falta? (coincidencia exacta)
duracion_sesion_promedio	855	a los 855 clientes sin sesiones en 30 días
csat_promedio	5.279	a los 5.279 que nunca abrieron un ticket
score_buro	5.279	a los 5.279 que nunca pidieron crédito

- No son huecos: son **“no aplica”**. La pregunta del podcast — *¿por qué falta?* — aquí la responde el diccionario de datos, y la respuesta es determinística.
- Imputar sería inventar: una mediana de satisfacción para quien nunca llamó a soporte es una **opinión que nadie dio**.

Paso 2 · ¿Qué falta y por qué falta?

Tres columnas traen vacíos — y las tres tienen explicación exacta:

Columna	Faltantes	¿A quién le falta? (coincidencia exacta)
duracion_sesion_promedio	855	a los 855 clientes sin sesiones en 30 días
csat_promedio	5.279	a los 5.279 que nunca abrieron un ticket
score_buro	5.279	a los 5.279 que nunca pidieron crédito

- No son huecos: son **“no aplica”**. La pregunta del podcast — *¿por qué falta?* — aquí la responde el diccionario de datos, y la respuesta es determinística.
- Imputar sería inventar: una mediana de satisfacción para quien nunca llamó a soporte es una **opinión que nadie dio**.

La decisión del paso (va al acta)


No se imputa. Se **marca**: `sin_sesiones`, `abrio_ticket` (y `tiene_credito` ya existe). El hecho de no tener sesiones es información para esta pregunta — lo veremos en el paso 5.

Paso 3 · ¿Cómo se ve el target?



- **1.772 de 8.000 = 22,15 %.**
Esa es la **tasa base**: el punto de comparación de todo lo que sigue.
- Desbalance moderado: la métrica del modelo *no* podrá ser la exactitud a secas (semana 10).
- **¿Qué es “activo”?** 886 clientes llevan **más de 90 días** sin transar; el 59,7 % de ellos ya está marcado como abandono. ¿Son “clientes activos hoy”?

Paso 3 · ¿Cómo se ve el target?





- **1.772 de 8.000 = 22,15 %.**
Esa es la **tasa base**: el punto de comparación de todo lo que sigue.
- Desbalance moderado: la métrica del modelo *no* podrá ser la exactitud a secas (semana 10).
- **¿Qué es “activo”?** 886 clientes llevan **más de 90 días** sin transar; el 59,7 % de ellos ya está marcado como abandono. ¿Son “clientes activos hoy”?

La decisión del paso



La definición de “activo” se acuerda **con Growth antes de modelar** (¿recencia $\leq$ 90 días?). El abismo semántico del podcast también existe *dentro* de la empresa.

Paso 4 · ¿Cómo se distribuyen las candidatas?



- Las dos tienen **cola larga a la derecha** y la media queda arrastrada: recencia, mediana **15** días vs. media **39**; monto total, mediana **\$417 mil** vs. media **\$610 mil**. “El cliente promedio transó hace 39 días” describe a muy pocos.

Paso 4 · ¿Cómo se distribuyen las candidatas?



- Las dos tienen **cola larga a la derecha** y la media queda arrastrada: recencia, mediana **15** días vs. media **39**; monto total, mediana **\$417 mil** vs. media **\$610 mil**. “El cliente promedio transó hace 39 días” describe a muy pocos.


La decisión del paso

Describir con **medianas y tramos**, no con promedios. Las comparaciones del paso 5 se hacen por tramos.

Paso 5 · ¿Quiénes abandonan más?


A más días sin transar, más abandono

tasa de abandono por tramo de recencia_dias



Quien no abre la app ya casi se fue

tasa de abandono por tramo de num_sesiones_ult30d




- Recencia: del **12,4 %** (transó esta semana) al **59,7 %** (más de 90 días).
Sesiones: del **56,5 %** (cero) al **2,2 %** (más de 20). La línea punteada es la tasa global: importa **cuánto se aleja** cada tramo.

Paso 5 · ¿Quiénes abandonan más?


A más días sin transar, más abandono

tasa de abandono por tramo de recencia_dias



Quien no abre la app ya casi se fue

tasa de abandono por tramo de num_sesiones_ult30d



- Recencia: del **12,4 %** (transó esta semana) al **59,7 %** (más de 90 días).
Sesiones: del **56,5 %** (cero) al **2,2 %** (más de 20). La línea punteada es la tasa global: importa **cuánto se aleja** cada tramo.


Hallazgo 1

El **comportamiento reciente** es la señal. Y el “faltante” del paso 2 — cero sesiones — resultó ser el grupo de mayor riesgo de toda la base.

Paso 6 · ¿Y lo que “debería” importar?


El canal por el que llegaron no cambia casi nada

misma escala que las figuras anteriores; línea: tasa global



Tampoco la ciudad: todas entre 20 % y 24 %

misma escala que las figuras anteriores; línea: tasa global




- Misma escala que la lámina anterior, a propósito. Canal: **21,1 a 23,9 %**; ciudad: **20,3 a 23,6 %**; género, sistema operativo, KYC y ocupación: todo entre 20 y 25 %. “Los de *influencer* se van más” es ruido alrededor de la tasa global.

Paso 6 · ¿Y lo que “debería” importar?


El canal por el que llegaron no cambia casi nada

misma escala que las figuras anteriores; línea: tasa global



Tampoco la ciudad: todas entre 20 % y 24 %

misma escala que las figuras anteriores; línea: tasa global



- Misma escala que la lámina anterior, a propósito. Canal: **21,1 a 23,9 %**; ciudad: **20,3 a 23,6 %**; género, sistema operativo, KYC y ocupación: todo entre 20 y 25 %. “Los de *influencer* se van más” es ruido alrededor de la tasa global.


Hallazgo 2 — un gráfico plano también es un hallazgo

La demografía y el canal **no discriminan**: la campaña se segmenta por comportamiento, no por ciudad ni por canal.

Paso 7 · ¿Las dos señales miden lo mismo?

Recencia y sesiones no miden lo mismo: se refuerzan

cero sesiones dispara el abandono aun con transacción reciente;
sin transar ni abrir la app, 3 de cada 4 se van




- Correlación recencia–sesiones: **−0,35**. Se parecen, pero no son lo mismo: con transacción de esta semana y **cero sesiones**, el abandono ya es del 35 %; sin transar en 90 días y sin sesiones, **74 %**; con más de 10 sesiones nunca pasa del 7 %.

La decisión del paso

Las dos señales entran a la base analítica; la campaña ya sabe a quién ir primero (arriba a la izquierda).

Paso 8 · ¿Qué aporta un anexo? Agregar y luego unir




El grano, en vivo:

- anexo_campanas: 13.467 envíos a 6.386 clientes.
- Se **agrega** por cliente (n_campanas, n_convertidas) y *después* se une a la base: siguen siendo **8.000 filas**.
- Unido **sin agregar**: **15.081 filas**. Clientes duplicados, totales inflados, y R no dice nada.
- 1.614 clientes nunca recibieron campaña: tras el join quedan en NA → se vuelven 0 y se documenta.

Paso 8 · ¿Qué aporta un anexo? Agregar y luego unir

Quien respondió alguna campaña abandona la mitad
anexo_campanas agregado por cliente y unido a base_clientes




El grano, en vivo:

- anexo_campanas: 13.467 envíos a 6.386 clientes.
- Se **agrega** por cliente (n_campanas, n_convertidas) y *después* se une a la base: siguen siendo **8.000** filas.
- Unido **sin agregar**: **15.081** filas. Clientes duplicados, totales inflados, y R no dice nada.
- 1.614 clientes nunca recibieron campaña: tras el join quedan en NA → se vuelven 0 y se documenta.

Hallazgo 3 — con letra pequeña


Quien respondió alguna campaña abandona el **12,3 %** frente al **24,1 %**. Pero es **correlación**: ¿la campaña retiene, o los clientes fieles responden más? Es una hipótesis para el modelo, no una conclusión para Growth.

Paso 9 · ¿Qué raro quedó — y qué *no* puedo usar?



- La regla del IQR marca **886 clientes (11 %)**. En una cola larga, “atípico” no significa “error”: significa que la regla no aplica.
- El máximo, **\$44,1 millones**: se mira la fila completa. Cliente de **1 mes**, **72 transacciones**, transó ayer, 15 sesiones. No es un dedo de más: es un cliente que despegó. **Se conserva y se reporta.**

Paso 9 · ¿Qué raro quedó — y qué *no* puedo usar?



- La regla del IQR marca **886 clientes (11 %)**. En una cola larga, “atípico” no significa “error”: significa que la regla no aplica.
- El máximo, **\$44,1 millones**: se mira la fila completa. Cliente de **1 mes**, **72 transacciones**, transó ayer, 15 sesiones. No es un dedo de más: es un cliente que despegó. **Se conserva y se reporta.**

La fuga de información (la regla de oro del caso)

gasto_proximo_trim “predice” el abandono de maravilla: mediana de \$105 mil en quienes se quedan y \$23 mil en quienes se van. Claro: **es el futuro**, se conoce después del corte igual que abandono. Nunca entra como predictor. Cuando una variable predice demasiado bien, sospechen de esto.

Roadmap

- 1 La pregunta que manda
- 2 El EDA de Cóndor, paso a paso
- 3 Lo que sale del EDA

El EDA de hoy, en una lámina

Hallazgos (con número)

- 1 22 % de los clientes se vuelve inactivo; el comportamiento reciente separa tasas del 5 % al 74 %.
- 2 Demografía, ciudad y canal no discriminan: todo entre 20 y 25 %.
- 3 Quien respondió alguna campaña abandona la mitad (12 vs. 24 %).

Hipótesis para el modelo

- Priorizar la reactivación en **cero sesiones y más de 30 días sin transar**: 587 clientes con tasas del 46 al 74 %.
- La respuesta a campañas puede ser causa o síntoma: señal, no palanca.

Decisiones (el acta)

- Faltantes = “no aplica” → indicadores; nada se imputa.
- Definir “activo” con Growth (¿recencia $\leq$ 90 días?) antes de modelar.
- Fuera de la base analítica: `gasto_proximo_trim` (es del futuro).
- Anexos: agregar por cliente antes de unir; verificar que sigan 8.000 filas.
- El máximo de \$44,1 M se conserva y se reporta.

La base analítica

8.000 filas $\times$ lo que la pregunta necesita: target, recencia, sesiones, RFM, indicadores derivados y campañas agregadas.

Qué produce un EDA — y qué no

Lo de hoy, generalizado. De cualquier EDA hecho **con una pregunta** se sale con cuatro cosas:

- 1 **Hallazgos con número**, en lenguaje de negocio: “los clientes sin sesiones en 30 días abandonan el 56 %” — no “la variable sesiones es significativa”.
- 2 **Hipótesis** para el modelo: qué señales prometen, cuáles salieron planas y qué habría que confirmar.
- 3 **Decisiones documentadas** (el acta): qué se hizo con los faltantes y los extremos, qué columnas se derivaron y cuáles se excluyeron — con el porqué.
- 4 **Una base analítica** lista: una fila por unidad de análisis, con lo que la pregunta necesita y sin lo que se conoce después del corte.

Qué produce un EDA — y qué no

Lo de hoy, generalizado. De cualquier EDA hecho **con una pregunta** se sale con cuatro cosas:

- 1 **Hallazgos con número**, en lenguaje de negocio: “los clientes sin sesiones en 30 días abandonan el 56 %” — no “la variable sesiones es significativa”.
- 2 **Hipótesis** para el modelo: qué señales prometen, cuáles salieron planas y qué habría que confirmar.
- 3 **Decisiones documentadas** (el acta): qué se hizo con los faltantes y los extremos, qué columnas se derivaron y cuáles se excluyeron — con el porqué.
- 4 **Una base analítica** lista: una fila por unidad de análisis, con lo que la pregunta necesita y sin lo que se conoce después del corte.

Y con lo que no se sale

Ni con la respuesta a la pregunta de negocio, ni con un modelo, ni con un catálogo de gráficos: hoy fueron nueve pasos y diez figuras para 29 columnas. Si una figura no acerca a la decisión, no va.