

Analítica para los negocios

06327-ECO

Semana 6: El EDA de Cóndor — conocer los datos antes de modelar

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

8 de septiembre de 2026

Objetivo de la sesión

Hacer, con los datos de Cóndor, el primer análisis exploratorio que pide una pregunta de negocio.

- Ver el razonamiento del analista paso a paso: qué se pregunta, qué mira y qué decide.
- Los datos están limpios: no se arregla nada, se entiende.
- Terminar con lo que sale de un EDA: hallazgos, hipótesis, decisiones y una base lista para modelar.

La regla de la sesión

El EDA no responde la pregunta de negocio: la prepara.

Previously...

- **Semana 5.** El proceso analítico: de una necesidad a una pregunta de negocio. Cada equipo formuló la suya sobre Cóndor.
- **El podcast de esta semana.** Fuentes de datos, las cuatro dimensiones de la calidad, faltantes, atípicos y qué es (y qué no es) un EDA.

Roadmap

1 Contexto

2 El EDA, paso a paso

3 Lo que nos llevamos

Contexto: la pregunta de Growth y sus datos

Growth quiere saber qué clientes activos se volverán inactivos el próximo trimestre, para enfocar su campaña de retención. Hoy la campaña va a ciegas.

Antes de modelar hay que conocer los datos: cuatro tablas unidas por `cliente_id`.

- `base_clientes`: un cliente por fila, con su comportamiento y el target abandono.
- `anexo_transacciones`: cada transacción.
- `anexo_creditos`: cada solicitud de crédito.
- `anexo_campanas`: cada envío de una campaña.

Lo que la pregunta le pide al EDA: entender la base, encontrar las señales del abandono y separar lo que no se puede usar.

Paso 1 · ¿Qué es una fila y qué falta?


Tabla	Una fila es...	Filas
base_clientes	un cliente	8.000
anexo_transacciones	una transacción	185.582
anexo_creditos	una solicitud	4.071
anexo_campanas	un envío	13.467

- **No creer: verificar.** La frecuencia de la base coincide con el anexo de transacciones en el 100 % de los clientes.
- **Tres columnas con vacíos**, exactamente en quienes no aplica: duración de sesión (855 sin sesiones), satisfacción (5.279 sin tickets) y score de buró (5.279 sin crédito).

Lo que importa

La unidad es el cliente: lo que venga de un anexo se agrega antes de unir. Y los vacíos son «no aplica»: no se imputan.

Paso 2 · ¿Cómo se ve el target?





- **1.772 de 8.000: 22,15 %.** Es la tasa base, el punto de comparación de todo lo que sigue.
- **¿Qué es «activo»?** 886 clientes llevan más de 90 días sin transar, y el 59,7 % de ellos ya figura como abandono.

Lo que importa

La definición de «activo» se acuerda con Growth antes de modelar.

Paso 3 · ¿Cómo se distribuyen las candidatas?



Las dos tienen cola larga a la derecha: recencia, mediana de 15 días y media de 39; monto total, mediana de \$417 mil y media de \$610 mil.


Lo que importa

Con colas largas, la media describe a muy pocos: se resume con medianas y se compara por tramos.

Paso 4 · ¿Quiénes abandonan más?


A más días sin transar, más abandono

tasa de abandono por tramo de recencia · punteada: tasa global



Quien no abre la app ya casi se fue

tasa de abandono por tramo de sesiones · punteada: tasa global




Por recencia, del 12,4 % (transó esta semana) al 59,7 % (más de 90 días). Por sesiones, del 56,5 % (cero) al 2,2 % (más de 20).

Paso 4 · ¿Quiénes abandonan más?


A más días sin transar, más abandono

tasa de abandono por tramo de recencia · punteada: tasa global



Quien no abre la app ya casi se fue

tasa de abandono por tramo de sesiones · punteada: tasa global




Por recencia, del 12,4 % (transó esta semana) al 59,7 % (más de 90 días). Por sesiones, del 56,5 % (cero) al 2,2 % (más de 20).

Lo que importa


El comportamiento reciente es la señal. Y el «faltante» del paso 1, cero sesiones, resultó ser el grupo de mayor riesgo.

Paso 5 · ¿Y lo que «debería» importar?

El canal de llegada no cambia casi nada
misma escala que la figura de recencia · punteada: tasa global



Tampoco la ciudad: todas entre 20 % y 24 %
misma escala que la figura de recencia · punteada: tasa global




Misma escala que el paso anterior, a propósito. Canal: del 21,1 al 23,9%; ciudad: del 20,3 al 23,6 %.

Lo que importa

Un gráfico plano también es un hallazgo: la campaña se enfoca por comportamiento, no por ciudad ni por canal.

Paso 6 · ¿Las dos señales miden lo mismo?




- Correlación de $-0,35$: se parecen, pero no son lo mismo.
- Con cero sesiones, aun transando esta semana, se va el 35 %.
- Sin transar en 90 días y sin sesiones, el 74 %.
- Con más de 10 sesiones, nunca más del 7 %.

Lo que importa


Las dos señales se complementan. A quién ir primero está arriba a la izquierda del mapa.

Paso 7 · ¿Qué aporta un anexo? Agregar y luego unir



- Las campañas traen una fila por envío: 13.467 envíos a 6.386 clientes.
- Unidas sin agregar: **15.081 filas**. Clientes duplicados, y R no avisa.
- Agregadas por cliente y después unidas: siguen siendo **8.000**.

Paso 7 · ¿Qué aporta un anexo? Agregar y luego unir




- Las campañas traen una fila por envío: 13.467 envíos a 6.386 clientes.
- Unidas sin agregar: **15.081 filas**. Clientes duplicados, y R no avisa.
- Agregadas por cliente y después unidas: siguen siendo **8.000**.

Lo que importa

Quien respondió alguna campaña abandona el 12,3 %; quien la recibió sin responder, el 24,1 %. Es una correlación: ¿la campaña retiene, o los clientes fieles responden más? Es una hipótesis, no una conclusión.

Paso 8 · ¿Qué raro quedó y qué no se puede usar?



- La regla del IQR marca al 11 % de la base: en una cola larga, atípico no significa error.
- El máximo, \$44,1 millones: un cliente de un mes, con 72 transacciones, que transó ayer. Se conserva y se reporta.

Lo que importa: la fuga de información

`gasto_proximo_trim` «separa» muy bien (\$105 mil frente a \$23 mil de mediana) porque es del futuro: se conoce después del corte. Nunca entra como predictora.

Lo que nos llevamos

La idea de hoy

Un EDA con pregunta no produce un catálogo de gráficos: produce hallazgos con número, hipótesis y decisiones.

- **Hallazgos:** el comportamiento reciente separa (del 5 al 74 % de abandono); la demografía y el canal, no (del 20 al 25 %).
- **Hipótesis para Growth:** empezar por los 587 clientes con cero sesiones y más de 30 días sin transar, que abandonan entre el 46 y el 74 %.
- **El acta:** los vacíos son «no aplica» y no se imputan; los anexos se agregan antes de unir; `gasto_proximo_trim` queda fuera; el máximo se conserva.

Ahora, con el monitor: `corran 06_eda_condor.R`, que sigue estos mismos pasos con sus propias salidas. **El taller** está al final del script: el EDA de la pregunta de su equipo, que se sube a Intu antes de terminar la clase.