Analítica para los negocios
06327-ECO

Semana 11: De evaluar a entrenar — el primer árbol de la casa

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

13 de octubre de 2026

Objetivo de la sesión

La pregunta de negocio

¿A qué clientes debe enviarles Growth la campaña de retención?

La semana pasada la respondimos con modelos de otros. Hoy entrenamos el nuestro:

- Elegir con qué variables aprende y con qué clientes se califica.
- Leer el árbol que sale: qué pregunta y a quién señala.
- Decidir, con las métricas y el dinero de la semana 10, si Growth lo adopta.

Hoy sí se entrena un modelo — y se califica igual que la semana pasada: con clientes que no vio.

Previously. . .

- **Semana 6: el EDA.** El comportamiento reciente separa a quienes se van: la recencia y las sesiones mueven el abandono del 12 al 60 %; la ciudad y el canal, no.
- **Semana 10: el juez de modelos.** Dos proveedores contra la línea base «no enviarle la campaña a nadie» (accuracy 0.779 sin encontrar a ninguno de los 354). El proveedor A encontraba 77 a \$3.214 cada uno; la decisión dependió de cuánto vale un cliente encontrado.
- **La teoría de esta semana.** Un árbol aprende haciendo preguntas a los datos: en cada paso elige el corte que mejor separa, y la profundidad controla cuánto memoriza.

Roadmap

1. Contexto

2. El árbol de la casa: de los datos a la decisión

Contexto: ¿por qué entrenar un modelo propio?

Tras el ejercicio de la semana pasada, la gerencia hizo la pregunta natural: **¿y si el modelo lo hacemos nosotros?** Un modelo propio no cobra por lista, se puede examinar pregunta por pregunta y se reentrena cuando cambien los datos.

Las opciones de hoy:

- **La línea base de siempre**: no enviarle la campaña a nadie. No cuesta nada y no encuentra a nadie.
- **El árbol de la casa**: un árbol de decisión entrenado con los datos de Cóndor.

Las preguntas de hoy

¿Qué aprende un árbol con los datos de Cóndor? ¿Le gana a la línea base — y a qué costo?

¿Con qué aprende el árbol?

Dos reglas para elegir las variables:

- Que **existan el día de la decisión**: nada que se conozca después, como `dias_mora` o `gasto_proximo_trim` (la fuga de la semana 6).
- Que **no tengan vacíos**: el árbol necesita un valor para cada cliente.

Variable	Qué mide	Por qué entra
`recencia_dias`	días desde la última transacción	la señal más fuerte del EDA
`num_sesiones_ult30d`	uso de la app en el último mes	del 56 al 2 % de abandono
`frecuencia_tx`	transacciones por trimestre	mide el hábito de uso
`antiguedad_meses`	meses como cliente	la relación acumulada
`gasto_promedio_mensual`	gasto típico mensual	el tamaño de la relación

Lo que importa

El target es `abandono` (1 = se fue). Cinco señales de comportamiento, las mismas que el EDA mostró que separan.

El sobre: unos clientes para aprender, otros para calificar

Lo que queremos del árbol es que **generalice**: que aprenda el patrón del abandono, no que se memorice la respuesta de cada cliente. Y eso solo se comprueba con clientes que no vio: si se califica con los mismos con los que aprendió, el examen trae las respuestas vistas y la nota sale inflada.

8.000 clientes

sorteo 80 / 20 $\longrightarrow$

6.400 entrenan: el árbol ve qué hicieron y si se fueron

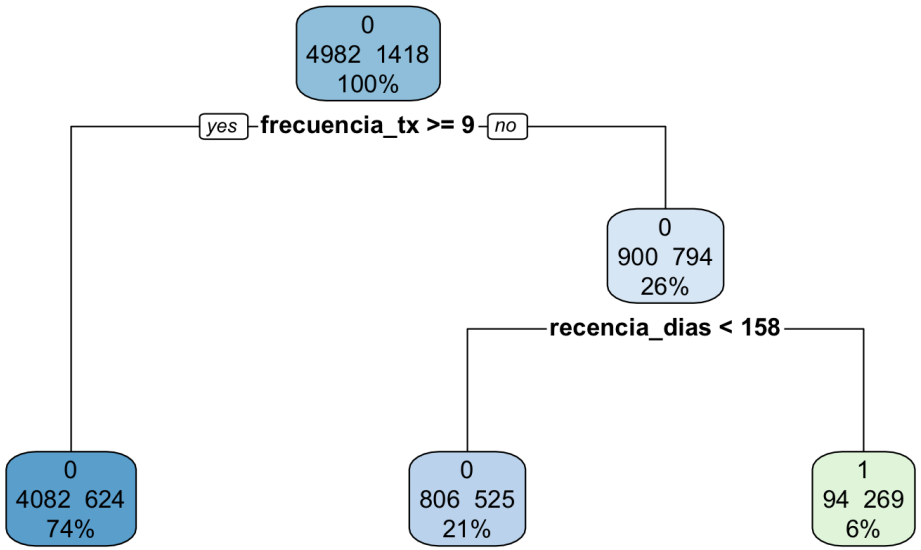
1.600 califican: el árbol no los ve al entrenar

De los 1.600 del sobre, **354 se fueron** y 1.246 se quedaron. Son **los mismos 1.600 que calificaron a los proveedores** la semana pasada: la vara no cambió.

Lo que importa

La nota del árbol se mide solo en el sobre: ahí se ve si generalizó o si memorizó. Entrenar es estudiar; el sobre es el examen.

El árbol entrenado: dos preguntas



El árbol quedó con **2 nodos de decisión y 3 hojas**. Cada caja es un grupo de clientes:

- arriba, la clase que predice (**1 = se va**);
- en el medio, **cuántos se quedaron y cuántos se fueron** (ceros | unos);
- abajo, qué % de los clientes cae ahí.

Solo la hoja «**transa poco y lleva 158 días o más**» recibe la predicción «se va»: 94 se quedaron, 269 se fueron.

Lo que importa

De las cinco variables, el árbol usó dos: frecuencia y recencia. Las demás no mejoraban la separación lo suficiente para ganarse una pregunta.

¿Acertó el árbol, cliente por cliente?

Cliente	Frec.	Rec.	Predicción	¿Se fue?	Res.
3000122	1	215	se va	sí	**TP**
3000182	1	205	se va	sí	**TP**
3000357	3	170	se va	sí	**TP**
3000077	3	266	se va	no	**FP**
3000099	1	188	se va	no	**FP**
3000149	6	358	se va	no	**FP**
3000027	3	131	se queda	sí	**FN**
3000030	13	24	se queda	sí	**FN**
3000050	22	15	se queda	sí	**FN**
3000003	22	6	se queda	no	TN
3000004	14	1	se queda	no	TN
3000007	21	6	se queda	no	TN

Doce clientes del test: tres de cada casilla.

Totales en los 1.600: **59 TP**, **17 FP**, **295 FN**, 1.229 TN.

Los TP y los FP tienen el perfil que el árbol señala: poca frecuencia, mucha recencia.

Los FN duelen: el 3000030 y el 3000050 transaban seguido y se fueron sin que estas señales avisaran — la semana pasada tampoco los vio el proveedor A.

¿Acertó el árbol, cliente por cliente?

Cliente	Frec.	Rec.	Predicción	¿Se fue?	Res.
3000122	1	215	se va	sí	**TP**
3000182	1	205	se va	sí	**TP**
3000357	3	170	se va	sí	**TP**
3000077	3	266	se va	no	**FP**
3000099	1	188	se va	no	**FP**
3000149	6	358	se va	no	**FP**
3000027	3	131	se queda	sí	**FN**
3000030	13	24	se queda	sí	**FN**
3000050	22	15	se queda	sí	**FN**
3000003	22	6	se queda	no	TN
3000004	14	1	se queda	no	TN
3000007	21	6	se queda	no	TN

Doce clientes del test: tres de cada casilla.

Totales en los 1.600: **59 TP**, **17 FP**, **295 FN**, 1.229 TN.

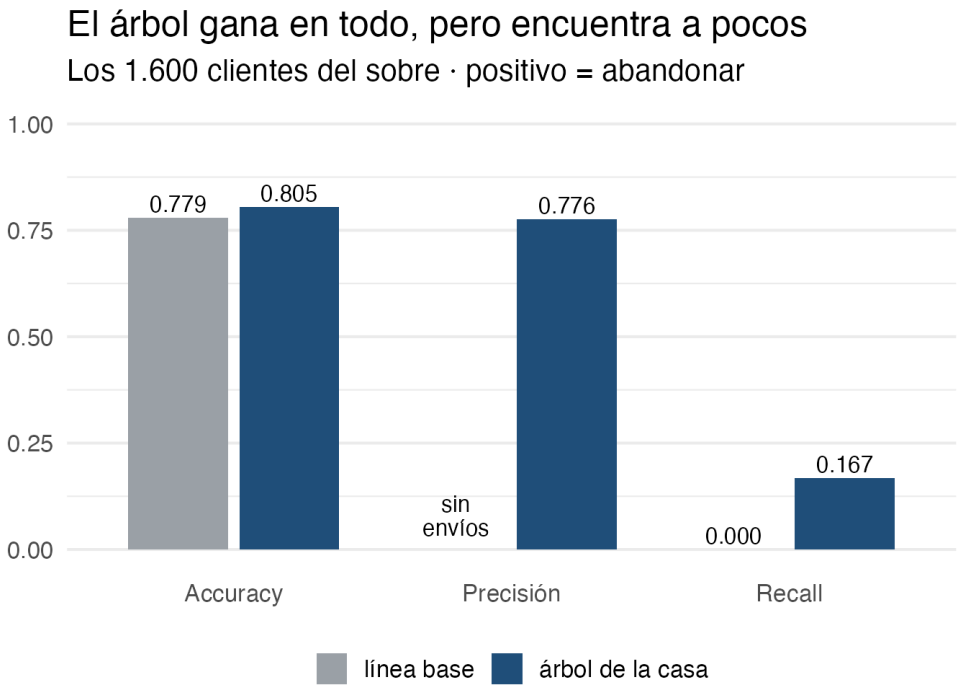
Los TP y los FP tienen el perfil que el árbol señala: poca frecuencia, mucha recencia.

Los FN duelen: el 3000030 y el 3000050 transaban seguido y se fueron sin que estas señales avisaran — la semana pasada tampoco los vio el proveedor A.

Lo que importa

El árbol solo encuentra el abandono que se parece a sus preguntas: 295 de los 354 se van por caminos que estas cinco señales no ven.

Tres métricas, las de la semana pasada



- **Accuracy**: 0.805 contra 0.779. Gana, pero la línea base ya acertaba mucho: con 22 % de abandono, acertar no es difícil.
- **Precisión**: 0.776. De cada 4 envíos, 3 van a alguien que de verdad se iba (el proveedor A lograba 0.700).
- **Recall**: 0.167. Encuentra a 59 de los 354; se le escapan 295.

Lo que importa

Mejor que la línea base en todo — pero «mejor» no dice todavía si el negocio paga. Eso lo decide el costo.

¿Cómo se calcula el costo de la lista del árbol?

Con las casillas de la lámina 8 y \$2.250 por envío, en cuatro pasos:

Paso	Línea base	Árbol de la casa
1. Envíos TP + FP	$0 + 0$ $= \mathbf{0}$	$59 + 17$ $= \mathbf{76}$
2. Costo envíos $\times$ \$2.250	0×2.250 $= \mathbf{\$0}$	76×2.250 $= \mathbf{\$171.000}$
3. Encontrados TP	**0**	**59**
4. Por encontrado costo $\div$ encontrados	$0 \div 0$ no aplica	$171.000 \div 59$ $= \mathbf{\$2.898}$

Lo que importa

Cada envío cuesta lo mismo, acierte o no; como 3 de cada 4 aciertan, cada encontrado sale en \$2.898 — más barato que los \$3.214 del proveedor A.

La recomendación: ¿Growth adopta el árbol?

Encontrar no es retener: cada cliente encontrado vale **la fracción que la campaña retiene** $\times$ **lo que deja un cliente retenido** ($40.000, cifras ilustrativas).

Escenario	**Vale c/u** *1.*	**2. Valor** *encontrados* $\times$ *valor*	**3. Costo** *lámina 10*	**4. Neto** *valor* $-$ *costo*
Retiene 1 de cada 10	$4.000	$59 \times 4.000 = \$236.000$	$171.000	$+$**$65.000**
Retiene 1 de cada 20	$2.000	$59 \times 2.000 = \$118.000$	$171.000	$-$**$53.000**
No enviar a nadie	—	$0	$0	$0

La recomendación: ¿Growth adopta el árbol?

Encontrar no es retener: cada cliente encontrado vale **la fracción que la campaña retiene** $\times$ **lo que deja un cliente retenido** ($40.000, cifras ilustrativas).

Escenario	**Vale c/u** *1.*	**2. Valor** *encontrados* $\times$ *valor*	**3. Costo** *lámina 10*	**4. Neto** *valor* $-$ *costo*
Retiene 1 de cada 10	$4.000	$59 \times 4.000 = \$236.000$	$171.000	$+$**$65.000**
Retiene 1 de cada 20	$2.000	$59 \times 2.000 = \$118.000$	$171.000	$-$**$53.000**
No enviar a nadie	—	$0	$0	$0

La recomendación

Si la campaña retiene al menos 1 de cada 10, el árbol se adopta: deja $65.000 más que no hacer nada. Si solo retiene 1 de cada 20, mejor no enviar. La frontera es **$2.898**: lo que cuesta encontrar a cada cliente.