

Analítica para los negocios

06327-ECO

Semana 11: El torneo de clasificadores — ¿quién se va de Cóndor?

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

[fecha por definir]

Objetivo de la sesión

La semana pasada se juzgaron reglas escritas a mano. Hoy la máquina **escribe sus propias reglas** — y compite contra la del EDA, en el mismo sobre sellado.

- Un árbol de dos preguntas, comprobado a mano.
- El árbol sin frenos y la poda: la validación cruzada como juez que no abre el sobre.
- Quinientos árboles votando, su juez gratis y su perilla.
- Toda cifra del examen, con su margen.

La idea que gobierna la sesión

El mejor modelo no es el que más acierta en general, sino el que **mejor sirve a la decisión**: a quién llama Growth con el cupo que tiene.

¿Dónde estamos en el curso?

- **Semana 6:** el EDA — recencia y sesiones separan a los que se van.
- **Semana 10:** el juicio — la regla del EDA encuentra a 151 de 354 con 278 llamadas; en accuracy empata con no hacer nada.
- **Semana 11 (hoy):** el entrenamiento — árboles y bosques, con la tabla del líder de la semana 10 como vara.

Lo que cambia hoy

Las reglas ya no las escribe el analista: las aprende el modelo, y la validación cruzada decide cuánto dejarlo aprender.

Roadmap

- 1 La vara y la base
- 2 El árbol
- 3 El bosque y la perilla
- 4 Lo que queda

Roadmap

1 La vara y la base

2 El árbol

3 El bosque y la perilla

4 Lo que queda

La pregunta de hoy, con presupuesto

La misión de Growth

“La regla del EDA encuentra a 151 de cada 354 clientes que se van. Tenemos cupo para unas **280 llamadas por cada 1.600 clientes**. ¿Un modelo entrenado encuentra más con ese cupo?”

La tabla del líder que dejó la semana 10 (test de 1.600; se van 354)

Regla	Llamadas	Encontrados	Accuracy
Nadie abandona	0	0	$0,779 \pm 0,021$
Regla del EDA	278	151	$0,794 \pm 0,020$
Memorizador	86	26	$0,757 \pm 0,021$

Paso 1 · ¿Con qué columnas se entrena?

De las 29 columnas de `base_clientes`, salen tres tipos:

Columna	Por qué sale	Criterio
<code>gasto_proximo_trim</code>	se conoce después del corte	fuga (semana 10)
<code>departamento</code>	12 ciudades, 12 combinaciones	repite a ciudad
<code>duracion_sesion_promedio</code>	vacía sin sesiones	ya está en las sesiones
<code>csat_promedio</code>	vacía sin tickets	ya está en los tickets
<code>score_buro</code>	vacía sin crédito	ya está en <code>tiene_credito</code>

Paso 1 · ¿Con qué columnas se entrena?

De las 29 columnas de `base_clientes`, salen tres tipos:

Columna	Por qué sale	Criterio
<code>gasto_proximo_trim</code>	se conoce después del corte	fuga (semana 10)
<code>departamento</code>	12 ciudades, 12 combinaciones	repite a ciudad
<code>duracion_sesion_promedio</code>	vacía sin sesiones	ya está en las sesiones
<code>csat_promedio</code>	vacía sin tickets	ya está en los tickets
<code>score_buro</code>	vacía sin crédito	ya está en <code>tiene_credito</code>

Hallazgo 1

Quedan **22 predictoras** y el mismo sobre de la semana 10 (6.400 en train, 1.600 en test): la comparación con la tabla del líder es justa. Y el bosque no acepta vacíos: los “no aplica” se resuelven con criterio, no con la media.

Roadmap


1 La vara y la base

2 El árbol

3 El bosque y la perilla


4 Lo que queda

Paso 2 · ¿Qué pregunta haría la máquina?




El primer corte del árbol, a mano

Tasa de abandono en train a cada lado de frecuencia_tx = 8,5 (punteada: tasa global)




- El árbol prueba todos los cortes de las 22 variables y se queda con el que más separa: **8 o menos transacciones** (47 % se va) contra **9 o más** (13%).
- En test: accuracy **0,805 ± 0,020**, pero solo 76 llamadas y 59 encontrados (recall **0,167 ± 0,040**).

Paso 2 · ¿Qué pregunta haría la máquina?



El primer corte del árbol, a mano

Tasa de abandono en train a cada lado de frecuencia_tx = 8,5 (punteada: tasa global)



- El árbol prueba todos los cortes de las 22 variables y se queda con el que más separa: **8 o menos transacciones** (47 % se va) contra **9 o más** (13%).
- En test: accuracy **0,805 ± 0,020**, pero solo 76 llamadas y 59 encontrados (recall **0,167 ± 0,040**).


Hallazgo 2

El árbol hace **solo** lo que se hizo a mano en la semana 6: comparar tasas por tramo. Repitió la recencia (158 días en vez de 90) y cambió sesiones por frecuencia. En accuracy empata con la regla del EDA; a Growth le sirve menos.

Paso 3 · ¿Cuánto árbol es demasiado árbol?

El dial de la semana 10, dibujado por la validación cruzada

Error relativo a no tener árbol, según el número de hojas (escala logarítmica)




El árbol sin frenos ($cp = 0,0001$, hojas de un cliente):

- **926 hojas**; train **100 %**; test **$0,729 \pm 0,022$** , por debajo de no hacer nada.
- La validación cruzada: de **1,00 a 0,89** con 2 cortes, y sube hasta **1,32**.
- Regla 1-SE: tope $0,89 + 0,02 = 0,91 \Rightarrow$ **3 hojas**.

Paso 3 · ¿Cuánto árbol es demasiado árbol?

El dial de la semana 10, dibujado por la validación cruzada

Error relativo a no tener árbol, según el número de hojas (escala logarítmica)



El árbol sin frenos ($c_p = 0,0001$, hojas de un cliente):

- 926 hojas; train 100 %; test $0,729 \pm 0,022$, por debajo de no hacer nada.
- La validación cruzada: de 1,00 a 0,89 con 2 cortes, y sube hasta 1,32.
- Regla 1-SE: tope $0,89 + 0,02 = 0,91 \Rightarrow$ 3 hojas.

Hallazgo 3

La poda devuelve **exactamente** el árbol de dos preguntas: la CV confirmó, sin abrir el sobre, que las otras 923 hojas compraban ruido.


Roadmap

- 1 La vara y la base
- 2 El árbol
- 3 El bosque y la perilla
- 4 Lo que queda

Paso 4 · ¿Qué gana el bosque votando?

Lo que más usa el bosque: el enganche del cliente

Importancia por defecto (disminución del Gini), las 10 primeras de 22




- 500 árboles sobre remuestras de train; en cada corte, 4 variables al azar.
- **Juez gratis** (fuera de la bolsa): error de 19,8 %, accuracy **0,802** sin abrir el sobre.
- Test: accuracy **0,809 ± 0,020** — la más alta del torneo.

Paso 4 · ¿Qué gana el bosque votando?

Lo que más usa el bosque: el enganche del cliente

Importancia por defecto (disminución del Gini), las 10 primeras de 22



- 500 árboles sobre remuestras de train; en cada corte, 4 variables al azar.
- **Juez gratis** (fuera de la bolsa): error de 19,8 %, accuracy **0,802** sin abrir el sobre.
- Test: accuracy **0,809 ± 0,020** — la más alta del torneo.


Hallazgo 4

El juez gratis y el examen coinciden. La accuracy más alta... **empata** con el árbol y con la regla del EDA. Lo que más usa el bosque es el enganche del cliente, lo mismo que encontró el EDA.

Paso 5 · ¿A quién llama Growth con su cupo?

Con el cupo de Growth, el bosque empata con la regla del EDA

Encontrados según el número de llamadas, en el test (1.600 clientes; se van 354)




- El bosque da una **probabilidad**; el umbral la vuelve decisión.
- Umbral 0,4: **288** llamadas, **159** encontrados.
- Regla del EDA: 278 llamadas, 151 encontrados, margen ± 19 .
- Umbral 0,3: 453 llamadas, 212 encontrados.

Paso 5 · ¿A quién llama Growth con su cupo?

Con el cupo de Growth, el bosque empata con la regla del EDA

Encontrados según el número de llamadas, en el test (1.600 clientes; se van 354)



- El bosque da una **probabilidad**; el umbral la vuelve decisión.
- Umbral 0,4: **288** llamadas, **159** encontrados.
- Regla del EDA: 278 llamadas, 151 encontrados, margen ± 19 .
- Umbral 0,3: 453 llamadas, 212 encontrados.


Hallazgo 5 — la lección de la semana

Con el cupo de Growth, **empate técnico**. Lo que compra el bosque es **la perilla**: ordena a los 1.600 por riesgo y deja fijar el cupo. El árbol podado no puede: su perilla salta en tres escalones.

Paso 5 · ¿Y son creíbles esas probabilidades?

El bosque aprendió la curva de la semana 6

Tasa real de abandono y probabilidad promedio del bosque, por recencia (test)



- Tasa real por tramo de recencia: de **12,2 %** a **60,1 %**. Probabilidad promedio del bosque: de **15,4 %** a **56,7 %** — nunca a más de 4 puntos.

La decisión del paso

Las probabilidades son creíbles y el bosque aprendió la curva de la semana 6: su riesgo sirve para decidir el cupo.

Roadmap

- 1 La vara y la base
- 2 El árbol
- 3 El bosque y la perilla
- 4 Lo que queda

La tabla del líder

Abandono (test de 1.600 clientes; se van 354)

Regla o modelo	Llamadas	Encontrados	Accuracy
Nadie abandona	0	0	$0,779 \pm 0,021$
Regla del EDA	278	151	$0,794 \pm 0,020$
Memorizador	86	26	$0,757 \pm 0,021$
Árbol de dos preguntas	76	59	$0,805 \pm 0,020$
Árbol sin frenos	344	132	$0,729 \pm 0,022$
Bosque, umbral 0,5	164	106	$0,809 \pm 0,020$
Bosque, umbral 0,4	288	159	$0,797 \pm 0,020$

La tabla del líder

Abandono (test de 1.600 clientes; se van 354)

Regla o modelo	Llamadas	Encontrados	Accuracy
Nadie abandona	0	0	$0,779 \pm 0,021$
Regla del EDA	278	151	$0,794 \pm 0,020$
Memorizador	86	26	$0,757 \pm 0,021$
Árbol de dos preguntas	76	59	$0,805 \pm 0,020$
Árbol sin frenos	344	132	$0,729 \pm 0,022$
Bosque, umbral 0,5	164	106	$0,809 \pm 0,020$
Bosque, umbral 0,4	288	159	$0,797 \pm 0,020$

La decisión

Nadie desbanca a la regla del EDA por más que el margen. El bosque entra como **colíder**: no porque acierte más, sino porque su riesgo ordena a todos los clientes.

Qué produce un torneo — y qué no

Produce

- Modelos elegidos por el juez (la CV), no por el examen.
- Un riesgo creíble para cada cliente.
- Una regla legible (el árbol) y un ordenador fino (el bosque).

No produce

- Causas: la importancia dice qué *usó* el bosque, no qué *causa* el abandono.
- Más señal que la que hay: con estos datos, el EDA ya había encontrado casi toda.
- Clientes que se van por razones que no están en la base.