Analítica para los negocios
06327-ECO

Semana 12: El árbol que predice números — ¿qué tan popular será una canción?

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

20 de octubre de 2026

Objetivo de la sesión

La pregunta de negocio

A SonoUrbano, un sello de música urbana, le ofrecen canciones para comprar. Para decidir cuáles, necesita pronosticar: ¿qué tan popular será cada una?

Por primera vez el target es **un número**, no una categoría — y los datos son **reales**: canciones que conoces.

- Entrenar un árbol que, con las características de la canción, pronostique su **popularidad** en Spotify (0–100: el índice que resume las reproducciones recientes).
- Medir el error **en puntos de popularidad** (MAE) contra la línea base del promedio.
- Convertir el pronóstico en la decisión: qué comprar y cuánto invertir en cada lanzamiento.

La herramienta es la de la semana pasada: cambia lo que guarda la hoja y cómo se mide el error.

Previously. . .

- **Semana 11: el primer árbol.** Entrenamos un árbol de clasificación con los frenos de fábrica de `rpart`: aprendió dos preguntas, encontró a 59 de los 354 que se iban y Growth decidió con costos si lo adoptaba.
- **El quiz de hoy.** Leímos árboles ya entrenados: cuántos casos caen en cada hoja, qué promedio predice y cómo se recorre el árbol con un caso nuevo.
- **La teoría de esta semana.** Cuando el target es un número, cada hoja guarda el promedio de su grupo y el error se mide en las unidades del target: el **MAE** es el error promedio por pronóstico.

Roadmap

1. Los datos y el sobre

2. Del árbol a la decisión

Los datos: 2.427 canciones urbanas, reales

La base pública de canciones de Spotify (proyecto TidyTuesday, enero de 2020), filtrada al género urbano — reggaeton y latin hip hop, sin duplicados —: **2.427 filas, una por canción**. El target es `popularidad` (0–100): el índice de Spotify que resume las reproducciones recientes.

Variable	**Qué mide**
`anio`	el año en que salió el álbum
`duracion_seg`	la duración, en segundos
`bailabilidad`	qué tan bailable es la canción (0–100)
`energia`	la intensidad de la pista (0–100)
`colaboracion`	1 si el título trae un *featuring*

`cancion` y `artista` identifican cada fila: en la base están Bad Bunny (24 canciones), J Balvin (37), Ozuna, Daddy Yankee... `subgenero` y `tempo` completan las 10 columnas.

Lo que importa

Las cinco predictoras se conocen desde el día del lanzamiento, antes de saber qué tan popular será la canción: no hay fuga. El artista **no** entra al árbol.

El sobre: unas canciones para aprender, otras para calificar

Queremos que el árbol **generalice** — que aprenda el patrón de la popularidad, no que se memorice sus 2.427 canciones. Eso solo se comprueba con canciones que no vio.

2.427 canciones

sorteo 80 / 20 $\longrightarrow$

1.942 entrenan: el árbol ve su popularidad

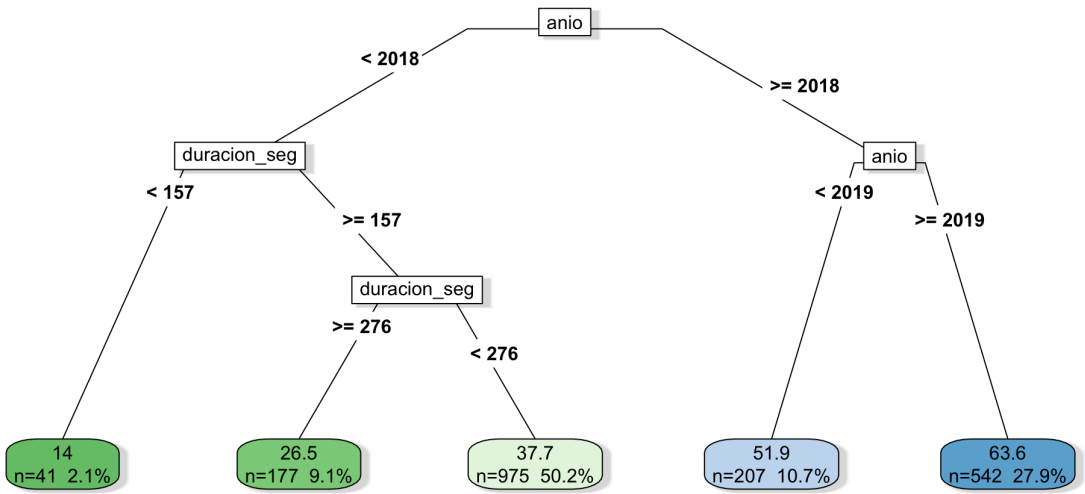
485 califican: el árbol no las ve al entrenar

En las 1.942 de entrenamiento, el promedio es **44.9 puntos de popularidad**: ese número es la línea base — pronosticárselo a todas.

Lo que importa

La nota del árbol se mide solo en las 485 del sobre: ahí se ve si generalizó o si memorizó.

El árbol entrenado: dos variables, cinco hojas



Cada caja: arriba, **la popularidad que predice** (el promedio de su grupo); abajo, cuántas canciones de entrenamiento caen ahí y qué % son.

Primero pregunta por el **año**: las de 2019 en adelante prometen **63.6**; las de 2018, 51.9. En el catálogo viejo manda la **duración**: menos de 157 segundos cae a 14; 276 o más, a 26.5; el resto queda en 37.7.

Lo que importa

De cinco variables usó dos: el año (dos veces) y la duración (dos veces). Ni la bailabilidad, ni la energía, ni el *featuring* ganaron una pregunta: **la popularidad de Spotify premia lo reciente**.

¿Cómo le fue, canción por canción?

Canción	Artista	Año	Dur. (seg)	Real	Pron.	Error
Me Gusta	Shakira	2020	191	79	63.6	15.4
Con Calma	Daddy Yankee	2019	193	87	63.6	23.4
Baila Baila Baila	Ozuna	2019	158	65	63.6	**1.4**
Felices los 4	Maluma	2018	230	76	51.9	24.1
Estamos Bien	Bad Bunny	2018	208	76	51.9	24.1
Gasolina	Daddy Yankee	2004	193	76	37.7	**38.3**
Bandoleros	Don Omar	2006	305	67	26.5	40.5
Te Suelto el Pelo	Yandel	2003	136	55	14.0	41.0

Ocho canciones del test; popularidad de 0 a 100.

Cada canción cae en una hoja y recibe su promedio: cinco pronósticos distintos. A *Baila Baila Baila* casi le atina (1.4). Y Daddy Yankee cae en dos hojas: *Con Calma* (2019) en la de 63.6 y *Gasolina* (2004) en la de 37.7 — el árbol no sabe quién canta: pregunta el año. Por eso con los clásicos que siguen sonando (*Gasolina*, *Bandoleros*, *Te Suelto el Pelo*) se queda corto por 38–41 puntos.

En regresión la pregunta no es «¿acertó?» sino **«¿por cuánto se equivocó?»** — y eso se promedia.

¿Cómo se calcula el MAE?

Con las ocho canciones de la lámina anterior, en tres pasos:

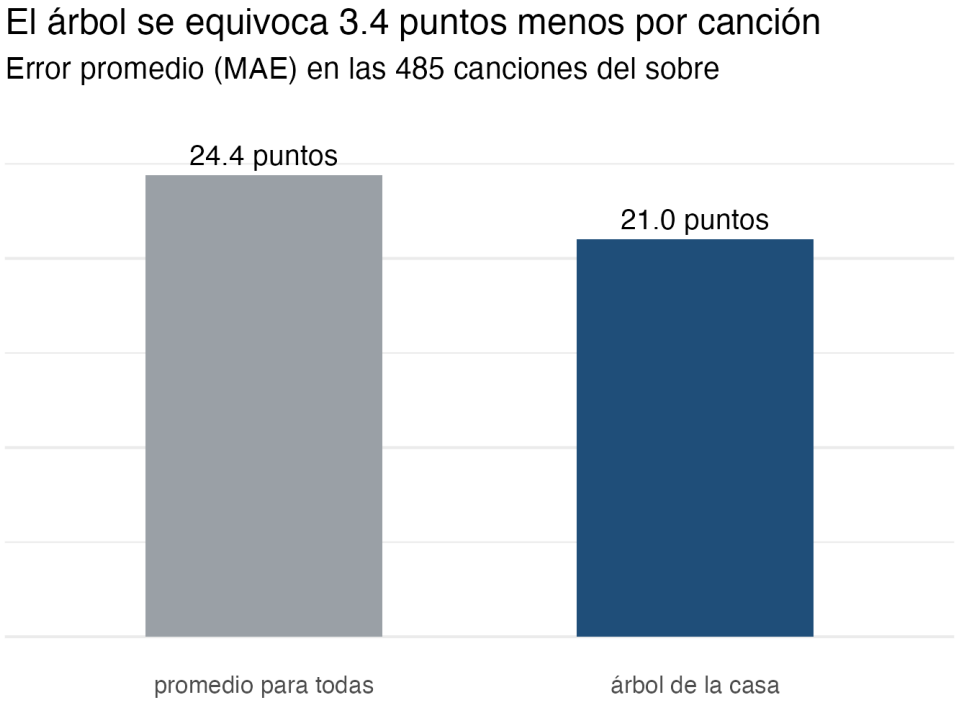
Paso	Con las 8 de la lámina 7
1. El error absoluto de cada una |pronóstico − real|	15.4; 23.4; 1.4; 24.1; 24.1; 38.3; 40.5; 41.0
2. Súmalos	$15.4 + 23.4 + \cdots + 41.0$ $= \mathbf{208.2\ puntos}$
3. Divide entre las canciones	$208.2 \div 8$ $= \mathbf{26.0\ puntos}$

La misma cuenta con las **485 canciones del sobre** — ya no solo éxitos conocidos —: el árbol se equivoca **21.0 puntos** por canción; el promedio, **24.4 puntos**.

Lo que importa

El MAE del árbol sale de la misma cuenta que acabas de hacer a mano — solo que sobre 485 canciones.

¿El árbol le gana al promedio?



- **La línea base**: pronosticar 44.9 puntos a todas se equivoca **24.4 puntos** por canción.
- **El árbol**: con el año y la duración, el error baja a **21.0 puntos**: 3.4 menos por canción, un 14 % menos.
- Con ese pronóstico, SonoUrbano prioriza: una canción que cae en la hoja de 63.6 no se lanza igual que una en la de 14.

Lo que importa

La vara de la regresión es el promedio: el árbol le gana por **3.4 puntos por canción**. Pero el negocio no es el error promedio: es **elegir cuáles comprar**.

¿Cuánto vale el pronóstico? La decisión de compra

SonoUrbano va a comprar **20 canciones**, y cada punto de popularidad que consigan vale $1 millón de pesos por canción (cifra ilustrativa). Sin modelo compra al azar: el promedio le pronostica lo mismo a todas y no distingue. Con el árbol, compra de la **hoja de 63.6**.

Paso	**Al azar**	**Con el árbol**
1. ¿Cuáles 20 compra?	cualquiera del catálogo	las de la hoja de 63.6
2. Popularidad real que consigue promedio por canción, en el test	46.6	66.0
3. Valor del lote real × $1 millón × 20	46.6×20 = **$932 M**	66.0×20 = **$1.320 M**

La recomendación

El lote elegido con el árbol vale **$388 millones más** (1.320 − 932): $19.4 millones más por canción. Adoptarlo — y para atinarle a los éxitos uno a uno, conseguir la variable que falta: **el artista**.