Analítica para los negocios
06327-ECO

Semana 12: El árbol que predice números — ¿cuántas reproducciones logrará una canción?

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

20 de octubre de 2026

Objetivo de la sesión

La pregunta de negocio

A SonoUrbano, un sello de música urbana, le ofrecen canciones para comprar. Para decidir cuáles, necesita pronosticar: ¿cuántas reproducciones logrará cada una?

Por primera vez el target es **un número**, no una categoría:

- Entrenar un árbol que, con las características de la canción, pronostique sus **reproducciones** (en millones).
- Medir el error **en millones de reproducciones** (MAE) contra la línea base del promedio.
- Convertir el pronóstico en la decisión: qué comprar y cuánto invertir en cada canción.

La herramienta es la de la semana pasada: cambia lo que guarda la hoja y cómo se mide el error.

Previously. . .

- **Semana 11: el primer árbol.** Entrenamos un árbol de clasificación con los frenos de fábrica de `rpart`: aprendió dos preguntas, encontró a 59 de los 354 que se iban y Growth decidió con costos si lo adoptaba.
- **El quiz de hoy.** Leímos árboles ya entrenados: cuántos casos caen en cada hoja, qué promedio predice y cómo se recorre el árbol con un caso nuevo.
- **La teoría de esta semana.** Cuando el target es un número, cada hoja guarda el promedio de su grupo y el error se mide en las unidades del target: el **MAE** es el error promedio por pronóstico.

Roadmap

1. Los datos y el sobre

2. Del árbol a la decisión

Los datos: 50.000 canciones urbanas

Una base al estilo Spotify, solo de género urbano: **50.000 filas, una por canción, y 7 columnas**. El target es `reproducciones` (millones); las predictoras describen cada canción:

Variable	Qué mide
`bailabilidad`	qué tan bailable es la canción (0–100)
`energia`	la intensidad de la pista (0–100)
`bpm`	el tempo, en golpes por minuto
`duracion_seg`	la duración, en segundos
`colaboracion`	1 si la canción tiene un *featuring*

Lo que importa

Las cinco existen el día del lanzamiento: se conocen antes de saber cuántas reproducciones logrará la canción. No hay fuga.

El sobre: unas canciones para aprender, otras para calificar

Queremos que el árbol **generalice** — que aprenda el patrón de las reproducciones, no que se memorice sus 50.000 canciones. Eso solo se comprueba con canciones que no vio.

50.000 canciones

sorteo 80 / 20 $\longrightarrow$

40.000 entrenan: el árbol ve sus reproducciones

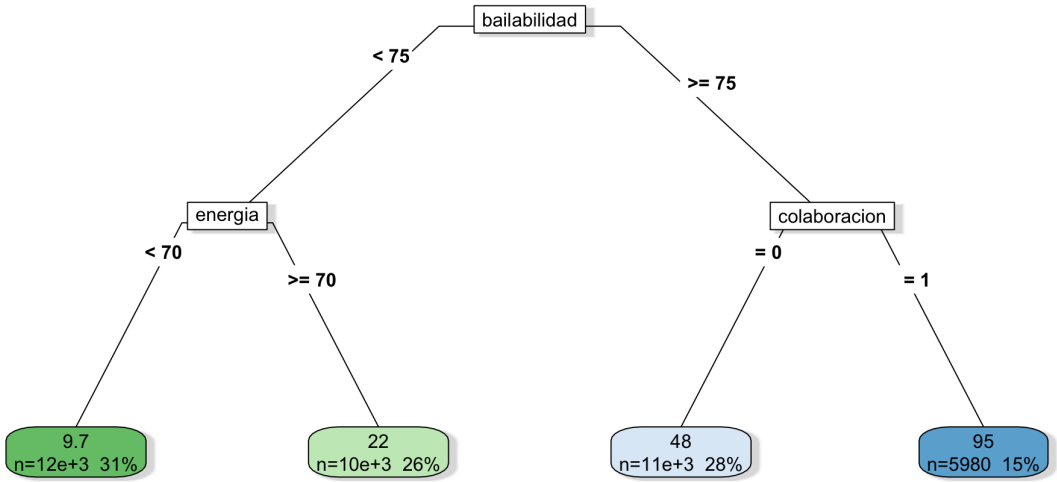
10.000 califican: el árbol no las ve al entrenar

En las 40.000 de entrenamiento, el promedio es **36.4 millones por canción**: ese número es la línea base — pronosticárselo a todas.

Lo que importa

La nota del árbol se mide solo en las 10.000 del sobre: ahí se ve si generalizó o si memorizó.

El árbol entrenado: tres preguntas, cuatro hojas



Cada caja: arriba, **los millones que predice** (el promedio de su grupo); abajo, cuántas canciones de entrenamiento caen ahí y qué % son (`n=12e+3` son 12.000).

Primero pregunta por la **bailabilidad**; entre las bailables, la **colaboración** separa 48 de 95 millones; entre las demás, la **energía** separa 9.7 de 21.9.

Lo que importa

De cinco variables usó tres: ni el `bpm` ni la duración ganaron una pregunta. Y el hallazgo del negocio: **entre las bailables, el *featuring* casi duplica las reproducciones**.

¿Cómo le fue, canción por canción?

Canción	Bail.	Colab.	Energía	Real	Pron.	Error
URB00002	57	sí	67	2.8	9.7	6.9
URB00007	62	no	79	12.2	21.9	9.7
URB00008	58	no	70	16.3	21.9	5.6
URB00010	65	no	68	2.3	9.7	7.4
URB00011	66	no	59	0.1	9.7	9.6
URB00016	91	no	100	36.5	48.0	**11.5**
URB00022	70	no	86	24.1	21.9	**2.2**
URB00026	99	no	82	61.2	48.0	13.2

Las primeras ocho canciones del test; reproducciones en millones.

Cada pronóstico es el promedio de la hoja donde cae la canción, y cada canción deja **una distancia en millones**.

A URB00022 casi le atina (2.2). Con URB00026 — bailable sin *featuring* que explotó — se queda corto por 13.2: la hoja predice su promedio, no los éxitos atípicos.

¿Cómo le fue, canción por canción?

Canción	Bail.	Colab.	Energía	Real	Pron.	Error
URB00002	57	sí	67	2.8	9.7	6.9
URB00007	62	no	79	12.2	21.9	9.7
URB00008	58	no	70	16.3	21.9	5.6
URB00010	65	no	68	2.3	9.7	7.4
URB00011	66	no	59	0.1	9.7	9.6
URB00016	91	no	100	36.5	48.0	**11.5**
URB00022	70	no	86	24.1	21.9	**2.2**
URB00026	99	no	82	61.2	48.0	13.2

Las primeras ocho canciones del test; reproducciones en millones.

Cada pronóstico es el promedio de la hoja donde cae la canción, y cada canción deja **una distancia en millones**.

A URB00022 casi le atina (2.2). Con URB00026 — bailable sin *featuring* que explotó — se queda corto por 13.2: la hoja predice su promedio, no los éxitos atípicos.

Lo que importa

En regresión no se pregunta «¿acertó?» sino **«¿por cuánto se equivocó?»** — y eso se promedia.

¿Cómo se calcula el MAE?

Con las ocho canciones de la lámina anterior, en tres pasos:

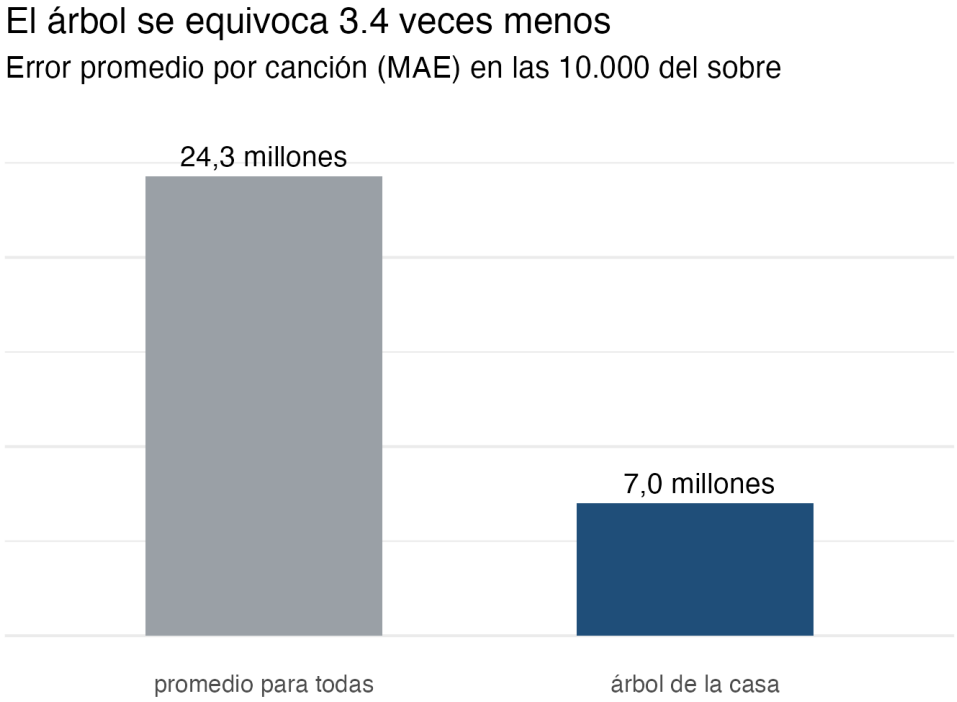
Paso	Con las 8 de la lámina 7
1. El error absoluto de cada una $\lvert$pronóstico $-$ real$\rvert$	6.9; 9.7; 5.6; 7.4; 9.6; 11.5; 2.2; 13.2
2. Súmalos	$6.9 + 9.7 + \cdots + 13.2$ $= \mathbf{66.1\ millones}$
3. Divide entre las canciones	$66.1 \div 8$ $= \mathbf{8.3\ millones}$

La misma cuenta con las **10.000 canciones del sobre**: el árbol se equivoca **7.0 millones** por canción; el promedio, **24.3 millones**.

Lo que importa

El MAE del árbol sale de la misma cuenta que acabas de hacer a mano — solo que sobre 10.000 canciones.

¿El árbol le gana al promedio?



- **La línea base**: pronosticar 36.4 millones a todas se equivoca **24.3 millones** por canción.
- **El árbol**: con tres preguntas, el error baja a **7.0 millones**: 3.4 veces menos.
- Con ese pronóstico, SonoUrbano prioriza: una canción que cae en la hoja de 95 millones no se promociona igual que una en la de 9.7.

Lo que importa

La vara de la regresión es el promedio: el árbol la mejora **3.4 a 1**, en millones de reproducciones. Falta traducir ese error a dinero.

¿Qué cuesta equivocarse? El costo de oportunidad

El sello invierte en marketing **según lo que espera de cada canción**: \$1 millón de pesos por cada millón de reproducciones pronosticado (cifra ilustrativa). Cada millón de error **desvía esa inversión**: sobra donde no habrá reproducciones y falta donde sí.

Paso	**Promedio**	**Árbol de la casa**
1. Error por canción el MAE, en millones	24.3	7.0
2. Inversión desviada por canción error $\times$ \$1 millón	\$24.3 M	\$7.0 M
3. En un lote de 20 canciones por canción $\times$ 20	24.3×20 $=$ **\$486 M**	7.0×20 $=$ **\$140 M**

La recomendación

Decidir el lote con el promedio desvía **\$346 millones más** $(486 - 140)$ que decidirlo con el árbol. Adoptarlo — y quedarse con su regla: **bailabilidad y *featuring* mandan; el bpm y la duración, no**.