Analítica para los negocios
06327-ECO

Semana 12: El árbol que predice números — ¿qué tan popular será una canción?

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

20 de octubre de 2026

Objetivo de la sesión

La pregunta de negocio

A SonoUrbano, un sello de música urbana, le ofrecen canciones para comprar. Para decidir cuáles, necesita pronosticar: ¿qué tan popular será cada una?

Por primera vez el target es **un número**, no una categoría — y los datos son **reales**: canciones que conoces.

- Entrenar un árbol que, con las características de la canción y la trayectoria de su artista, pronostique su **popularidad** en Spotify (0–100: el índice que resume las reproducciones recientes).
- Medir el error **en puntos de popularidad** (MAE) contra la línea base del promedio.
- Convertir el pronóstico en la decisión: qué comprar y cuánto invertir en cada lanzamiento.

La herramienta es la de la semana pasada: cambia lo que guarda la hoja y cómo se mide el error.

Previously. . .

- **Semana 11: el primer árbol.** Entrenamos un árbol de clasificación con los frenos de fábrica de `rpart`: aprendió dos preguntas, encontró a 59 de los 354 que se iban y Growth decidió con costos si lo adoptaba.
- **El quiz de hoy.** Leímos árboles ya entrenados: cuántos casos caen en cada hoja, qué promedio predice y cómo se recorre el árbol con un caso nuevo.
- **La teoría de esta semana.** Cuando el target es un número, cada hoja guarda el promedio de su grupo y el error se mide en las unidades del target: el **MAE** es el error promedio por pronóstico.

Roadmap

1. Los datos y el sobre

2. Del árbol a la decisión

Los datos: 2.427 canciones urbanas, reales

La base pública de Spotify (TidyTuesday, enero 2020), filtrada al género urbano — reggaeton y latin hip hop, sin duplicados —: **2.427 canciones**. El target es `popularidad` (0–100): el índice que resume las reproducciones recientes.

Variable	**Qué mide**
`pop_artista`	la trayectoria: el promedio de popularidad de las otras canciones del artista
`tempo`	la velocidad de la canción, en golpes por minuto
`duracion_seg`	la duración, en segundos
`bailabilidad`	qué tan bailable es la canción (0–100)
`energia`	la intensidad de la pista (0–100)
`colaboracion`	1 si el título trae un *featuring*

`cancion` y `artista` identifican cada fila: en la base están Bad Bunny (24 canciones), J Balvin (37), Ozuna, Daddy Yankee... `anio` y `subgenero` completan las 11 columnas; a un artista nuevo en el catálogo se le asigna el promedio general (45.3).

Lo que importa

Las seis predictoras llegan con cualquier oferta nueva: una canción trae sus atributos **y a su artista con su historial**. El año **no** entra: toda oferta nueva llega con el año de hoy y no distingue entre canciones.

El sobre: unas canciones para aprender, otras para calificar

Queremos que el árbol **generalice** — que aprenda el patrón de la popularidad, no que se memorice sus 2.427 canciones. Eso solo se comprueba con canciones que no vio.

2.427 canciones

sorteo 80 / 20 $\longrightarrow$

1.942 entrenan: el árbol ve su popularidad

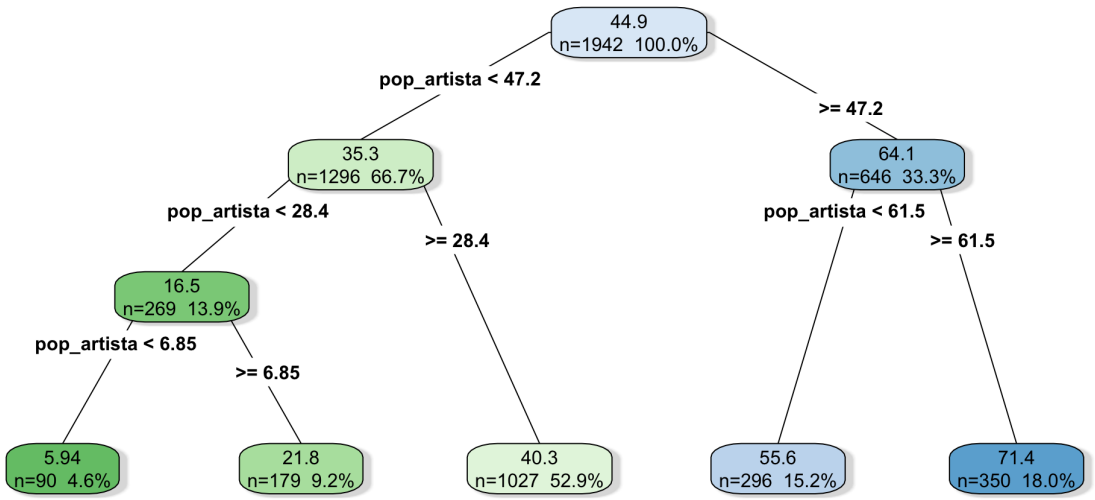
485 califican: el árbol no las ve al entrenar

En las 1.942 de entrenamiento, el promedio es **44.9 puntos de popularidad**: ese número es la línea base — pronosticárselo a todas.

Lo que importa

La nota del árbol se mide solo en las 485 del sobre: ahí se ve si generalizó o si memorizó.

El árbol entrenado: el artista manda



Cada caja: arriba, **la popularidad que predice** (el promedio de su grupo); abajo, cuántas canciones de entrenamiento caen ahí y qué % son.

Las cuatro preguntas son la misma: la **trayectoria del artista**. Una escalera de cinco escalones — historial muy bajo, 5.9; bajo, 21.8; medio, 40.3; alto, 55.6; y los artistas de 61.5 o más prometen **71.4**.

Lo que importa

De seis variables el árbol usó **una**: la trayectoria del artista, cuatro veces. Ni el tempo, ni la bailabilidad, ni el *featuring* ganaron una pregunta: **quién canta pesa más que cómo suena**.

¿Cómo le fue, canción por canción?

Canción	Artista	Trayectoria	Real	Pron.	Error
Me Gusta	Shakira	64.6	79	71.4	7.6
Estamos Bien	Bad Bunny	68.4	76	71.4	**4.6**
Si Te Vas	Sech	47.7	88	55.6	32.4
Felices los 4	Maluma	58.9	76	55.6	20.4
Aullando	Wisin & Yandel	35.6	80	40.3	39.7
Con Calma	Daddy Yankee	44.8	87	40.3	**46.7**
Gasolina	Daddy Yankee	44.8	76	40.3	35.7
Amor De Pobre	Zion	12.1	0	21.8	21.8

Ocho canciones del test; popularidad de 0 a 100.

Cada canción recibe el escalón de su artista: cuatro pronósticos distintos. A *Estamos Bien* (Bad Bunny, historial 68.4) casi le atina: error 4.6. A *Con Calma* no: vale 87 y recibe 40.3, porque el historial de Daddy Yankee promedia 44.8 — **un éxito supera el historial de cualquiera**, y por eso ningún árbol pronostica un hit.

En regresión la pregunta no es «¿acertó?» sino **«¿por cuánto se equivocó?»** — y eso se promedia.

¿Cómo se calcula el MAE?

Con las ocho canciones de la lámina anterior, en tres pasos:

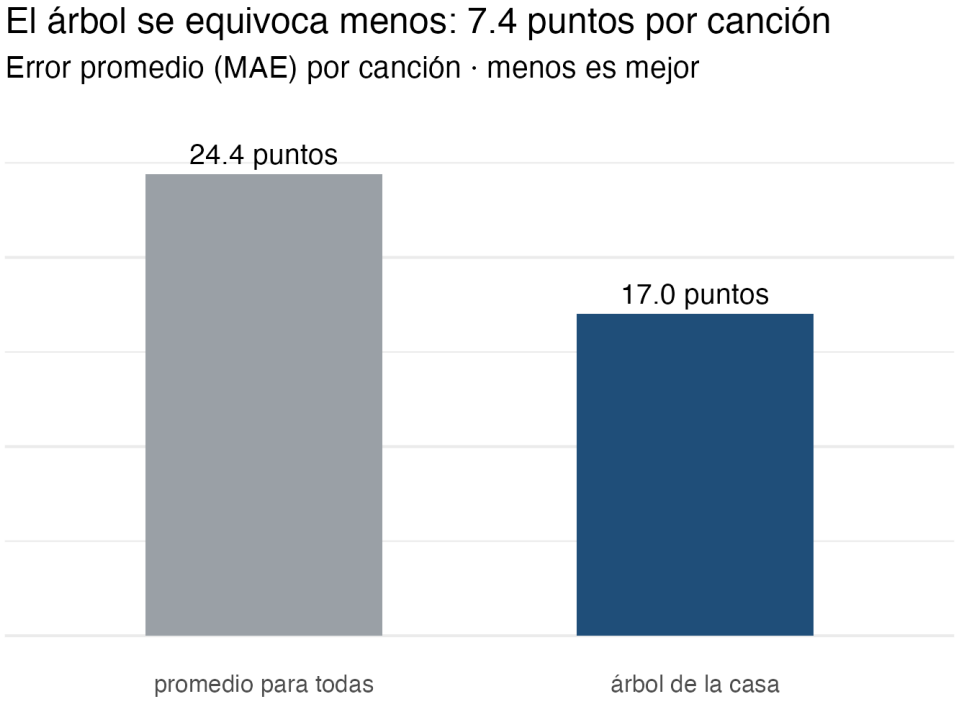
Paso	**Con las 8 de la lámina 7**
1. El error absoluto de cada una $\lvert$pronóstico $-$ real$\rvert$	7.6; 4.6; 32.4; 20.4; 39.7; 46.7; 35.7; 21.8
2. Súmalos	$7.6 + 4.6 + \cdots + 21.8$ $= \mathbf{208.9}$ **puntos**
3. Divide entre las canciones	$208.9 \div 8$ $= \mathbf{26.1}$ **puntos**

La misma cuenta con las **485 canciones del sobre** — ya no solo éxitos conocidos —: el árbol se equivoca **17.0 puntos** por canción; el promedio, **24.4 puntos**.

Lo que importa

El MAE del árbol sale de la misma cuenta que acabas de hacer a mano — solo que sobre 485 canciones.

¿El árbol le gana al promedio?



- **La línea base**: pronosticar 44.9 puntos a todas se equivoca **24.4 puntos** por canción.
- **El árbol**: con la trayectoria del artista, el error baja a **17.0 puntos**: 7.4 menos por canción, un 30 % menos.
- El error es menor — y **al elegir es donde se nota**: 20 canciones al azar promedian **46.6** de popularidad real; las 20 de la hoja top del árbol, **72.3**.

Lo que importa

La vara de la regresión es el promedio: el árbol le gana por **7.4 puntos por canción**. Pero el negocio no es el error promedio: es **elegir cuáles comprar**.

¿Cuánto vale el pronóstico? La decisión de compra

SonoUrbano va a comprar **20 canciones**, y cada punto de popularidad que consigan vale \$1 millón de pesos por canción (cifra ilustrativa). Sin modelo compra al azar: el promedio le pronostica lo mismo a todas y no distingue. Con el árbol, compra de la **hoja de 71.4** (los artistas de historial alto).

Paso	**Al azar**	**Con el árbol**
1. ¿Cuáles 20 compra?	cualquiera del catálogo	las de la hoja de 71.4
2. Popularidad real que consigue promedio por canción, en el test	46.6	72.3
3. Valor del lote real $\times$ \$1 millón $\times$ 20	46.6×20 $=$ **\$932 M**	72.3×20 $=$ **\$1.446 M**

La recomendación

El lote elegido con el árbol vale **\$514 millones más** $(1.446 - 932)$: \$25.7 millones más por canción. Adoptarlo — con su límite a la vista: los éxitos como *Con Calma* superan cualquier historial. **Ningún modelo pronostica un hit**.