Analítica para los negocios
06327-ECO

Semana 12: El árbol que predice números — ¿qué tan popular será una canción?

Eduard F. Martínez González, Ph.D.

Departamento de Economía, Universidad Icesi

20 de octubre de 2026

Objetivo de la sesión

La pregunta de negocio

A SonoUrbano, un sello de música urbana, le ofrecen canciones para comprar. Para decidir cuáles, necesita pronosticar: ¿qué tan popular será cada una?

Por primera vez el target es **un número**, no una categoría — y los datos son **reales**: canciones que conoces.

- Entrenar un árbol que, con las características de la canción, pronostique su **popularidad** en Spotify (0–100: el índice que resume las reproducciones recientes).
- Medir el error **en puntos de popularidad** (MAE) contra la línea base del promedio.
- Convertir el pronóstico en la decisión: qué comprar y cuánto invertir en cada lanzamiento.

La herramienta es la de la semana pasada: cambia lo que guarda la hoja y cómo se mide el error.

Previously. . .

- **Semana 11: el primer árbol.** Entrenamos un árbol de clasificación con los frenos de fábrica de `rpart`: aprendió dos preguntas, encontró a 59 de los 354 que se iban y Growth decidió con costos si lo adoptaba.
- **El quiz de hoy.** Leímos árboles ya entrenados: cuántos casos caen en cada hoja, qué promedio predice y cómo se recorre el árbol con un caso nuevo.
- **La teoría de esta semana.** Cuando el target es un número, cada hoja guarda el promedio de su grupo y el error se mide en las unidades del target: el **MAE** es el error promedio por pronóstico.

Roadmap

1. Los datos y el sobre

2. Del árbol a la decisión

Los datos: 2.427 canciones urbanas, reales

La base pública de canciones de Spotify (proyecto TidyTuesday, enero de 2020), filtrada al género urbano — reggaeton y latin hip hop, sin duplicados —: **2.427 filas, una por canción**. El target es `popularidad` (0–100): el índice de Spotify que resume las reproducciones recientes.

Variable	Qué mide
`tempo`	la velocidad de la canción, en golpes por minuto
`duracion_seg`	la duración, en segundos
`bailabilidad`	qué tan bailable es la canción (0–100)
`energia`	la intensidad de la pista (0–100)
`colaboracion`	1 si el título trae un *featuring*

`cancion` y `artista` identifican cada fila: en la base están Bad Bunny (24 canciones), J Balvin (37), Ozuna, Daddy Yankee... `anio` y `subgenero` completan las 10 columnas.

Lo que importa

Las cinco predictoras son **atributos de la canción**: cualquier oferta nueva los trae el día del lanzamiento. El año **no** entra: una canción nueva llega con el año de hoy y no distingue entre las ofertas. El artista tampoco: queda para la discusión.

El sobre: unas canciones para aprender, otras para calificar

Queremos que el árbol **generalice** — que aprenda el patrón de la popularidad, no que se memorice sus 2.427 canciones. Eso solo se comprueba con canciones que no vio.

2.427 canciones

sorteo 80 / 20 $\longrightarrow$

1.942 entrenan: el árbol ve su popularidad

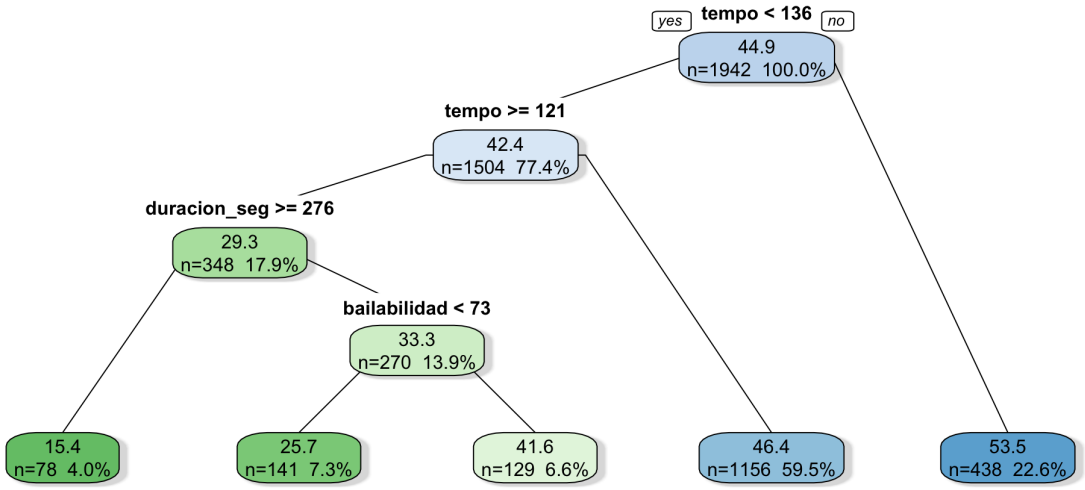
485 califican: el árbol no las ve al entrenar

En las 1.942 de entrenamiento, el promedio es **44.9 puntos de popularidad**: ese número es la línea base — pronosticárselo a todas.

Lo que importa

La nota del árbol se mide solo en las 485 del sobre: ahí se ve si generalizó o si memorizó.

El árbol entrenado: el tempo manda



Cada caja: arriba, **la popularidad que predice** (el promedio de su grupo); abajo, cuántas canciones de entrenamiento caen ahí y qué % son.

Primero pregunta por el **tempo**: las rápidas (136 o más) prometen **53.5**; las lentas (menos de 121), 46.4. En el tempo medio decide el resto: 15.4 si es larga (276 s o más); si es corta, 25.7 o 41.6 según la **bailabilidad**.

Lo que importa

Cuatro nodos y cinco hojas con tres variables: el tempo (dos veces), la duración y la bailabilidad. Ni la energía ni el *featuring* ganaron una pregunta — y ningún atributo reconoce un éxito: **eso lo pone el artista**.

¿Cómo le fue, canción por canción?

Canción	Artista	Tempo	Dur. (seg)	Real	Pron.	Error
Si Te Vas	Sech	174	205	88	53.5	34.5
Atrévete	Nicky Jam	184	198	81	53.5	27.5
Me Gusta	Shakira	92	191	79	46.4	32.6
Aullando	Wisin & Yandel	90	226	80	46.4	33.6
Con Calma	Daddy Yankee	94	193	87	46.4	**40.6**
Felices los 4	Maluma	94	230	76	46.4	29.6
Zumba	Don Omar	125	264	57	41.6	15.4
Taboo	Don Omar	125	292	1	15.4	**14.4**

Ocho canciones del test; popularidad de 0 a 100.

Cada canción cae en una hoja y recibe su promedio: cuatro pronósticos distintos. A *Taboo* — casi sin audiencia — le pronostica 15.4, cerca de su 1 real. A los éxitos, en cambio, los subestima: *Con Calma* vale 87 y recibe 46.4; *Si Te Vas*, 88 contra 53.5 — la hoja predice el promedio de su grupo, y **el árbol no sabe quién canta**: el artista no está entre los atributos.

En regresión la pregunta no es «¿acertó?» sino **«¿por cuánto se equivocó?»** — y eso se promedia.

¿Cómo se calcula el MAE?

Con las ocho canciones de la lámina anterior, en tres pasos:

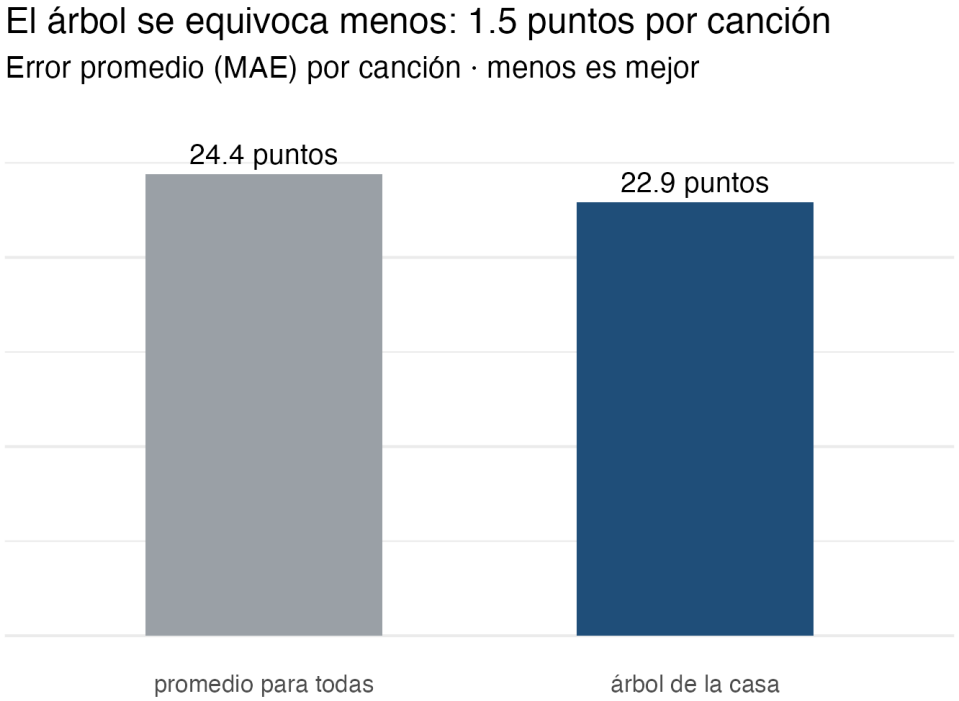
Paso	Con las 8 de la lámina 7
1. El error absoluto de cada una $\lvert$pronóstico $-$ real$\rvert$	34.5; 27.5; 32.6; 33.6; 40.6; 29.6; 15.4; 14.4
2. Súmalos	$34.5 + 27.5 + \cdots + 14.4$ $= \mathbf{228.2\ puntos}$
3. Divide entre las canciones	$228.2 \div 8$ $= \mathbf{28.5\ puntos}$

La misma cuenta con las **485 canciones del sobre** — ya no solo éxitos conocidos —: el árbol se equivoca **22.9 puntos** por canción; el promedio, **24.4 puntos**.

Lo que importa

El MAE del árbol sale de la misma cuenta que acabas de hacer a mano — solo que sobre 485 canciones.

¿El árbol le gana al promedio?



- **La línea base**: pronosticar 44.9 puntos a todas se equivoca **24.4 puntos** por canción.
- **El árbol**: con el tempo, la duración y la bailabilidad, el error baja a **22.9 puntos**: 1.5 menos por canción, un 6 % menos.
- El error es menor — y **al elegir es donde se nota**: 20 canciones al azar promedian **46.6** de popularidad real; las 20 de la hoja top del árbol, **54.3**.

Lo que importa

La vara de la regresión es el promedio: el árbol le gana por **1.5 puntos por canción**. Pero el negocio no es el error promedio: es **elegir cuáles comprar**.

¿Cuánto vale el pronóstico? La decisión de compra

SonoUrbano va a comprar **20 canciones**, y cada punto de popularidad que consigan vale $1 millón de pesos por canción (cifra ilustrativa). Sin modelo compra al azar: el promedio le pronostica lo mismo a todas y no distingue. Con el árbol, compra de la **hoja de 53.5** (las rápidas).

Paso	**Al azar**	**Con el árbol**
1. ¿Cuáles 20 compra?	cualquiera del catálogo	las de la hoja de 53.5
2. Popularidad real que consigue promedio por canción, en el test	46.6	54.3
3. Valor del lote real $\times$ $1 millón $\times$ 20	46.6×20 $=$ **$932 M**	54.3×20 $=$ **$1.086 M**

La recomendación

El lote elegido con el árbol vale **$154 millones más** ($1.086 - 932$): $7.7 millones más por canción. Adoptarlo — y para reconocer los éxitos uno a uno, conseguir la variable que falta: **el artista**.